Universidad Rey Juan Carlos

ESCUELA DE INGENIERÍA DE FUENLABRADA

GRADO EN INGENIERÍA EN INGENIERÍA BIOMÉDICA

TRABAJO FIN DE GRADO

Planificación adaptativa de trayectorias articulares para exoesqueletos de rehabilitación motora mediante inteligencia artificial

Autor: Manuel Guerrero Sancho

Tutor: Juan Carballeira López

Curso académico 2025/2026

"Un viaje de mil millas siempre comienza con un primer paso"
(Lao Tzu)

Agradecimientos

Quiero empezar agradeciendo a mi familia, por su apoyo incondicional a lo largo de todos estos años. Gracias por enseñarme el valor del esfuerzo, por animarme en los momentos difíciles y por darme siempre la oportunidad de estudiar aquello que me apasiona.

También quiero agradecer a mis amigos, a los que he tenido más ausentes de lo que me habría gustado mientras terminaba este proyecto. Gracias por entender mis desapariciones, por aguantar mis quejas por plazos y entregas y por estar ahí para obligarme a desconectar.

Por último, quiero dar las gracias a mi novia, Laura. Juntos hemos sobrevivido a noches eternas de estudio, a asignaturas que parecían imposibles y a entregas que llegaban demasiado rápido, pero también hemos compartido risas en mitad del agobio y momentos de calma entre tanto caos. No solo ha estado a mi lado en cada etapa de este proceso, sino que ha transformado este camino en algo mucho más bonito de lo que jamás podía haber imaginado al empezar.

Gracias.

Resumen

La rehabilitación de la marcha asistida por robot requiere trayectorias articulares biomecánicamente coherentes, adaptables a cada paciente y controlables mediante metas clínicas como la longitud y la altura de paso. En el proyecto NIMBLE, que desarrolla un exoesqueleto de miembro inferior con actuador pélvico por cables y un sistema ambulatorio de soporte de peso, se diseñó inicialmente un planificador basado en algoritmos evolutivos integrado con un modelo cinemático directo, capaz de generar trayectorias de alta calidad pero con tiempos de cálculo incompatibles con su usabilidad en tiempo real. Para superar esta limitación se propuso un modelo de red neuronal tipo perceptrón multicapa que imita dicho planificador, reduciendo el coste computacional a costa de requerir grandes volúmenes de datos de entrenamiento.

En este contexto, el objetivo de este trabajo es diseñar, entrenar y evaluar un modelo generativo adversarial condicionado (cGAN) capaz de sintetizar ciclos articulares de la marcha humana a partir de metas clínicas y medidas antropométricas. Se plantea una cGAN de tipo Wasserstein con penalización por gradiente que genera trayectorias de flexión de cadera, rodilla y tobillo y de inclinación pélvica condicionadas por la longitud y la altura de paso y por la antropometría del usuario. El modelo se entrena con datos experimentales de sujetos sanos registrados y procesados con el modelo cinemático directo de NIMBLE, que proporciona posiciones cartesianas del pie y de la pelvis y las métricas clínicas asociadas a cada ciclo.

El rendimiento se evalúa mediante análisis estadístico de la distribución sintética generada, junto con un estudio biomecánico de las trayectorias cartesianas del pie y de la consistencia entre metas impuestas y reconstruidas. Los resultados muestran que la cGAN reproduce con alta fidelidad la forma media del ciclo y la variabilidad de cadera, rodilla y pelvis, preserva los patrones principales de coordinación interarticular y genera trayectorias del pie espacialmente plausibles. La altura de paso mantiene una correspondencia estrecha con las condiciones clínicas, mientras que la longitud de paso y el comportamiento del tobillo presentan una degradación mayor al generar nuevos datos. Además, las limitaciones en el cierre exacto del ciclo obligan a descartar una fracción de las secuencias. En conjunto, el trabajo demuestra que las cGAN constituyen una vía prometedora para la síntesis de trayectorias articulares condicionadas en rehabilitación de la marcha y complementan el modelo neuronal existente en NIMBLE, aunque será necesario reforzar la periodicidad y el control de la longitud de paso para su integración clínica robusta.

Índice general

Agradecimientos **III**

Resumen **V**

Lista de figuras **IX**

Lista de tablas **XV**

1. Introducción **1**

1.1. Contexto y motivación 1

1.2. Objetivos 2

1.3. Metodología 2

1.4. Estructura de la memoria 3

2. Fundamentos teóricos **5**

2.1. Biomecánica de la marcha humana 5

2.1.1. Articulaciones implicadas en el proceso de la marcha 5

2.1.2. Fases del ciclo de la marcha 7

2.2. Contexto clínico y tecnológico de la rehabilitación de la marcha . . . 13

2.3. Paso histórico por las tendencias en RAGT 15

2.4. Proyecto NIMBLE 17

2.5. Cálculo de trayectorias para la marcha asistida 19

2.6. Inteligencia artificial en el control de exoesqueletos 21

2.7. Redes Generativas Antagónicas 23

3. Solución técnica **27**

3.1. Datos de entrenamiento y preprocesado 27

3.2. Arquitectura: Generador y Crítico 29

3.2.1. Generador (G) 29

3.2.2. Crítico (C) 30

3.3. Funciones de pérdida 31

3.4. Protocolo de entrenamiento 33

3.5. Herramientas utilizadas 34

3.5.1. Python 34

3.5.2. MATLAB 36

3.5.3. Datos NIMBLE 36

4. Evaluación y resultados **37**

4.1. Análisis de distribución 38

4.1.1. Análisis de las curvas promedio 38

4.1.2. Acoplamiento interarticular 43

4.1.3. Análisis mediante componentes principales (PCA) 46

4.2. Análisis biomecánico 50

4.2.1. Consistencia de las condiciones clínicas 51

4.2.2. Análisis de las trayectorias cartesianas del pie 55

4.2.3. Análisis temporal de las trayectorias del pie 59

5. Discusión **61**

6. Conclusiones y líneas futuras **65**

Lista de figuras

2.1. Clasificación del ciclo de la marcha humana. Imagen tomada de Haas et al. (2015) [1]. 7

2.2. Subfases de la fase de apoyo (stance phase) de la marcha humana. Imagen recortada y adaptada de Haas et al. (2015) [1]. 10

2.3. Subfases de la fase de balanceo (swing phase) de la marcha humana. Imagen recortada y adaptada de Haas et al. (2015) [1]. 12

2.4. Distribución de las alteraciones de la marcha en supervivientes de ictus. El anillo interior refleja la proporción global de pacientes con y sin alteraciones, mientras que el exterior desglosa el 80 % afectado según la gravedad [8, 9]. 14

2.5. Comparativa de distintos exoesqueletos utilizados históricamente en el entrenamiento de la marcha asistido por robot (RAGT). La imagen incluye: (a) Lokomat, (b) LOPES, (c) HAL y (d) ReStore. Cada fotografía ha sido adaptada de sus fuentes originales, indicadas en [30–33]. 17

2.6. Diagrama del robot NIMBLE, que integra un bastidor móvil, un sistema de soporte parcial de peso (PBWS), un actuador pélvico por cables y el exoesqueleto de miembro inferior Exo-H3. Imagen adaptada de [34]. 18

4.1. Comparación entre las curvas promedio reales y sintéticas para las cuatro articulaciones analizadas (cadera, rodilla, tobillo e inclinación pélvica) en el conjunto de entrenamiento. La línea continua representa la media de las señales reales y la línea discontinua la media de las señales generadas por el modelo, mientras que las bandas sombreadas muestran la dispersión típica ($\pm 1\sigma$) en cada conjunto. 40

4.2. Comparación entre las curvas promedio reales y sintéticas para las cuatro articulaciones analizadas (cadera, rodilla, tobillo e inclinación pélvica) en el conjunto de validación. La línea continua representa la media de las señales reales y la línea discontinua la media de las señales generadas por el modelo, mientras que las bandas sombreadas muestran la dispersión típica ($\pm 1\sigma$) en cada conjunto. 41

4.3. Matriz de acoplamiento interarticular obtenida a partir de los datos reales del conjunto de entrenamiento. Cada elemento refleja la correlación media entre dos articulaciones durante el ciclo de marcha. . . . 44

4.4. Matriz de acoplamiento interarticular obtenida a partir de los datos reales del conjunto de validación. Cada elemento refleja la correlación media entre dos articulaciones durante el ciclo de marcha. 44

4.5. Matriz de acoplamiento interarticular obtenida a partir de las señales sintéticas generadas por el modelo en el conjunto de entrenamiento. . 45

4.6. Matriz de acoplamiento interarticular obtenida a partir de las señales sintéticas generadas por el modelo en el conjunto de validación. . . . 45

4.7. Matriz de diferencias del acoplamiento interarticular en el conjunto de entrenamiento. 46

4.8. Matriz de diferencias del acoplamiento interarticular en el conjunto de validación. 46

4.9. Proyección conjunta de los ciclos reales y sintéticos del conjunto de entrenamiento en el plano PCA.. Se muestran los centroides y las elipses de dispersión de una desviación estándar de cada conjunto. . . 48

4.10. Proyección conjunta de los ciclos reales y sintéticos del conjunto de validación en el plano PCA. Se muestran los centroides y las elipses de dispersión de una desviación estándar de cada conjunto. 48

4.11. Plano L–H comparando las condiciones de entrada (X_{cond}) y las obtenidas tras el modelo cinemático (X_{real}) en el conjunto de entrenamiento. 51

4.12. Plano L–H comparando las condiciones de entrada (X_{cond}) y las obtenidas tras el modelo cinemático (X_{real}) en el conjunto de validación. 51

4.13. Diagramas de dispersión para la comparación entre X_{real} y X_{cond} en el conjunto de entrenamiento. 52

4.14. Comparación entre las condiciones clínicas y los valores reconstruidos en el conjunto de validación. Izquierda longitud de paso. Derecha altura de paso. La recta discontinua representa la recta identidad $y = x$. 52

4.15. Distribución del error firmado entre condiciones y valores reconstruidos en el conjunto de entrenamiento, agrupado por tramos de condición. 54

4.16. Distribución del error firmado entre condiciones y valores reconstruidos en el conjunto de validación, agrupado por tramos de condición. . 54

4.17. Trayectorias cartesianas sagitales (X) del tobillo reconstruidas mediante el modelo cinemático en el conjunto de entrenamiento. Las líneas finas representan todas las muestras, la línea gruesa indica la media y la banda sombreada corresponde a ± 1 desviación estándar. . 57

4.18. Trayectorias anteroposteriores (X) del tobillo reconstruidas a partir de las señales sintéticas del conjunto de validación. 57

4.19. Trayectorias cartesianas verticales (Z) del tobillo, talón y punta reconstruidas mediante el modelo cinemático en el conjunto de entrenamiento. 58

4.20. Trayectoria vertical del pie derecho en la coordenada Z para la señal `R_toe_Z` en el conjunto de entrenamiento. 58

4.21. Trayectorias verticales (Z) del tobillo, talón y punta reconstruidas a partir de las señales sintéticas del conjunto de validación. 59

5.1. Trayectorias del pie en X recreadas con el total de los datos sintéticos de entrenamiento tras aplicar un desfase del 50 %. 63

5.2. Trayectorias del pie en Z recreadas con el total de los datos sintéticos de entrenamiento tras aplicar un desfase del 50 %. 63

Lista de tablas

4.1. Curvas promedio reales y sintéticas en el conjunto de entrenamiento. Se muestra el rango angular de la curva media real (A_j), el error cuadrático medio entre curvas promedio (RMSE_j), su versión relativa normalizada respecto al rango ($\mathrm{RMSE}_j^{\mathrm{rel}}$) y la correlación de Pearson (r_j). 42

4.2. Curvas promedio reales y sintéticas en el conjunto de validación. Se indica el rango angular de la curva media real, el RMSE absoluto entre las curvas promedio, el RMSE relativo normalizado por el rango y la correlación de Pearson para cada articulación. 42

4.3. Percentiles del error absoluto entre las condiciones deseadas y las reconstruidas en el conjunto de entrenamiento. 55

4.4. Percentiles del error absoluto entre las condiciones deseadas y las reconstruidas en el conjunto de validación ($N = 771$). 55

4.5. Duraciones temporales de las fases del ciclo de marcha estimadas mediante el modelo cinemático en el conjunto de entrenamiento. . . . 60

4.6. Duraciones temporales de las fases del ciclo de marcha estimadas mediante el modelo cinemático en el conjunto de validación. 60

Capítulo 1

Introducción

1.1. Contexto y motivación

El análisis y la síntesis de patrones de marcha humana son elementos fundamentales en ingeniería biomédica, especialmente en aplicaciones relacionadas con la rehabilitación del movimiento. Muchos de estos sistemas dependen de disponer de trayectorias articulares que sean biomecánicamente coherentes, que respondan a metas clínicas concretas y que puedan adaptarse a las características individuales de cada usuario. Esta necesidad es particularmente importante en la rehabilitación robótica, donde la calidad y el realismo de las trayectorias influyen directamente en la eficacia del entrenamiento y en la naturalidad del movimiento asistido.

En este contexto se enmarca el proyecto NIMBLE, que persigue el desarrollo de un sistema de rehabilitación de la marcha que integra un exoesqueleto de miembro inferior, un actuador pélvico por cables y un sistema ambulatorio de soporte y guiado del paciente. En este tipo de plataformas, la generación de trayectorias articulares no es un módulo aislado, sino un componente central que permite traducir objetivos clínicos formulados en el espacio cartesiano del pie en secuencias angulares del miembro inferior compatibles con la cinemática del exoesqueleto y del actuador pélvico. El enfoque inicial del proyecto, basado en algoritmos evolutivos, proporciona trayectorias de alta calidad, pero a costa de tiempos de cálculo demasiado elevados para aplicaciones interactivas o de tiempo real dentro del sistema completo. Para solventar esta limitación, NIMBLE optó por emplear redes neuronales capaces de aprender el comportamiento del algoritmo evolutivo y generar trayectorias articulares de forma prácticamente inmediata. Sin embargo, estos modelos requieren grandes volúmenes de datos y no siempre capturan toda la variabilidad natural del movimiento humano.

En los últimos años, las redes generativas antagónicas (GAN) han emergido como

una alternativa sólida para ampliar conjuntos de datos y mejorar la diversidad de las señales generadas. Resulta, por tanto, natural plantearse su uso para sintetizar movimientos de marcha humana realistas, reproduciendo tanto la forma media como la variabilidad natural de sus patrones. Motivado por estas necesidades, este trabajo propone integrar en la arquitectura de NIMBLE una red generativa antagónica condicionada (cGAN) encargada de producir trayectorias articulares de la marcha que dependan explícitamente de la longitud y la altura del paso, así como de la antropometría del usuario. De este modo, se persigue dotar al sistema de rehabilitación de una herramienta de síntesis de movimiento rápida, flexible y potencialmente más robusta que los métodos evolutivos clásicos, manteniendo la fidelidad biomecánica necesaria para su empleo seguro en el exoesqueleto del proyecto NIMBLE.

1.2. Objetivos

Este trabajo tiene como finalidad explorar el uso de un enfoque generativo adversarial condicionado (cGAN) como mecanismo de entrenamiento para obtener un modelo generativo capaz de sintetizar trayectorias articulares de la marcha humana a partir de metas clínicas relevantes. En concreto, los objetivos principales del estudio son los siguientes:

- Diseñar un modelo generativo basado en una arquitectura cGAN capaz de producir ciclos articulares de la marcha condicionados por la longitud y la altura de paso, así como por la antropometría del usuario.
- Entrenar el modelo generativo utilizando las trayectorias articulares registradas en el proyecto NIMBLE y las correspondientes metas clínicas de paso obtenidas mediante su modelo cinemático directo, de modo que el generador aprenda la relación existente entre metas clínicas y cinemática articular.
- Evaluar la coherencia estadística y biomecánica de las trayectorias sintéticas, analizando su similitud con el comportamiento real del movimiento humano y su validez una vez reconstruidas en el espacio cartesiano.

1.3. Metodología

En primer lugar, se recopilaron las trayectorias articulares proporcionadas por el proyecto NIMBLE y se procesaron mediante su modelo cinemático directo. Aunque dicho modelo describe todos los grados de libertad del sujeto, en este trabajo se restringió su uso a la cadera, rodilla, tobillo y a la inclinación pélvica, por ser los únicos grados de libertad actuados en el exoesqueleto del mismo proyecto. A partir

de las medidas antropométricas del sujeto y de la evolución angular de estas articulaciones, el modelo permite obtener las posiciones cartesianas del pie y de la pelvis durante la marcha, así como las métricas clínicas asociadas a cada ciclo (longitud y altura de paso). Estas señales constituyeron el conjunto de datos empleado para entrenar y evaluar el modelo generativo.

Posteriormente, se diseñó una red generativa antagónica condicionada basada en la formulación WGAN-GP (*Wasserstein Generative Adversarial Network with Gradient Penalty*). El generador recibe como entrada un vector de ruido latente junto con las condiciones clínicas y antropométricas, y produce un ciclo articular completo. El crítico evalúa la coherencia de las trayectorias sintetizadas frente a las reales incorporando las mismas condiciones en su entrada. El entrenamiento se realizó de forma adversarial, alternando ambas redes e incluyendo términos adicionales en la función de pérdida para mejorar la estabilidad y fomentar la continuidad temporal del ciclo.

Una vez entrenado el modelo, su funcionamiento se evaluó en dos planos complementarios. En el plano estadístico, se analizaron las curvas promedio, la variabilidad temporal, las correlaciones entre articulaciones y la distribución global de los ciclos en el espacio de componentes principales. En el plano biomecánico, a través del modelo cinemático directo de NIMBLE, las trayectorias sintéticas se proyectaron de nuevo al espacio cartesiano aplicando un desfase del 50 % para reconstruir la pierna contralateral, lo que permitió estudiar la geometría del movimiento del pie, verificar la consistencia de las condiciones clínicas obtenidas y estimar la secuencia temporal de eventos del ciclo de marcha. Este análisis permitió identificar las limitaciones actuales del modelo y determinar los aspectos que requieren ajustes en versiones futuras.

1.4. Estructura de la memoria

La memoria se organiza de la siguiente manera:

- **Fundamentos teóricos:** Se presentan los conceptos necesarios para contextualizar el trabajo, incluyendo biomecánica de la marcha, la rehabilitación de la marcha, la generación de trayectorias, el aprendizaje profundo y los modelos generativos adversarios.
- **Solución técnica:** Se describe el proceso completo seguido para preparar los datos, diseñar el modelo, entrenarlo y las herramientas utilizadas para hacer el proyecto realidad.
- **Evaluación y resultados:** Se analizan los resultados obtenidos sobre los conjuntos de entrenamiento y validación. Esto incluye el estudio estadístico de

las trayectorias generadas y la evaluación biomecánica realizada mediante el modelo cinemático de NIMBLE.

- **Discusión:** Se interpretan los resultados en detalle, relacionándolos con la literatura previa y discutiendo sobre las diferencias entre ambos conjuntos generados y la discrepancia observada entre la fidelidad estadística del generador y las limitaciones del análisis clínico.
- **Conclusiones y líneas futuras:** Se resumen los aportes principales del trabajo y se establecen las mejoras necesarias para etapas posteriores.

Capítulo 2

Fundamentos teóricos

2.1. Biomecánica de la marcha humana

La marcha, definida de forma sencilla como la acción de caminar, es un proceso cíclico y complejo que permite el desplazamiento del cuerpo humano hacia una dirección. Este proceso requiere la acción coordinada de diversos músculos y articulaciones tanto de las extremidades inferiores como de las superiores, además de la pelvis y la columna vertebral. Desde un punto de vista biomecánico, la marcha puede definirse como la sucesión repetida de ciclos de movimiento en los que el cuerpo avanza, de forma estable y continuada, en una dirección mientras mantiene el equilibrio del sistema y optimiza su gasto energético. Cada uno de estos ciclos de movimiento, denominados ciclos de la marcha, comienza cuando el talón de uno de los pies hace contacto con el suelo y finaliza cuando ese mismo pie vuelve a realizar un nuevo contacto con la superficie.

Cada uno de estos ciclos de la marcha, aun siendo encadenados uno detrás de otro hasta el fin del desplazamiento, no genera una secuencia rígida de movimientos. Por el contrario, la marcha es un patrón dinámico en el que se va ajustando de forma constante su cinemática en función del entorno y las metas del paso que va a realizar, todo ello mientras minimiza el coste energético asociado a este desplazamiento mediante movimientos suaves y continuos.

2.1.1. Articulaciones implicadas en el proceso de la marcha

Para obtener un patrón de marcha correcto es esencial la acción coordinada de múltiples articulaciones incluyendo las articulaciones ubicadas desde la pelvis hasta

el pie, la participación adicional del tronco y las extremidades superiores y una red compleja de musculatura que controla el movimiento. Aunque todas contribuyen al patrón global, las más relevantes desde el punto de vista de la locomoción están asociadas a movimientos en el plano sagital. Este es el plano en el que se producen los movimientos de flexión y extensión, permitiendo el avance del cuerpo. Las articulaciones más relevantes en este plano son la cadera, la rodilla y el complejo tobillo–pie. Adicionalmente encontramos la pelvis y la columna vertebral cuyo objetivo se centra en el control de la estabilidad y el equilibrio en el plano frontal.

La cadera es una articulación esférica que conecta el fémur del miembro inferior con el acetábulo de la pelvis. Esta articulación permite orientar el muslo en el espacio y ayuda a regular la longitud del paso mediante movimientos de flexoestensión, abducción-adducción y rotación interna y externa. Sus movimientos de flexoestensión en el plano sagital controlan el avance del miembro y la posición relativa del pie respecto al centro de masas, facilitando tanto la propulsión como la colocación del pie para el siguiente contacto inicial. Además, en los planos frontal y transversal, la cadera contribuye al control de la estabilidad lateral y a la rotación del miembro durante la marcha.

La rodilla es una articulación sinovial compleja situada a la mitad del miembro inferior conectando el fémur con la tíbia y el peroné. Su función varía según la fase del ciclo de la marcha. Durante el apoyo, su capacidad de flexión permite amortiguar las fuerzas de reacción del suelo, mientras que en el balanceo, su función se centra más en la reducción del momento de inercia del miembro y el despeje del pie.

El complejo tobillo–pie es el encargado de gestionar la interacción directa con el suelo. Está formado principalmente por la articulación talocrural del tobillo, que conecta la tibia y el peroné con el astrágalo, y la articulación subastragalina, que une el astrágalo con el calcáneo. En conjunto permiten movimientos de flexoesxtensión, inversión-eversión y pronación-supinación. Para el estudio del movimiento es importante recalcar que el movimiento de flexoextensión encuentra su posición neutra cuando hay un ángulo de 90° con la tibia. Esto es relevante para no confundir la posición neutra de 0° con la posición plana de la planta del pie con el suelo, pues depende tanto del pie como del complejo tíbia-peroné. La disminución de este ángulo es denominada flexión dorsal y la flexión plantar sucede cuando dicho ángulo aumenta. Además, este movimiento no se produce en un plano sagital puro pues la articulación talocrural está orientada oblicuamente y, por ende, la dorsiflexión y la flexión plantar vienen acompañadas de pequeños movimientos de abducción–aducción e inversión–eversión. A través de la combinación coordinada de estos movimientos, el complejo tobillo-pie regula la progresión del apoyo desde el talón hasta el antepié, contribuyendo a la fase final de propulsión y facilitando una transición eficiente del peso corporal durante la marcha.

Aunque estas tres articulaciones sean las principales para el desplazamiento en el plano sagital, múltiples articulaciones adicionales participan en la marcha y contribuyen a estabilizar el movimiento. Entre ellas se incluyen las articulaciones del

pie, como las metatarsofalángicas, que permiten la extensión de los dedos durante el despegue y facilitan la rigidez del antepié en la propulsión, o las articulaciones del tarso, que ajustan de forma fina la adaptación del pie al terreno, entre otras. Destacan también la pelvis y la columna vertebral, que aseguran la transmisión de fuerzas entre los miembros inferiores y el tronco. En específico, la pelvis desempeña un papel esencial en la estabilidad y el equilibrio durante la marcha, actuando como punto de transmisión de fuerzas entre el tronco y los miembros inferiores. En el plano frontal, su comportamiento se analiza principalmente a través de la inclinación pélvica lateral, que describe la inclinación vertical de un hemipelvis respecto al otro a lo largo del ciclo. Este movimiento sirve para mantener el centro de masas dentro de una trayectoria estable y reducir las oscilaciones innecesarias. Valores positivos del ángulo de inclinación pélvica lateral indican que el hemipelvis del lado contralateral se eleva respecto al lado ipsilateral, lo que permite el despegue y el avance de la pierna contralateral durante el balanceo. Del mismo modo, valores negativos implican que el hemipelvis del lado contralateral desciende por debajo del nivel del lado ipsilateral, permitiendo la fase de balanceo del lado ipsilateral.

2.1.2. Fases del ciclo de la marcha

Para comprender el funcionamiento global de la marcha es esencial comprender la organización de los ciclos que la componen. Como se muestra en la Figura 2.1, el ciclo de la marcha humana se divide en dos fases principales, denominadas fase de apoyo y fase de balanceo. La fase de apoyo comprende aproximadamente el 60 % del ciclo y la fase de balanceo corresponde al 40 % restante. De forma aproximada, los ciclos de las dos piernas están desfasados aproximadamente un 50 %. Este desfase temporal entre ambas piernas es el que permite alternar los periodos de apoyo simple y doble, garantizando una progresión continua y estable del centro de masas. Cada una de las fases de apoyo incluye a su vez varias subfases que permiten describir con precisión la progresión del pie y la transferencia del peso corporal durante la locomoción.

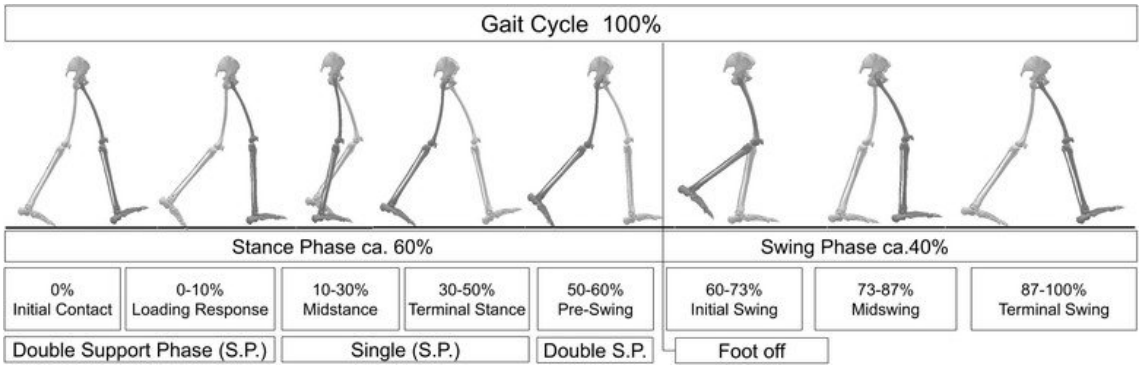


Figura 2.1: Clasificación del ciclo de la marcha humana. Imagen tomada de Haas et al. (2015) [1].

2.1.2.1 Fase de apoyo

La fase de apoyo es la etapa durante la cual el pie se encuentra en contacto con el suelo y sostiene el peso del cuerpo. Esta fase constituye aproximadamente el 60 % del ciclo de la marcha y su función principal es permitir la progresión del centro de masas, garantizar la estabilidad del cuerpo y preparar el miembro inferior para el inicio de la fase del balanceo donde despega el pie. Aunque se describe como un único bloque, la fase de apoyo se subdivide en cinco subfases, cada una diferenciada por los cambios funcionales que experimenta el miembro inferior durante el desplazamiento. Las cinco subfases, en orden cronológico, se denominan contacto inicial, respuesta a la carga, apoyo intermedio, apoyo final y prebalanceo. Observando la Figura 2.2, se podrá visualizar de forma esquemática estas subfases dentro de la fase de apoyo.

- **Contacto inicial (0-2 %)**
  El contacto inicial corresponde al instante en el que el talón realiza contacto con el suelo y marca el comienzo del ciclo de marcha. Durante este breve intervalo, el miembro inferior acaba de tocar el suelo y se realizan ajustes de alineación con el objetivo de posicionarse de forma correcta antes de iniciar la transferencia del peso corporal. Para prepararse, la rodilla se encuentra muy próxima a la extensión completa, menor a 5° de flexión. Al mismo tiempo, la cadera también se encuentra en una posición de flexión cercana a 20° o 30°, dado el avance del miembro durante la última parte de la fase de balanceo anterior. Esta flexión irá disminuyendo progresivamente durante la fase de apoyo a medida que el cuerpo avanza sobre el pie de contacto. Simultáneamente, el tobillo se encuentra en una posición neutra inicial que transiciona hacia una flexión plantar para recepcionar la carga. Es importante recalcar que este movimiento no se completará hasta la siguiente subfase de la respuesta a la carga. Aunque solamente dura un 2 % del ciclo, esta subfase posiciona al miembro correctamente para poder realizar una adecuada absorción del impacto en la respuesta a la carga.

- **Respuesta a la carga (2-10 %)**
  Durante la respuesta a la carga, el miembro inferior debe absorber el impacto inicial y prepararse para aceptar el peso corporal que antes sostenía el miembro contralateral. Esta subfase es muy compleja pues el sistema musculoesquelético debe gestionar sus componentes de forma simultánea para absorber las fuerzas de impacto, cambiar la distribución de pesos y ajustar la postura del sujeto para mantener un avance estable sin perder el equilibrio. La amortiguación del impacto se produce principalmente gracias a una ligera flexión de la rodilla, que pasa de extensión completa en el contacto inicial a una flexión de 10° a 15° durante esta etapa. Al mismo tiempo, tras la flexión plantar iniciada en la subfase anterior, el apoyo pasa de estar centralizado sobre el talón a un contacto total de la cara plantar del pie con el suelo. En este momento, el tobillo entra en un sistema cinemático cerrado en el que, debido al avance anterior de la tibia, comienza a experimentar una dorsiflexión progresiva. Esta subfase termina cuando el pie contralateral abandona el suelo, marcando el final del primer doble apoyo del ciclo y el inicio del soporte monopodal.

- **Apoyo intermedio (10-30 %)**
  El apoyo intermedio comienza cuando el pie contralateral despega del suelo, haciendo que el cuerpo entre en soporte monopodal. Esto significa que el cuerpo solo cuenta con un miembro inferior en contacto con el suelo que debe sostener la totalidad del peso corporal mientras permite el avance del centro de masas hasta situarse encima del pie de apoyo. Durante esta etapa, la tibia continúa su progresión anterior de forma controlada, lo que incrementa de forma progresiva la dorsiflexión del tobillo en cinemática cerrada. La rodilla, previamente flexionada para amortiguar el impacto, vuelve progresivamente a su posición extendida, con una flexión menor a 5° para optimizar la transmisión vertical de fuerzas, reduciendo el gasto energético durante el avance. En esta subfase, la pelvis, la cual durante las subfases anteriores se encontraba con una ligera caída en el lado contralateral, comienza la elevación de la hemipelvis contralateral de hasta 3°. Esta ligera elevación se debe principalmente a la activación de la musculatura abductora del miembro de apoyo, que genera un momento abductor capaz de contrarrestar la tendencia natural de la pelvis a caer hacia el miembro en fase de balanceo. En conjunto, el apoyo intermedio se trata de una subfase de equilibrio relativo en la que el sistema musculoesquelético del miembro inferior se adapta para aguantar el peso corporal mientras moviliza el centro de masas hasta situarse directamente sobre el pie de apoyo.

- **Apoyo final (30-50 %)**
  El apoyo final se inicia tras la alineación del centro de masas sobre el pie en apoyo y, en esta subfase, el peso corporal se transfiere progresivamente hacia la parte anterior del pie y el miembro se prepara para generar el impulso que dará inicio a la fase de prebalanceo. La tibia continúa avanzando sobre el tobillo, alcanzando los mayores valores de dorsiflexión del ciclo de hasta 10° aproximadamente. Con esta dorsiflexión y la planta del pie completa aún el contacto con el suelo, se comienza a estirar el complejo sóleo-gemelos y el tendón de Aquiles de forma controlada. La tensión acumulada en estos tejidos consigue almacenar energía elástica que se utilizará en el impulso final, contribuyendo a una mejor eficiencia energética en el paso. En el plano frontal, la pelvis inicia una disminución de la elevación contralateral alcanzada en el apoyo intermedio. Este descenso suave no constituye una caída del hemipelvis contralateral, sino una disminución de su elevación por consecuencia de la reducción del brazo de momento de la musculatura abductora por la progresiva pérdida de flexión de la cadera. Simultáneamente, en esta subfase también se inicia el mecanismo pasivo de *windlass* del pie, el cual, debido al desplazamiento del peso corporal hacia la parte anterior del pie, se obtiene una tensión en la fascia plantar que endurece el mediopié, convirtiendo el pie en una palanca rígida para el impulso. Por ello, el apoyo final se caracteriza por la preparación mecánica del miembro inferior para actuar como una palanca rígida mientras se acumula la energía necesaria en los tendones y músculos para el despegue del antepié.

- **Prebalanceo (50-60 %)**
  El prebalanceo es la transición entre la fase de apoyo y la fase de balanceo. Esta subfase corresponde al segundo periodo de doble apoyo del ciclo, pues comienza con el contacto inicial del miembro contralateral y finaliza cuando el pie en apoyo se eleva sobre el suelo, coincidiendo en tiempo con el fin de la

respuesta a la carga del miembro contralateral. Los objetivos de esta subfase se centran en transferir la carga del cuerpo al miembro recién apoyado y preparar el despegue del miembro de apoyo para iniciar el balanceo. Para conseguir la transferencia de carga, el miembro contralateral realiza los mismos ajustes explicados en las subfases de contacto inicial y prebalanceo. Entre estos ajustes, la pelvis se estabiliza en una inclinación lateral suave con la hemipelvis contralateral elevada por 2° aproximadamente. Al mismo tiempo, la cadera, que lleva disminuyendo su flexión desde el contacto inicial, alcanza su punto de mínima flexión de 0° o incluso 5° de extensión, preparándose para invertir el movimiento en la subfase siguiente. Del mismo modo, la rodilla comienza con sus primeros grados de flexión, en preparación para la rápida flexión en la siguiente subfase. Gracias a la pérdida progresiva de carga sobre el pie en salida, el tobillo invierte su dirección de movimiento y pasa de la dorsiflexión máxima a una potente flexión plantar que puede llegar a los 10°. Esta flexión plantar es la responsable del impulso final del antepié y del despegue de los dedos, también conocido como *toe-off*. Esta acción, combinada con la tensión acumulada previamente en los tejidos y el mecanismo de *windlass*, consigue iniciar el balanceo con un gasto energético mínimo. Con esta subfase de prebalanceo, que termina con el *toe-off*, se da por finalizada la fase de apoyo, el segundo apoyo doble y se da comienzo a la fase de balanceo del miembro.

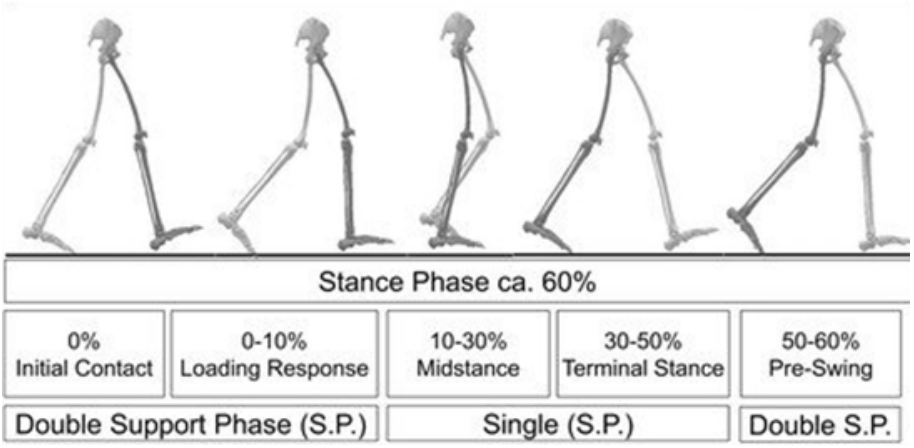


Figura 2.2: Subfases de la fase de apoyo (stance phase) de la marcha humana. Imagen recortada y adaptada de Haas et al. (2015) [1].

2.1.2.2 Fase de balanceo

Tras el (*toe-off*) se inicia la fase de balanceo donde el miembro inferior ya no está en contacto con el suelo y se avanza hasta el siguiente contacto inicial. Esta fase representa aproximadamente el 40 % del ciclo de la marcha y tiene como objetivos principales el desplazamiento seguro del miembro de salida, garantizando el despeje del pie respecto al suelo y permitiendo un avance fluido del centro de masas sin comprometer la estabilidad del cuerpo. Funcionalmente, la fase de balanceo se divide

en tres subfases, denominadas: balanceo inicial, balanceo medio y balanceo terminal. Observando la Figura 2.3, se podrá visualizar de forma esquemática estas subfases dentro de la fase de balanceo.

- **Balanceo inicial (60-73 %)**
  El balanceo inicial comienza inmediatamente después del *toe-off*, cuando el pie abandona completamente el suelo y el miembro inicia su desplazamiento hacia adelante. En este instante el objetivo principal es conseguir un despeje seguro del pie respecto al suelo. Para ello, la rodilla realiza una rápida flexión, alcanzando sus valores máximos de flexión del ciclo, cercanos a los 60° justo al final del balanceo inicial. Esta acción reduce el momento de inercia del miembro y permite elevar el pie sin interferir con el suelo durante el avance. De igual forma, la cadera también realiza una flexión de manera progresiva, iniciando el desplazamiento anterior del muslo. El desplazamiento del muslo hacia anterior es muy importante para impulsar el miembro hacia delante, permitiendo que la rodilla flexionada acompañe el movimiento sin aumentar el momento de inercia ni comprometer el despeje del pie. En cuanto al despeje del pie, en esta subfase el tobillo pasa de la flexión plantar responsable del impulso final del antepié hacia una posición neutra o ligeramente dorsal mediante una flexión dorsal rápida que garantiza el despeje del antepié de cualquier obstáculo en el suelo. Esta coordinación entre la rodilla, la cadera y el tobillo es esencial para liberar el pie del suelo con seguridad y colocarlo en una trayectoria ascendente eficiente. Mientras tanto, en el plano frontal, la pelvis inicia una elevación progresiva de la hemipelvis ipsilateral para evitar la caída del peso hacia la pierna en balanceo.

- **Balanceo medio (73-87 %)**
  La subfase de balanceo medio comienza cuando la pierna en balanceo alcanza su máxima flexión de rodilla y termina cuando la tibia se vuelve perpendicular al suelo. Una vez garantizada la rodilla, que en el balanceo inicial había alcanzado sus valores máximos de flexión en el ciclo, inicia ahora una extensión progresiva que reduce la flexión hasta valores aproximados de 25° a 30° para comenzar la alineación del balanceo final sin comprometer significativamente la elevación del pie. Al mismo tiempo, la cadera continúa aumentando su flexión hasta su máximo valor del ciclo alrededor de 20° a 30° de flexión. A través de esta flexión, se impulsa el avance del muslo y se acompaña al desplazamiento del centro de masas hacia adelante. En este instante, el miembro contralateral se encuentra terminando la subfase del apoyo intermedio y comenzando el apoyo final, por lo que, inicialmente, la acción de los músculos abductores del miembro en carga, por la pérdida de flexión de la cadera de ese miembro, continúa favoreciendo una ligera elevación de la hemipelvis ipsilateral de 1° a 3°. Posteriormente, conforme la cadera contralateral alcanza su máxima extensión, dicha elevación comienza a disminuir ligeramente. Mientras tanto, el tobillo, en posición neutra o ligera dorsiflexión tras el balanceo inicial, continúa con la dorsiflexión asociada a la posición del complejo tíbia-peroné. En esta subfase la colaboración de todas las articulaciones es muy importante pues el balanceo medio continúa hasta que el muslo se sitúa alineado bajo el tronco

gracias a la flexión de la cadera y la tibia alcanza la verticalidad gracias a la rodilla.

- **Balanceo terminal (87-100 %)**
  El balanceo terminal comienza cuando la tibia se vuelve perpendicular al suelo y finaliza en el instante en el que se hace contacto con el suelo. En esta subfase, se busca posicionar el miembro en preparación para un contacto estable y eficiente, ajustando la orientación de la cadera, la rodilla y el tobillo. La rodilla continúa su extensión progresiva desde la subfase anterior hasta obtener una flexión menor a 5°, lo que prepara la extremidad para absorber el impacto inicial que sufrirá el miembro al hacer contacto con el suelo, asegurando una correcta amortiguación sin bloquear la articulación. Al mismo tiempo, la cadera, que alcanzó sus últimos grados de flexión al final de la subfase anterior y a comienzos de esta, comienza a reducir la flexión suavemente, pasando de valores cercanos a los 40° en el balanceo medio a aproximadamente 25° a 30° de flexión en esta subfase. Esta reducción en la flexión sigue dejando la cadera en un rango que permite colocar el pie por delante del centro de masas en el momento del contacto. En cuanto al tobillo, este comienza a realizar una ligera flexión plantar hasta situarse en una posición neutra equivalente al ángulo de 90° con el complejo tíbia-peroné. Debido a la flexión de la cadera y la falta de flexión en la rodilla, el complejo tibia pernoé se sitúa angulado frente al suelo, por lo que una posición neutra del tobillo garantiza el apoyo del pie con el talón. En el plano frontal, la pelvis, preparando al cuerpo para la aceptación del peso en la siguiente fase, reduce gradualmente la elevación ipsilateral presente en las fases previas, pasando a valores cercanos a 2° de inclinación pélvica con la hemipelvis contralateral por debajo. El balanceo terminal finaliza cuando el talón del miembro en balanceo realiza el contacto inicial con el suelo, marcando el inicio de un nuevo ciclo de marcha.

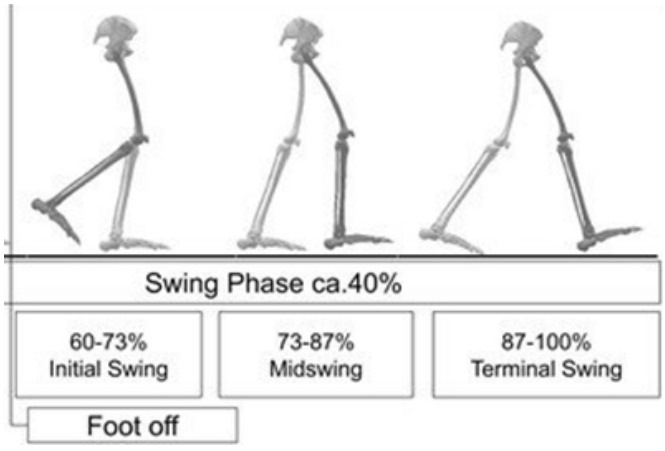


Figura 2.3: Subfases de la fase de balanceo (swing phase) de la marcha humana. Imagen recortada y adaptada de Haas et al. (2015) [1].

A pesar de describir ambas fases de forma diferenciada, durante la marcha normal ambas fases son parte de un ciclo continuo en el que los límites entre sus distintas

subfases son fluidos y dependientes de la coordinación entre las distintas articulaciones. En condiciones patológicas, esta coordinación puede verse alterada, dando lugar a fallos en el patrón del cíclo, causando pérdidas de estabilidad que pueden comprometer la capacidad de deambulación independiente [2, 3].

2.2. Contexto clínico y tecnológico de la rehabilitación de la marcha

El campo de la rehabilitación de la marcha se centra en restaurar las funciones locomotoras alteradas que han modificado el ciclo tradicional de la marcha. Para ello se emplean intervenciones terapéuticas convencionales e innovaciones tecnológicas orientadas a recuperar patrones de movimiento eficientes, seguros y lo más naturales posible. Cuando las alteraciones locomotoras tienen origen neurológico, esta intervención se clasifica dentro del campo de la neurorehabilitación. Esta disciplina está centrada en restaurar las funciones motoras, sensoriales y cognitivas afectadas por lesiones que suceden específicamente en el sistema nervioso. Es en este campo de la neurorehabilitación donde han comenzado a aparecer innovaciones tecnológicas centradas en el uso de exoesqueletos para asistir en la rehabilitación de la marcha. Estos avances se deben a la alta prevalencia de trastornos de la marcha en poblaciones con patologías neuromusculares tales como lesión cerebral traumática, lesión medular, ictus o parálisis cerebral. Los trastornos de la marcha afectan aproximadamente al 60 % de los pacientes atendidos en servicios de neurología hospitalaria, identificándose como uno de los síntomas más comunes en la neurología [4]. Además, estos trastornos afectan de más de una manera a los pacientes que los padecen, incluyendo, entre otros, atrofia muscular, pérdida ósea, alteraciones cardiovasculares y un mayor riesgo de aislamiento social. Es por ende que muchos pacientes con afectaciones en la marcha sienten una limitación considerable en su calidad de vida e independencia [5].

En Europa, las patologías neurológicas representan una de las principales causas de discapacidad a largo plazo. El Dr. Tedros Adhanom Ghebreyesus, director general de la OMS, comunicó en 2021 que la carga creciente de patologías neurológicas debería interpretarse como una llamada urgente a reforzar las intervenciones dirigidas a personas que las padecen para que puedan acceder a mejores servicios de tratamiento y pautas más eficientes de rehabilitación [6]. Aunque no todas las patologías neurológicas afectan al patrón de marcha, muchas de ellas sí generan déficits en los sistemas locomotores que pueden perjudicar gravemente la movilidad del paciente. Entre este grupo de patologías destaca el ictus, responsable de más de 1,1 millones de nuevos casos anuales en Europa [7]. A nivel global, se estima que aproximadamente el 80 % de los supervivientes de ictus presentan alteraciones de la marcha [8] y que alrededor del 25 % mantienen déficits que impiden la deambulación independiente al alta hospitalaria [9], tal como se muestra en la Figura 2.4. Debido al impacto de este tipo de alteraciones, resulta evidente la necesidad de aumentar la búsqueda de

estrategias enfocadas a una correcta rehabilitación de la movilidad.



Figura 2.4: Distribución de las alteraciones de la marcha en supervivientes de ictus. El anillo interior refleja la proporción global de pacientes con y sin alteraciones, mientras que el exterior desglosa el 80 % afectado según la gravedad [8, 9].

En las últimas décadas, con el auge en innovación en los campos de robótica e inteligencia artificial, el mundo de la neurorehabilitación se ha abierto a nuevas posibilidades para la rehabilitación de la movilidad tras lesiones neurológicas. En específico, y en rápido aumento, encontramos la rehabilitación robótica como complemento a la terapia convencional con fisioterapeutas. Aunque los primeros conceptos de órtesis robóticas se remontan a la década de 1960 con fines militares [10], fue a comienzos de los años 2000 cuando surgieron los primeros sistemas clínicos orientados a la rehabilitación [11]. La evolución de estos sistemas permitió pasar de dispositivos que se limitaban a asistir en el movimiento a equipos capaces de entrenar funciones motoras concretas [10]. En un contexto clínico, el uso de esta tecnología en la rehabilitación de la marcha se conoce como Entrenamiento de la Marcha Asistido por Robot o RAGT por sus siglas en inglés (Robot-Assisted Gait Training). Las prácticas de RAGT consisten en repetir muchas veces un patrón de marcha correcto de forma segura y controlada. Esta repetición promueve la neuroplasticidad, obtiene datos objetivos del progreso del paciente, aumenta la intensidad

del entrenamiento y reduce la carga física sobre el terapeuta [10, 12] .

Muchos estudios han demostrado la efectividad de estas prácticas en la recuperación funcional de la marcha en pacientes con lesiones neurológicas [13–15]. No obstante, la evidencia científica disponible no es unánime respecto a su superioridad frente a los programas de rehabilitación convencional. Algunos ensayos clínicos informan sobre mejoras significativas en la independencia para caminar, la simetría de la marcha o la fuerza muscular, mientras que otros encuentran resultados muy similares a los obtenidos mediante fisioterapia tradicional cuando la intensidad y la dosis de entrenamiento son similares [16, 17]. Esta diferencia en resultados viene dada, entre otros factores, por la dificultad de replicar movimientos humanos naturales y la falta de validación sistemática de los resultados. Pues, aún con el desarrollo tecnológico mencionado anteriormente, varios equipos bajo ciertos modos de control guiado presentan dificultades para lograr una participación muscular activa y patrones de movimiento naturales [18, 19].

2.3. Paso histórico por las tendencias en RAGT

Existen múltiples soluciones comerciales y prototipos para el entrenamiento de la marcha asistido por robot, cada una con características particulares que han ido variando con el tiempo. Es importante conocer la evolución del desarrollo de los exoesqueletos en el campo de la rehabilitación neuromotora, antes de adentrarnos en los principios de diseño y control que caracterizan el exoesqueleto con el que se ha trabajado.

Uno de los primeros prototipos funcionales que se desarrolló fue el Lokomat (Hocoma), mostrado en la imagen *a* en la Figura 2.5. Este dispositivo, introducido comercialmente en 2001, es considerado el primer exoesqueleto clínico moderno para rehabilitación [11]. Combina un sistema de suspensión corporal con dos órtesis motorizadas en la cadera y las rodillas. Todo ello fijado a una cinta de correr autopropulsada. Durante la terapia, un arnés suspende parcialmente el peso del paciente y los actuadores eléctricos guían sus piernas a lo largo de un patrón de marcha preprogramado. Este dispositivo permitía un entrenamiento repetitivo y controlado, permitiendo reducir el esfuerzo motor realizado por el fisioterapeuta aun manteniendo un entorno seguro [12]. El sistema, considerado el primer equipo RAGT, supuso un gran avance en la automatización en la rehabilitación de la marcha.

Sin embargo, el control de Lokomat era predominantemente rígido y predefinido, limitando considerablemente la participación activa del paciente en el movimiento [11]. A través del trabajo de investigadores en la Universidad de Twente en Países Bajos, se desarrolló el exoesqueleto LOPES (LOwer-extremity Powered ExoSkeleton), mostrado en la imagen *b* en la Figura 2.5. LOPES es un prototipo presentado en 2007 que solventaba la limitación de Lokomat introduciendo el concepto de

"*patient-in-charge*" y "robot-in-charge" en el que el robot podía seguir o guiar los movimientos del paciente según fuese necesario [20]. Este concepto, conocido actualmente como asistencia adaptativa (*assist-as-needed*), se basa en hacer que el robot solo intervenga cuando el paciente no logra completar adecuadamente el paso [21]. Específicamente, el nuevo equipo LOPES fue diseñado con un control de impedancia variable, que variaba la fuerza aplicada en función de la desviación del movimiento del paciente respecto al patrón deseado, aumentando la rigidez del patrón del robot a mayor desviación [20]. Frente al patrón de marcha guiado de Lokomat, con su nueva metodología, LOPES permitía una mayor participación activa del paciente, promoviendo un mayor aprendizaje motor [20]. Este nuevo paradigma se consolidó como una de las bases del diseño de los exoesqueletos RAGT modernos [19].

Posteriormente, el desarrollo se orientó hacia el control inteligente y la personalización de la asistencia. El exoesqueleto Hybrid Assistive Limb o HAL, desarrollado por Cyberdyne, mostrado en la imagen *c* en la Figura 2.5, fue de los primeros exoesqueletos de rehabilitación comercialmente disponibles para incorporar señales electromiográficas para detectar la intención motora del usuario antes de que el movimiento se produjese [22]. El equipo HAL contaba con una arquitectura híbrida de control, combinando el denominado *Cybernic Voluntary Control* (CVC), que modificaba la interacción del robot según las señales electromiográficas detectadas, con el *Cybernic Autonomous Control* (CAC), que seguía patrones automatizados. Si las señales de los músculos resultaban insuficientes, se activaba el sistema autónomo de manera proporcional [22]. Esta sincronización entre equipo y paciente permitió una iteración más fluida y una respuesta más natural, incluso en pacientes con problemas con la marcha gravemente afectada [23].

Acercándonos más al presente, en la última década la mayoría de los exoesqueletos RAGT se han centrado primordialmente en los movimientos de cadera y rodilla, mientras que el tobillo carecía de motorización activa. Esta elección se ha atribuido principalmente a los retos de diseño y control derivados de la complejidad biomecánica de la articulación [24]. Como se expuso en la sección de biomecánica de la marcha, el tobillo presenta múltiples grados de libertad asociados a movimientos de flexoextensión, inversión-eversión y pronación-supinación muy interrelacionados entre sí [2], lo que introduce dificultades en el diseño de actuadores y en el control. Actualmente, gracias al avance tecnológico de la última década, algunos estudios han demostrado sistemas capaces de controlar esta articulación, mostrando que la ausencia de asistencia activa en el tobillo puede limitar la naturalidad del patrón de marcha y reducir la eficacia del entrenamiento, dificultando su transferencia a la locomoción independiente [25, 26]. Estas limitaciones han impulsado el desarrollo de una nueva vertiente de sistemas RAGT centrados específicamente en la movilización activa del tobillo.

Al mismo tiempo, durante esta última década, ha aparecido otra vertiente distintiva en el desarrollo de exoesqueletos RAGT. Pues, en el campo de la rehabilitación, también han surgido dispositivos centrados en la portabilidad y la rehabilitación sobre suelo real. Aquí aparecen los primeros exoesqueletos móviles centrados en el

entrenamiento de la marcha como ReStore, de ReWalk Robotics, mostrado en la imagen *d* en la Figura 2.5. ReStore fue aprobado por la FDA (Administración de Alimentos y Medicamentos de Estados Unidos) en 2019 y es el primer exoesqueleto blando para la rehabilitación de la marcha posictus [27, 28]. ReStore es un exoesqueleto de tobillo que proporciona asistencia adaptativa de dorsiflexión y flexión plantar para mejorar el patrón de marcha incluso con velocidades más rápidas y distancias mayores. Para ello, combinan el uso de sensores inerciales y un algoritmo de temporalización que detecta las distintas fases de la marcha y modula la asistencia en tiempo real. A diferencia de los dispositivos anteriores, los equipos portátiles no presentan un sistema de soporte parcial de peso, pues están diseñados para usuarios con un mayor grado de ambulación propia. Siendo más concretos, según comunicados comerciales del fabricante, el usuario debe ser capaz de deambular con no más que una asistencia mínima a moderada [27], considerándose como asistencia mínima a moderada el uso de menos del 50 al 75 % del esfuerzo del paciente [29].

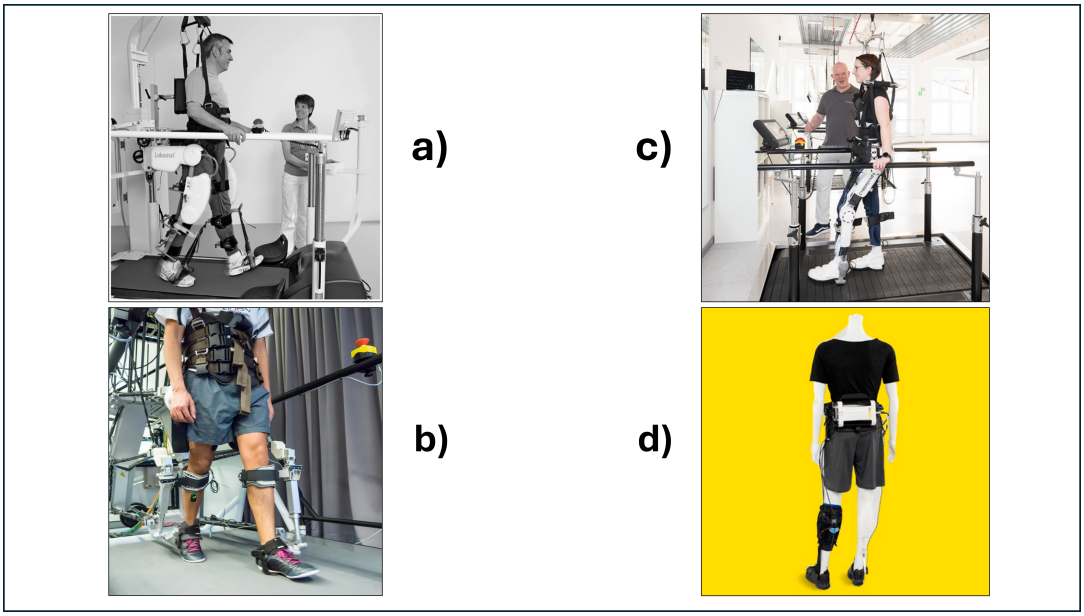


Figura 2.5: Comparativa de distintos exoesqueletos utilizados históricamente en el entrenamiento de la marcha asistido por robot (RAGT). La imagen incluye: (a) Lokomat, (b) LOPES, (c) HAL y (d) ReStore. Cada fotografía ha sido adaptada de sus fuentes originales, indicadas en [30–33].

2.4. Proyecto NIMBLE

Tras más de dos décadas desde la introducción del primer exoesqueleto de RAGT y el consiguiente desarrollo del campo, el proyecto NIMBLE surge como una respuesta a las limitaciones y oportunidades identificadas en este recorrido. NIMBLE es un proyecto de investigación de la Universidad Rey Juan Carlos, desarrollado por el grupo BeST (Grupo de Investigación de Alto Rendimiento en Tecnologías y Sistemas para la Bioingeniería). El sistema propone una estructura híbrida que com-

bina la seguridad y el soporte de peso de los sistemas estacionarios, la comunicación y adaptabilidad de asistencia centrada en el movimiento del tobillo de los nuevos enfoques *assist-as-needed* y la capacidad de entrenamiento sobre suelo real de los exoesqueletos portátiles de nueva generación. El robot NIMBLE, aún en desarrollo, puede representar la siguiente etapa en el entrenamiento de la marcha asistido por robot para pacientes con todo tipo de grados de afectación motora rehabilitable [34].

El objetivo principal del proyecto es proporcionar entrenamiento de la marcha ambulatoria con soporte parcial de peso fuera de la cinta rodante, en un entorno dinámico con la posibilidad de introducir objetos que permitan patrones de locomoción más naturales. Para cumplir este objetivo, el robot NIMBLE integra un conjunto de sistemas robóticos que trabajan de forma coordinada. Como se puede visualizar en la Figura 2.6, en la base del equipo se encuentra el bastidor móvil, encargado de seguir al usuario durante todo el entrenamiento. Anclado al bastidor, el sistema de soporte parcial de peso (PBWS) ayuda a descargar el peso del paciente de forma ajustable. El equipo cuenta también con un mecanismo pélvico de desplazamiento del centro de masas en el eje mediolateral y anteroposterior con el uso de cables accionados durante la marcha. Por último, cuenta con el Exo-H3, un exoesqueleto de miembro inferior que proporciona asistencia articular directa. La cooperación y comunicación de todos estos sistemas permiten guiar el movimiento de manera más natural, favoreciendo la transferencia de peso, la simetría de paso y el equilibrio dinámico sin necesidad de imponer una cinemática rígida [34].

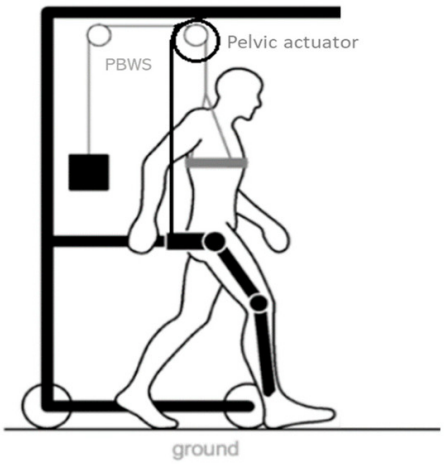


Figura 2.6: Diagrama del robot NIMBLE, que integra un bastidor móvil, un sistema de soporte parcial de peso (PBWS), un actuador pélvico por cables y el exoesqueleto de miembro inferior Exo-H3. Imagen adaptada de [34].

En cuanto a su arquitectura, el sistema emplea un control jerárquico basado en ROS 2, que sincroniza la participación de los distintos módulos y ajusta la asistencia motora según el rendimiento y el esfuerzo del paciente, promoviendo una rehabilitación participativa assist-as-needed. En las pruebas de validación presentadas, se evaluó la interacción entre estos módulos y su impacto sobre la cinemática natural de la marcha. Los resultados mostraron que las desviaciones angulares se mantuvieron

inferiores a 2° en los planos sagital y frontal, demostrando que el movimiento del bastidor no interfiere con el patrón del usuario [34]. De la misma manera, el sistema proporcionaba trayectorias de seguimiento del paciente con precisión, asistiendo en la locomoción de las extremidades inferiores y el desplazamiento de la pelvis.

Referente a la generación y seguimiento de las trayectorias, el sistema de NIMBLE utiliza un modelo que convierte objetivos relevantes en el espacio cartesiano del pie como la longitud del paso y altura de paso en la evolución temporal de los ángulos articulares. Para ello, se creó el sistema de progresión hacia adelante o *forward progression*, en el que se concatenan cadenas sucesivas en función del punto de contacto del pie con el suelo. Para determinar el movimiento del pie por el plano cartesiano, el sistema utiliza un modelo cinemático basado en Denavit-Hartenberg que incluye flexo-extensión de cadera, rodilla y tobillo, la abducción de la cadera y grados de libertad de la pelvis en los planos frontal, con inclinación lateral o *pelvis list*, y sagital, con anteversión y retroversión pélvica o *pelvis tilt* [35]. Para realizar esta tarea el sistema evalúa en cada instante del ciclo la configuración de ambas piernas, utilizando los ángulos de la pierna ipsilateral y de la contralateral para reconstruir las posiciones tridimensionales del tobillo, talón y antepié. A partir de estas trayectorias cartesianas, el sistema identifica el cruce entre pies, calculando directamente la longitud del paso, la altura de paso y el porcentaje de fase de oscilación.

Sobre esa base, se creó el sistema inverso. Este sistema calcula qué combinación de ángulos articulares es necesaria para producir una trayectoria del pie con longitud y altura específicas. Para ello, se utiliza un método de optimización llamado Invasive Weed Optimization (IWO). El algoritmo IWO genera una gran cantidad de posibles combinaciones y, pasándolo por el modelo cinemático directo, selecciona las que mejor cumplen los objetivos de longitud y altura establecidos [36]. El resultado son trayectorias articulares biomecánicamente válidas, aunque con un elevado coste computacional. Esto conlleva largos tiempos de espera y hace que el uso de este algoritmo sea poco práctico durante la terapia.

Para entender cómo se abordan actualmente estos cálculos y el paso por parte del proyecto NIMBLE hacia el uso de redes neuronales generativas, es necesario revisar primero las principales estrategias de generación de trayectorias empleadas en exoesqueletos de la marcha.

2.5. Cálculo de trayectorias para la marcha asistida

El cálculo de trayectorias articulares en exoesqueletos de marcha busca convertir metas clínicas como, en el caso de NIMBLE, la longitud y la altura de paso en secuencias de ángulos articulares biomecánicamente coherentes con las medidas es-

pecíficas del paciente. Para que estas trayectorias puedan aplicarse de forma segura, deben respetar los principios biomecánicos fundamentales del movimiento humano y garantizar una interacción estable entre el usuario y el dispositivo [37]. Lograr esta combinación de precisión y suavidad resulta esencial para preservar la comodidad del usuario, por lo que, para generarla, se recurre a algoritmos de cálculo de trayectorias capaces de generar movimientos estables, eficientes y fieles al comportamiento humano.

En el campo de la robótica, el uso de algoritmos evolutivos y otras técnicas metaheurísticas ha mostrado resultados prometedores en la resolución de problemas complejos de optimización, incluyendo la planificación del movimiento y el ajuste de parámetros de control en distintos tipos de robots [38]. Entre las técnicas más conocidas de algoritmos evolutivos se encuentran la optimización por enjambre de partículas (PSO), la evolución diferencial (DE), la búsqueda armónica (HS) y la ya mencionada Invasive Weed Optimization (IWO) utilizada por NIMBLE. Todas ellas están inspiradas en procesos naturales que durante varias iteraciones mejoran sus soluciones según una función de coste [39]. Dentro del campo de los exoesqueletos, estas técnicas se han aplicado para generar trayectorias de la marcha mediante algoritmos genéticos de forma exitosa [40] y ajustar en tiempo real a través de PSO los parámetros de control de un exoesqueleto de tobillo [41]. Estos trabajos recalcan en sus conclusiones que las metaheurísticas pueden trabajar correctamente con información biomecánica, siendo una herramienta útil para el cálculo y modificación de la trayectoria generada, mejorando el comportamiento del exoesqueleto y su interacción con el paciente.

La principal ventaja de estas técnicas evolutivas es su capacidad de adaptación. Pueden manejar funciones complejas, con múltiples criterios y sin necesidad de gradientes o relaciones lineales. Buscan, en paralelo, una gran cantidad de soluciones, aumentando la probabilidad de encontrar aquellas óptimas. Adicionalmente, modificando su función de coste, se pueden incorporar restricciones biomecánicas o cinemáticas, personalizando la técnica para la tarea específica [39]. Aunque no hay muchos trabajos que utilicen estas técnicas como algoritmo único en el campo de RAGT, su uso en exoesqueletos de la marcha en general evidencia su utilidad para crear patrones correctos de la marcha que pueden emplearse en RAGT [40]. Como ya se mencionó anteriormente, el Proyecto NIMBLE empleó la técnica IWO para calcular trayectorias articulares que cumpliesen metas de altura y longitud de paso. El resultado de este trabajo fue la obtención de trayectorias biomecánicamente válidas, pero, como pasa con la mayoría de algoritmos evolutivos, con un alto coste computacional [39].

Para resolver este problema, con las soluciones de referencia generadas con el IWO, NIMBLE ha alimentado una red neuronal generativa que aprende a imitar el comportamiento del algoritmo de optimización. Esto reduce los elevados costes computacionales y temporales asociados a la técnica anterior. Para entrenar la red, se generó un conjunto de datos mediante el algoritmo IWO, permitiendo que la red aprendiese a generar nuevas trayectorias articulares correspondientes a distintas

longitudes y alturas de paso. La red además tiene en cuenta la antropometría del usuario, siendo capaz de generar trayectorias personalizadas en apenas milisegundos. Este nuevo enfoque permite adaptar la asistencia del robot en tiempo real sin comprometer la naturalidad del movimiento [36].

2.6. Inteligencia artificial en el control de exoesqueletos

Es evidente que la inteligencia artificial (IA) ha adquirido un papel fundamental en la robótica moderna, incluyendo el campo de la rehabilitación. La aplicación de sistemas basados en redes neuronales permite que los exoesqueletos de asistencia pasen de comportamientos preprogramados a sistemas personalizables y adaptativos. En este ámbito, las redes neuronales se utilizan para estimar la intención a partir de sensores electromiográficos (EMG), inerciales (IMU) o de presión plantar. Simultáneamente, pueden detectar fases de la marcha y generar trayectorias articulares que no solo son compatibles con las metas clínicas determinadas, sino que además, pueden ajustar la asistencia en tiempo real cuando se integran con controladores adaptativos [42].

El tipo de red o algoritmo se selecciona según la tarea a realizar. Dentro de las redes neuronales, encontramos varios algoritmos clásicos y algunos emergentes en el ámbito:

- **Feed-forward Networks o Perceptrones Multicapa (MLP):** Los MLP son capaces de aprender mapeos directos de una entrada a una salida concreta. Por ejemplo, pueden mapear parámetros de la marcha con los correspondientes ángulos articulares del exoesqueleto. Su uso suele limitarse a cuando la relación entre las variables y la salida es estática o se puede representar mediante una correspondencia directa. Las mayores ventajas de este tipo de red son que su entrenamiento suele ser más rápido y estable que en otros modelos más complejos. Pero su capacidad de encontrar patrones directos depende fuertemente de la calidad de los datos. Adicionalmente, no dispone de memoria temporal, lo que limita su aplicación en tareas donde la salida depende de secuencias previas, como ocurre en el ciclo de la marcha [43]. No obstante, algunos profesionales como el proyecto NIMBLE utilizan este tipo de redes para generar trayectorias articulares según condiciones clínicas del paso, debido a su rapidez y estabilidad en el entrenamiento, permitiendo su uso en tiempo real.

- **Redes Recurrentes (RNN):** Esta arquitectura está diseñada para procesar secuencias temporales. Dentro de las RNN hay dos principales variantes, las LSTM (Long Short-Term Memory) y las GRU (Gated Recurrent Unit). Estas

variantes permiten mantener información sobre estados pasados, evitando la pérdida de contexto que suelen tener las RNN convencionales [44]. En el contexto de los exoesqueletos de rehabilitación, este tipo de redes muestra una gran precisión en la detección de fases de la marcha y en la predicción de trayectorias articulares, pero su entrenamiento tiene un mayor coste computacional y precisa de grandes volúmenes de datos para lograr una convergencia estable [45].

- **Aprendizaje por Refuerzo (Reinforcement Learning, RL):** A diferencia de los anteriores, en lugar de aprender una correspondencia directa entre entrada y salida, el aprendizaje por refuerzo busca una política óptima que maximice una recompensa. En el ámbito de los exoesqueletos, se ha utilizado para ajustar en tiempo real el torque o la rigidez de los motores en función del esfuerzo del usuario. Su principal ventaja reside en que no necesita datos de entrenamiento supervisados, sino que aprende por interacción. En consecuencia, precisa de largos tiempos de entrenamiento. En la literatura, estos enfoques se usan principalmente en entornos simulados o con usuarios sanos y su aplicación clínica aún está en fase experimental [46] .

Un denominador común en todos los enfoques es la dependencia crítica de los datos para realizar el entrenamiento de los modelos. Para entrenar redes robustas hacen falta datos con mucha variabilidad, en el caso de NIMBLE esto significaría diferentes metas de paso, velocidades y medidas antropométricas del usuario. Sin embargo, en el ámbito de la neurorehabilitación la obtención de datos de calidad presenta importantes limitaciones. La mayoría de bases de datos disponibles como The OU-ISIR Gait Database [47] están construidas a partir de sujetos sanos, realizando pasos estándar, que no reflejan adecuadamente la cinemática necesaria para el proceso de rehabilitación de pacientes con deficiencias de la marcha. Luego, en el campo de la marcha, mucha literatura recoge sus datos con pasos realizados sobre citas de correr. El patrón de marcha sobre este tipo de equipos no refleja patrones similares a los obtenidos en terreno libre [48]. Adicionalmente, la obtención de datos de la marcha se ve incluso más dificultada cuando se considera la inconsistencia en la obtención y tratamiento de los datos y en la falta de accesibilidad a ellos de forma pública [49].

Ante esta situación, cada vez es más común el uso de estrategias alternativas para ampliar la cantidad de datos. Entre ellas, destaca la creación de algoritmos o simuladores que, a costa de grandes necesidades computacionales, son capaces de recrear o simular los datos originales, con los que, a través de métodos como modelos subrogados, donde se entrena una red neuronal con los resultados de un algoritmo original, se consigue imitar su proceso [50]. Como se explicó anteriormente, la alternativa que tomó NIMBLE fue esta, utilizando un modelo computacionalmente denso basado en algoritmos evolutivos para generar varias señales de referencia para alimentar una red neuronal generativa basada en MLP, consiguiendo que aprendiese del proceso. Esta iniciativa presenta un principal problema mencionado anteriormente y es que supone un gran coste computacional y temporal. Es por ello que ha crecido el uso de redes generativas antagónicas (GAN) [51]. Estas redes son capaces de aprender

la distribución subyacente de los datos reales y generar nuevas muestras sintéticas que conservan la biomecánica natural del movimiento del paciente [52, 53]. Así, a partir de un conjunto menor de datos de pacientes con trastornos de la marcha, es posible generar datos sintéticos que sigan su biomecánica específica, ofreciendo una solución prometedora para la falta de datos de entrada de los modelos de predicción y planificación del movimiento [53].

2.7. Redes Generativas Antagónicas

Las redes generativas antagónicas o GAN (Generative Adversarial Networks) son modelos generativos que aprenden una distribución de datos mediante el entrenamiento de dos redes neuronales en un juego de suma cero. La primera, la red Generador (G), transforma un vector de ruido en muestras sintéticas con el objetivo de aproximarlo a la distribución real de los datos. La segunda, la red Discriminador (D), intenta distinguir si la muestra que recibe de entrada proviene del conjunto de datos reales o ha sido generada por G [54].

El entrenamiento ideal se alcanza cuando ambas redes llegan a un equilibrio de Nash. El equilibrio de Nash es un problema de teoría de juegos que ocurre cuando ningún jugador puede mejorar su resultado de forma unilateral, sino que solo podrá mejorar si alguno de los otros empeora [55]. En el caso de los GAN, D aprende a detectar muestras falsas, mientras que G aprende a engañar a D generando datos cada vez más realistas. Esto continúa hasta que se llega a un equilibrio de Nash, donde G genera datos tan reales que D no es capaz de distinguir si es real o no mejor que el azar. La función original propuesta se define de la siguiente manera [54]:

$$\min_G \max_D \; V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}\big[\log D(x)\big] + \mathbb{E}_{z\sim p_z}\big[\log\big(1 - D(G(z))\big)\big].$$

donde: $p_{\text{data}}(x)$ y $p_z(z)$ son la distribución real de los datos y del ruido latente que se introduce en el generador, respectivamente. Siendo $G(z)$ la función del generador que transforma el ruido z en una muestra sintética y $D(x)$ la salida del discriminador, que indica la probabilidad de que una muestra x sea real.

Es decir, D trata de maximizar la función y para ello busca que D(x) sea cercano a 1, que ocurre cuando consigue detectar cuáles son las muestras reales, y que D(G(z)) sea 0, detectando las muestras falsas. A su vez, G busca justo lo contrario, tratando de minimizar la función engañando a D para que clasifique sus muestras sintéticas como reales. Originalmente, este proceso se definó como una minimización de la divergencia de Jensen–Shannon (JSD) entre la distribución de los datos reales y la distribución de los datos generados [54]. La JSD es una medida estadística que cuantifica la diferencia entre dos distribuciones de probabilidad [56]. En este contexto, indica cómo de indistinguibles se vuelven las muestras sintéticas respecto a las

reales. Es decir, cuando la JSD tiende a cero, el generador ha aprendido a replicar tan bien la distribución real que el discriminador ya no es capaz de distinguirla mejor que el azar [54].

No obstante, la aproximación original con JSD resulta inadecuada en escenarios donde los datos reales son complejos. En estos casos, la distribución de los reales y los generados presentan poco solapamiento, de modo que D discrimina perfectamente los datos reales de los generados, haciendo que la JSD alcance su valor máximo y se estanque. Este estancamiento hace que se vuelva insensible a los cambios, pues, como el gradiente que recibe G es muy cercano a cero, este no obtiene información para mejorar [57]. Debido a estas limitaciones, con el objetivo de mejorar la estabilidad durante el entrenamiento, han aparecido otras variantes que solucionan este problema.

La principal solución que emergió para abordar este problema es la Wasserstein GAN (WGAN). La WGAN reformula la función de pérdida sustituyendo la divergencia de Jensen–Shannon por la distancia de Wasserstein o Earth Mover's Distance. Esta métrica mide el coste mínimo necesario para transformar una distribución en otra. Se la conoce como Earth mover's distance porque se puede entender como si se moviese "tierra" de una distribución a otra para igualarlas [58]. Este cambio aporta una función de coste más informativa que sirve incluso cuando la distribución de los datos reales apenas se solapa con la de los sintéticos. En la práctica, el objetivo de una WGAN ya no es que el discriminador identifique entre real y falso, sino que mida cómo de diferentes son las dos distribuciones. Su formulación propuesta se define de la siguiente manera [58]:

$$W\big(p_{\text{data}},\, p_G\big) = \inf_{\gamma \in \Pi(p_{\text{data}},\, p_G)} \mathbb{E}_{(x,y)\sim\gamma}\big[\|x - y\|\big],$$

donde $\Pi(p_{\text{data}}, p_G)$ representa el conjunto de todas las posibles formas de emparejar o transportar puntos de una distribución a la otra, y $\|x - y\|$ es el coste de trasladar esos puntos desde x hasta y.

Es decir, se busca el menor valor posible para transformar puntos de la distribución de datos reales en puntos de datos generados. No obstante, calcular directamente la ínfima sobre γ es imposible en la práctica y por ello se utiliza la forma dual, conocida como la dualidad de Kantorovich–Rubinstein, que permite expresar la distancia de Wasserstein de la siguiente manera [58]:

$$W(p_{\text{data}}, p_G) = \sup_{f \in \mathcal{L}_1} \mathbb{E}_{x\sim p_{\text{data}}}[f(x)] - \mathbb{E}_{x\sim p_G}[f(x)],$$

donde, en lugar de buscar planes de transporte entre dos distribuciones, se busca una función f que sea capaz de diferenciar perfectamente entre ambas distribuciones.

Esta función f es lo que el discriminador, ahora llamado crítico (C), va aprendiendo a aproximar durante el entrenamiento del WGAN. De forma práctica, esto significa que el C deja de ser una red que categoriza las señales en dos grupos, real y falso, como hace el discriminador en una GAN convencional, sino que, en lugar de devolver una probabilidad, C devuelve un valor real que representa la puntuación de cómo de real es la muestra. Durante el entrenamiento, el crítico aprende a aproximar la función f que maximiza la diferencia entre las distribuciones reales y generadas. El crítico va ganando cuando consigue aumentar esa diferencia, mientras que el generador trata de aprender para que sus señales obtengan una mejor puntuación, disminuyendo la diferencia [58].

Es importante resaltar que, para evitar que el entrenamiento se vuelva inestable, haciendo que sus gradientes se vuelvan demasiado grandes y el *loss* crezca sin parar, la función f a la que se aproxima debe ser 1-Lipschitz, es decir, su salida no puede variar más de lo que varía su entrada [58]:

$$|f(x_1) - f(x_2)| \leq \|x_1 - x_2\|.$$

Para cumplir esta restricción, las primeras versiones de WGAN empleaban un método llamado *weight clipping*. Este método consistía en limitar los pesos del crítico a un pequeño rango, aplastando pesos que se salían del rango a sus límites predefinidos [58]. Esto se hacía porque si los pesos son muy pequeños, el crítico no puede reaccionar con tanta fuerza, limitando la salida y cumpliendo la condición de 1-Lipschitz. No obstante, con esta técnica el modelo perdía su capacidad para aprender funciones complejas, generando gradientes pobres e inestabilizando el entrenamiento [59]. Para solucionar este problema, se propuso el método de penalización de gradiente, conocido como Gradient Penalty (WGAN-GP) [59]. En esta variante, en lugar de recortar los pesos, se añade a la función de pérdida del crítico un término adicional que lo penaliza cuando el valor de su gradiente se aleja de 1. De esta forma se consigue que el modelo cumpla la condición 1-Lipschitz sin restringir su expresividad, alcanzando un aprendizaje más suave y consistente, especialmente en tareas con señales continuas como las de la marcha.

A pesar de que la formulación Wasserstein mejora notablemente la estabilidad del entrenamiento, las WGAN convencionales siguen presentando una limitación importante. Esto se debe a que para una gran cantidad de contextos, es necesario un control exhaustivo sobre el tipo de muestras generadas. Con un GAN no condicionado, el modelo aprende a aproximar la distribución global de los datos, pero no permite especificar las características de las muestras que deseamos generar. Esta falta de control puede causar que el modelo genere señales que no sean coherentes con las medidas que se tenían en mente sobre todo en señales complejas [60]. En el campo de la creación de trayectorias, el uso de modelos GAN no condicionados, aun pudiendo crear señales que son realistas, pueden resultar biomecánicamente incoherentes con las métricas clínicas deseadas.

Para solventar este problema, se propusieron las redes generativas antagónicas condicionadas o cGAN (conditional GAN) [61]. La arquitectura cGAN introduce variables de condición (y), como longitud, altura de paso o medidas antropométricas

como en el caso del proyecto NIMBLE, que actúan como guías durante la generación de nuevos datos . Con las variables de condición se consigue añadir información adicional a las muestras y realizar peticiones de muestras generadas con los parámetros específicos que se deseen [62]. En esta arquitectura, el generador, en lugar de fabricar datos únicamente a partir de ruido aleatorio, recibe también las propiedades deseadas para las muestras. Lo mismo pasa con el crítico, que recibe la señal generada o real y las condiciones asociadas, evaluando tanto si la muestra es real como si corresponde con las condiciones proporcionadas [62]. Adicionalmente, al generar señales sintéticas se pueden modificar las condiciones de entrada, obteniendo secuencias para características concretas.

En el entorno biomédico, las cGAN se han utilizado para generar señales clínicas con condiciones explícitas, mejorando el rendimiento de modelos supervisados. Su uso se observa en campos que van desde la creación de datos sintéticos de señales de electrocardiografía (ECG) [63] hasta la recreación de señales de actividad electrodérmica en episodios de estrés [64]. En el ámbito específico de la marcha, se desarrolló un modelo cGAN capaz de generar patrones sintéticos de marcha que replican la distribución de *datasets* utilizados en el control de una prótesis transfemoral. Una vez entrenado, se puede condicionar el modelo con distintas fases de la marcha y velocidades para generar tanto ángulos articulares como fuerzas de reacción vertical. Se demostró que el uso de los datos sintéticos generados mejoró el entrenamiento de modelos destinados al control de la prótesis, reduciendo la dependencia de grandes bases de datos reales y aumentando la robustez de la prótesis ante variabilidad intersujeto [65].

Capítulo 3

Solución técnica

Para cumplir el objetivo de este trabajo se deberá diseñar y entrenar una red generativa antagónica condicionada capaz de transformar objetivos de longitud y altura de paso, junto con la antropometría del usuario, en secuencias angulares de un conjunto de articulaciones específicas.

3.1. Datos de entrenamiento y preprocesado

Los datos que se emplean para el entrenamiento, y que el modelo tratará de replicar, se han obtenido del proyecto NIMBLE. En este estudio, las trayectorias originales se registraron a partir de ensayos experimentales con sujetos sanos. Durante los ensayos, los participantes caminaron realizando pasos con diferentes longitudes, alturas y velocidades, mientras su movimiento era capturado mediante un sistema de análisis de marcha *Vicon* compuesto por diez cámaras ópticas. A partir de las posiciones de los marcadores, el software *Vicon Nexus* reconstruyó las trayectorias articulares de la pelvis, la cadera, la rodilla y el tobillo [34]. Posteriormente, como se explicó anteriormente, el proyecto NIMBLE desarrolló un modelo cinemático directo basado en el método de Denavit–Hartenberg. El modelo transforma las trayectorias articulares $Y(t, j)$ en posiciones cartesianas del pie y de la pelvis y, a partir de ellas, calcula de forma automática la longitud (L) y la altura (H) del paso. En este trabajo se seleccionan la flexión de cadera, rodilla y tobillo, y la inclinación lateral de la pelvis no solo porque son los algunos de los grados de libertad utilizados por el modelo, permitiendo la obtención de las condiciones clínicas relacionadas con la trayectoria, sino porque son precisamente los grados de libertad actuados en el exoesqueleto de rehabilitación NIMBLE, lo que garantiza la compatibilidad directa entre las trayectorias generadas y el sistema robótico al que van destinadas.

Para la creación de la base de datos de entrenamiento se recorren todos los sujetos y condiciones disponibles, extrayendo las trayectorias articulares de ambas piernas junto con las medidas antropométricas correspondientes. A diferencia del modelo desarrollado en el proyecto NIMBLE, cuyo entrenamiento se basó exclusivamente en datos de la pierna izquierda y en condiciones de marcha lenta, en este trabajo se utiliza un conjunto de datos más amplio. Esto se debe a que la arquitectura seleccionada, basada en unidades recurrentes GRU, requiere un mayor volumen de información temporal para garantizar la estabilidad del entrenamiento, en contraste con las redes MLP empleadas en NIMBLE.

Para extraer las trayectorias angulares, primero cada paso se normaliza detectando de manera automática el instante de apoyo inicial a partir de los marcadores del pie, de forma que todas las secuencias comienzan y terminan en eventos equivalentes dentro del ciclo de marcha. Las trayectorias articulares de ambas piernas son idénticas entre sí excepto con la inclinación lateral de la pelvis. Esta última describe un único movimiento en el plano frontal que refleja cómo la pelvis se inclina hacia el lado de la pierna de apoyo o hacia el lado contrario. Debido a que el sistema de referencia de *Vicon* cambia de orientación según la pierna analizada, el mismo gesto de inclinación pélvica aparece con signos opuestos si el paso es derecho o izquierdo. Para unificar la base de datos y poder tratar todos los pasos como si correspondieran al mismo lado, las trayectorias del lado izquierdo se transforman en su equivalente contralateral invirtiendo el signo de la inclinación pélvica. De esta manera, una inclinación hacia la pierna ipsilateral se representa siempre con el mismo signo, independientemente de cuál fuera la pierna original del ensayo, y las muestras pueden mezclarse sin inconsistencias de referencia.

Una vez obtenidas las trayectorias articulares normalizadas, se aplica un filtrado fisiológico sobre las metas del paso, conservándose únicamente aquellos ciclos cuyos valores se encuentran dentro de rangos considerados plausibles en el contexto terapéutico del proyecto NIMBLE. Esta selección no pretende abarcar todo el repertorio posible de la marcha, sino centrarse en el tipo de pasos que se utilizarían en rehabilitación. Es decir, pasos relativamente lentos, de longitud moderada y con una altura de paso contenida. Esta elección resulta especialmente relevante en pacientes con ictus, que a menudo tienden a arrastrar el pie durante la fase de oscilación y para los que se priorizan patrones seguros. Concretamente, se descartan aquellos ciclos con longitudes de paso superiores a 0.80 m o con alturas del pie fuera del rango comprendido entre 0.05 m y 0.45 m, conservando así únicamente trayectorias compatibles con los escenarios de terapia previstos en NIMBLE [35]. Además, se eliminan también aquellos ciclos en los que la reconstrucción cinemática presenta errores numéricos o inconsistencias geométricas. Este filtrado garantiza que la base de datos final esté compuesta por ciclos de marcha biomecánicamente coherentes para ser utilizados en el entrenamiento del modelo generativo.

Tras este preprocesado, el resultado es una base de datos reestructurada, consistente con el modelo cinemático de NIMBLE y preparada para el entrenamiento del cGAN, organizada como $(X_{\text{cond}}, Y_{\text{seq}}, S_{\text{meas}})$, donde:

- $X_{\text{cond}} = [L, H]$ son las condiciones clínicas del paso en metros.
- $Y_{\text{seq}} \in \mathbb{R}^{T \times J}$ representa las secuencias en grados de los ángulos de las articulaciones.
- $S_{\text{meas}} \in \mathbb{R}^{M}$ contiene las medidas antropométricas (en metros) del sujeto: altura, longitud del fémur, longitud de la tibia, longitud total de la pierna, ancho de la pelvis y ancho de la rodilla.

siendo N el número total de muestras, T el número de instantes por ciclo, J el número de articulaciones y M el número de medidas antropométricas consideradas.

3.2. Arquitectura: Generador y Crítico

La arquitectura propuesta está compuesta por el generador (G) y su contrincante, el crítico (C). Las dos piezas conforman el núcleo adversarial del modelo realizando un aprendizaje eficaz, capaz de producir trayectorias articulares coherentes. A lo largo del entrenamiento, ambos se optimizan de manera opuesta. Mientras que el generador busca maximizar el valor de realismo que establece el crítico a sus secuencias, este trata de mejorar su capacidad de distinguir entre datos reales y sintéticos, ampliando la diferencia entre las puntuaciones medias de las muestras reales y las generadas, estimando así la distancia Wasserstein entre ambas distribuciones.

3.2.1. Generador (G)

El generador (G) es el encargado de transformar las condiciones de entrada en secuencias angulares posibles. Su objetivo es aprender una correspondencia entre las metas de longitud y altura de paso, las características antropométricas del sujeto y las trayectorias articulares de forma que pueda crear nuevas señales que respeten la biomecánica natural de la marcha.

Las condiciones de entrada del generador se componen de la longitud de paso L, la altura de paso H, el vector de medidas antropométricas del sujeto S y un vector de ruido z . Antes de combinarse con el ruido, las condiciones se procesan mediante una pequeña red neuronal de tipo MLP que las proyecta al espacio latente del modelo. Este paso permite transformar las variables originales en una representación de mayor dimensión que captura combinaciones lineales, cuadráticas, cúbicas y relaciones no lineales de todo tipo. Alimentar al generador con esta representación facilita que el modelo descubra patrones ocultos que no serían detectables usando directamente las condiciones originales. Posteriormente las condiciones se concatenan con el ruido, el cual se modela como un proceso autorregresivo de primer orden (AR1). El proceso AR1 genera ruido para cada instante que no varía mucho del ins-

tante anterior, introduciendo variabilidad a la señal pero sin cambios bruscos entre pasos temporales, garantizando que la señal mantenga su suavidad y continuidad característica.

El bloque central del generador está compuesto por dos capas recurrentes GRU. Como se mencionó anteriormente, las GRU permiten mantener memoria temporal y capturar las dependencias secuenciales a lo largo del ciclo de la marcha. La primera GRU recibe directamente las entradas de ruido y condiciones, aprendiendo patrones locales del paso asociados a cambios entre instantes de tiempo consecutivos. La segunda capa recibe la salida de la primera, una representación ya resumida de la marcha. De esta forma, mientras la primera aprende los cambios más locales, la segunda procesa los datos de forma global, representando la coordinación completa del paso. Adicionalmente, se añaden las denominadas "cabezas por articulación". En este trabajo, las cabezas están implementadas como pequeñas redes MLP independientes para cada articulación. Su función es transformar la representación conjunta proveniente de las GRU en las señales angulares de cada articulación por separado, permitiendo que estas conserven su propia dinámica dentro del contexto común del paso.

3.2.2. Crítico (C)

El crítico (C) tiene la función de evaluar las trayectorias generadas por el modelo G según su plausibilidad de ser reales. A diferencia de los discriminadores en las GAN tradicionales, cuyo funcionamiento se limita a clasificar las señales como reales o sintéticas, se utiliza el principio de la Wasserstein GAN (WGAN). Como se mencionó anteriormente, este enfoque estima un valor que mide la distancia entre la distribución real y la generada.

El modelo recibe como entrada la trayectoria Y, que puede ser real o generada, y las condiciones clínicas de altura, longitud y medidas de la persona. Esta información pasa por una capa recurrente bidireccional (Bi-GRU), que analiza la secuencia en ambas direcciones temporales. La capa Bi-GRU está formada por dos capas GRU: una analiza la señal de pasado a futuro, mientras que la otra la analiza en sentido contrario. De esta manera, el crítico es capaz de evaluar la coherencia temporal completa del movimiento, comprendiendo las dependencias de cada articulación tanto del pasado como del futuro. Cuando la Bi-GRU procesa una secuencia, genera un vector de activación por cada instante de tiempo. Este vector de activación es el estado interno de la red, es decir, lo que el modelo considera importante para distinguir si la marcha analizada es real o sintética. Tras la lectura de la secuencia completa, se genera un vector de activación global del promedio de los vectores de activación temporales. Este vector global resume la dinámica completa del paso y pasa a través de una pequeña red MLP que genera un valor escalar de plausibilidad, cuantificando como de realista es la secuencia evaluada.

Además de su uso para calcular el vector promedio, los vectores de activación locales proporcionan información adicional al modelo. A través del mecanismo de *feature matching*, el generador es penalizado si las secuencias que genera no proporcionan vectores de activación similares a los obtenidos en las secuencias reales. De esta manera, no solo se discrimina entre real y sintético por el paso completo, sino también según la similitud de las *features* o activaciones que el modelo considera relevantes.

No obstante, debido a la complejidad y variabilidad de las secuencias a generar, los dos modelos por sí solos no serían suficientes para garantizar la coherencia biomecánica completa de las trayectorias. Por ello, se incorporan términos de pérdida adicionales que actúan como restricciones y penalizaciones sobre el generador, reforzando la estabilidad del entrenamiento y asegurando una mejor coherencia entre las condiciones clínicas y las trayectorias resultantes.

3.3. Funciones de pérdida

Para favorecer el correcto entrenamiento del modelo se definen funciones de pérdida específicas tanto para el crítico como para el generador. Además, se establecen algunos términos de regularización que garantizan una mayor estabilidad en el aprendizaje.

El entrenamiento del modelo se basa en un esquema adversarial entre el generador y el crítico, inspirado en la formulación de la Wasserstein GAN con penalización de gradiente (WGAN-GP). Como se explicó anteriormente, con este enfoque, el crítico no clasifica las secuencias en grupos de secuencias reales o sintéticas como hacía el discriminador en las GAN convencionales, sino que estima una distancia de Wasserstein entre la distribución de las trayectorias reales y las generadas. El objetivo final es minimizar esta distancia, de modo que el generador consiga engañar al crítico hasta el punto de que la distancia entre ambas distribuciones sea nula o lo menor posible.

La función de pérdida del crítico se define como:

$$\mathcal{L}_C = -\mathbb{E}\big[D(Y_{\text{real}})\big] + \mathbb{E}\big[D(Y_{\text{fake}})\big] + \lambda_{\text{GP}}\,\mathbb{E}\Big[\big(\|\nabla_{\hat{Y}} D(\hat{Y})\|_2 - 1\big)^2\Big], \tag{3.1}$$

donde $D(Y)$ representa la salida del crítico para una secuencia Y, y el último término corresponde al *gradient penalty*, que fuerza a C a cumplir la condición 1-Lipschitz, mejorando la estabilidad del entrenamiento.

La función de pérdida del generador combina múltiples componentes que actúan

de manera complementaria:

$$\mathcal{L}_G = \underbrace{\alpha_{\text{adv}}\,\mathcal{L}_{\text{adv}}}_{\text{adversarial}} + \underbrace{\alpha_{\text{fm}}\,\mathcal{L}_{\text{FM}}}_{\text{feature matching}} + \underbrace{\alpha_{\text{bio}}\,\mathcal{L}_{\text{bio}}}_{\text{suavidad y coherencia}} + \underbrace{\alpha_{\text{cons}}\,\mathcal{L}_{\text{cons}}}_{\text{consistencia de metas}} . \tag{3.2}$$

Los distintos términos representan:

- **Pérdida adversarial** ($\mathcal{L}_{\text{adv}}$): Este término incentiva al generador a producir trayectorias que el crítico perciba como reales dentro de la métrica de Wasserstein. En la práctica, el generador es penalizado cuando el crítico distingue correctamente entre datos reales y sintéticos y es recompensado cuando sus muestras resultan indistinguibles. De esta forma, el generador aprende a maximizar la valoración del crítico, mejorando progresivamente el realismo de las secuencias generadas.
- ***Feature matching*** ($\mathcal{L}_{\text{FM}}$): Como se explicó anteriormente, el *feature matching* incentiva al generador a producir salidas cuyas activaciones intermedias sean similares a las de las muestras reales al ser analizadas por el crítico. Así, se asegura de que la estructura temporal y las correlaciones interarticulares sean consistentes con las de las trayectorias reales.
- **Pérdidas biomecánicas** ($\mathcal{L}_{\text{bio}}$): Este término está formado por un conjunto de penalizaciones que buscan garantizar que las curvas generadas sean fisiológicamente coherentes y plausibles. En concreto, se incluyen cuatro términos:
  - *Suavidad:* penaliza las diferencias cuadráticas entre instantes consecutivos $(y_{t+1} - y_t)^2$, evitando así transiciones bruscas en los ángulos.
  - *Curvatura:* penaliza la segunda derivada discreta $(y_{t+2} - 2y_{t+1} + y_t)^2$, fomentando curvas más regulares y realistas.
  - *Jerk:* penaliza la tercera derivada discreta, controlando las variaciones rápidas de aceleración y mejorando la naturalidad del movimiento.
  - *Cierre de ciclo:* penaliza la discrepancia entre el estado articular del primer y del último instante del ciclo $(y_T - y_1)^2$, forzando que las trayectorias sean periódicas y estén correctamente cerradas.
- **Pérdida de consistencia** ($\mathcal{L}_{\text{cons}}$): Dado que nos interesa que las señales generadas cuenten con coherencia biomecánica según las condiciones clínicas de entrada, se añadió una pérdida que penaliza al generador cuando las señales generadas no respetan dicha coherencia. Para ello, se hace uso de un predictor auxiliar (P). El predictor auxiliar es una red MLP que recibe como entrada la secuencia angular generada Y_{fake} y las medidas antropométricas del sujeto S. Durante su entrenamiento, la red incorpora un bloque de *convoluciones unidimensionales* (*Conv1D*) que permiten extraer descriptores locales del movimiento, representando de forma más eficiente la evolución de los ángulos articulares. De esta forma, al combinar las características extraídas por las convoluciones con el vector de medidas S, la red es capaz de generar una estimación de las metas clínicas del paso, es decir, la longitud y la altura de

paso $(\hat{L}, \hat{H})$. Finalmente, estas estimaciones se comparan con las condiciones clínicas originales establecidas para la generación de la secuencia, penalizando al generador en función de la diferencia entre ambas.

Los coeficientes α controlan el peso relativo de cada término de pérdida. Para su selección se tomaron como referencia configuraciones ampliamente aceptadas en la literatura de modelos generativos. En particular, el valor del *gradient penalty* ($\lambda_{\text{GP}} = 10$) se adoptó directamente de la formulación WGAN-GP [59], donde se establece como valor estándar para garantizar la condición 1-Lipschitz y estabilizar el entrenamiento adversarial. La relación entre la pérdida adversarial y los términos adicionales se ajustó siguiendo las prácticas comunes en modelos GAN aplicados a series temporales y señales biomédicas, tal y como recogen distintos trabajos y guías recientes [60, 63, 68].

3.4. Protocolo de entrenamiento

Una vez comprendidas las partes del modelo y sus funciones de pérdida, es importante conocer el protocolo concreto del entrenamiento. Primero, los datos originales obtenidos del proyecto NIMBLE se dividen en entrenamiento (90 %) y validación (10 %). Además, se normalizan las condiciones clínicas, las medidas antropométricas y las trayectorias angulares utilizando su media y desviación típica. Esta estandarización permite que todas las variables operen en escalas comparables, evitando que magnitudes grandes dominen el gradiente y mejorando la estabilidad del entrenamiento.

El procedimiento de entrenamiento elegido adopta una configuración coherente con las prácticas recomendadas en la literatura [66–68] para garantizar la estabilidad del proceso adversarial y una relación adecuada entre el crítico y el generador. En particular, se utilizó una estrategia en la que el crítico se actualiza tres veces por cada iteración del generador. Este enfoque es habitual en los modelos de tipo WGAN, ya que permite que el crítico mantenga un aprendizaje más sólido y estable.

El entrenamiento en sí se lleva a cabo empleando *batches* de 64 muestras tomadas del conjunto de datos de entrenamiento. El generador trata de recrear las muestras reales del *batch* utilizando sus condiciones de altura, longitud y medidas antropométricas en el espacio latente como entrada. Tras esto, el crítico recibe ambos tipos de señales y asigna valores de plausibilidad mayores a las señales reales y menores a las señales sintéticas. Con estas valoraciones, se calcula la pérdida del crítico, que mide la diferencia entre ambos grupos, y se actualizan los pesos del crítico para mejorar su capacidad de discriminación. A su vez, con las secuencias reales, se entrena el predictor auxiliar (P), que aprende a estimar con mayor precisión la longitud y la altura de paso. Finalmente, se actualiza el generador tratando de con-

seguir que el crítico asigne valores más altos a sus muestras y reducir la penalización impuesta por las pérdidas adicionales de *feature matching*, biomecánica y coherencia de condiciones. Tras el procesamiento de cada *batch*, los pesos de las redes se actualizan según los gradientes obtenidos, de modo que el modelo va refinando su aprendizaje progresivamente a lo largo de las épocas.

Cuando se utilizan todos los datos de entrenamiento disponibles, se procede con la validación. En esta fase, se calcula el error cuadrático medio (MSE) entre las trayectorias generadas y las trayectorias reales del conjunto de validación. Este valor determina cómo de fieles son las trayectorias generadas respecto a las reales. Para evitar el sobreajuste, se implementa un criterio de parada temprana que detiene el entrenamiento si han pasado varias épocas sin mejora en el error de validación. Además, se almacenan puntos de control (*checkpoints*) del mejor modelo según la pérdida de validación, conservando los pesos de G, C y el predictor P para futuras evaluaciones y creación de datos. Además, estos puntos de control permiten conservar versiones intermedias del modelo y evaluar su comportamiento a medida que se va entrenando.

Para muestrear la información contenida en estos *checkpoints* se ha creado un módulo de muestreo que permite generar trayectorias articulares bajo condiciones específicas de longitud, altura de paso y antropometría del usuario. Este módulo carga el generador entrenado y toma las condiciones clínicas y antropométricas del conjunto de datos real y las usa para recrear sus trayectorias asociadas. De esta forma, obtenemos un archivo de datos sintéticos, ordenados igual que los originales, permitiéndonos realizar comparaciones entre las secuencias reales y sintéticas para evaluar el modelo.

3.5. Herramientas utilizadas

Una vez conocida la solución técnica de este proyecto, es importante conocer las herramientas utilizadas para hacerlo realidad. Todos los documentos originados para la creación de la solución técnica expuesta se encuentran subidos a un repositorio de github encontrado en el siguiente vínculo (Código TFG).

3.5.1. Python

Python ha sido el entorno principal para la construcción del modelo generativo adversarial, así como para el análisis de la distribución de las secuencias. Se ha elegido este lenguaje debido a su uso extendido a lo largo del grado de Ingeniería Biomédica. Al mismo tiempo, Python cuenta con una comunidad muy activa y

accesible en el ámbito de las redes generativas, ofreciendo repositorios y guías de referencia [66–68] que han permitido adaptar y ajustar la arquitectura del modelo hasta alcanzar la solución deseada. Para la solución técnica creada se han utilizado las siguientes librerías:

- **PyTorch**: Pytorch es un framework de aprendizaje profundo, que está diseñado para crear y entrenar redes neuronales como el generador, el discriminador y el predictor auxiliar de este modelo. Además de usarse para la construcción de toda la lógica del entrenamiento adversario, PyTorch permite usar la GPU para trabajar con tensores, lo que permitió acelerar significativamente el tiempo de entrenamiento necesario. También cuenta con herramientas para la mejora de la estabilización del entrenamiento, la inicialización de los pesos evitando saturaciones y explosiones en los gradientes.

- **NumPy**: NumPy es conocida por ser una de las librerías más esenciales para la computación científica en Python. Proporciona soporte para crear vectores y matrices multidimensionales de gran tamaño, presentando varios comandos y operaciones matemáticas para su manipulación. Se ha usado para preparar y transformar los datos, calcular estadísticas, realizar normalizaciones y gestionar matrices antes de integrarlas en PyTorch.

- **h5py**: h5py permite leer y escribir archivos en formato `HDF5`. Esta librería es necesaria pues HDF5 es el formato en el que MATLAB guarda los ficheros `.mat`. Se utiliza para abrir en Python los archivos generados en MATLAB y guardar los datos sintéticos de forma que puedan ser analizados fácilmente desde MATLAB.

- **matplotlib**: matplotlib se utiliza para la generación de gráficos en Python. En específico, se ha usado para el análisis de distribución, permitiendo generar figuras para evaluar la calidad de las secuencias generadas.

- **argparse**: argparse es una herramienta muy recomendada en la creación de interfaces para *scripts* de Python. Permite modificar parámetros del *script* sin cambiar el código fuente ni recordar manualmente la posición de cada argumento en las funciones. Su uso ha sido empleado en la generación de datos sintéticos y en la comparación de datos usados.

- **scipy y math**: Tanto scipy como math son colecciones de funciones matemáticas avanzadas. Se han usado para operaciones específicas como la generación de ruido autoregresivo AR(1), en los cálculos de las pérdidas de suavidad, curvatura, jerk, correlaciones y otras métricas estadísticas para la evaluación del modelo.

3.5.2. MATLAB

Además del uso de Python, para el preprocesado de los datos y el análisis cinemático se ha trabajado con el framework de MATLAB. Se ha optado por el uso de esta herramienta debido a su uso en la creación del modelo cinemático directo del proyecto NIMBLE. Como ya se ha mencionado anteriormente, para la obtención de la solución técnica planteada, el proyecto ha empleado las herramientas proporcionadas por el entorno de trabajo de NIMBLE en MATLAB. Estas funciones permiten transformar ángulos articulares en trayectorias cartesianas del pie y la pelvis, así como extraer las principales características clínicas de la marcha. En este trabajo se han utilizado específicamente las siguientes funciones:

- `executeKinematicModel`: función central del modelo cinemático directo de NIMBLE. A partir de las señales articulares de cadera, rodilla, tobillo y pelvis, calcula la posición tridimensional de los principales puntos anatómicos del miembro inferior. Este modelo utiliza una cadena cinemática basada en parámetros de Denavit–Hartenberg y un sistema de *forward progression* que actualiza el punto de contacto del pie en función del ciclo de marcha.
- `gaitFeatureExtraction`: a partir de las trayectorias cartesianas generadas por el modelo cinemático, esta función calcula las métricas clínicas principales del paso: longitud, altura, porcentaje de oscilación y los eventos temporales característicos. Estas métricas son fundamentales para construir las etiquetas de entrenamiento del GAN y para evaluar la consistencia biomecánica de sus resultados.

Estas funciones han permitido generar el *dataset* procesado utilizado en el entrenamiento del modelo generativo, así como implementar el proceso de validación clínica descrito en la sección anterior.

3.5.3. Datos NIMBLE

Resulta evidente recalcar también el uso de los datos obtenidos a través del sistema de captura de movimiento Vicon del proyecto NIMBLE. Sin el acceso a estas señales no habría sido posible entrenar el modelo ni realizar su validación. Los datos cuentan con muestras de sujetos distintos que presentan un conjunto de medidas antropométricas particulares. A su vez, cada sujeto presenta una serie de distintos ensayos que se organizan por nivel de velocidad, nivel de longitud del paso y nivel de altura del paso, disponiendo por cada uno las series temporales de ángulos articulares y las trayectorias tridimensionales de los marcadores en el sistema de coordenadas global. Extrayendo los datos y procesándolos a través del modelo cinemático directo, obtenemos nuestro *dataset* procesado, listo para el entrenamiento del GAN.

Capítulo 4

Evaluación y resultados

Una vez entrenado el modelo generativo, el siguiente paso consiste en comprobar si realmente ha aprendido a reproducir la marcha humana y si es capaz de generar trayectorias articulares coherentes bajo distintas condiciones clínicas. Esta etapa no solo sirve para verificar que el modelo funciona, sino también para entender cómo se comporta cuando se enfrenta tanto a los datos con los que aprendió como a nuevas condiciones que no había visto antes. El análisis combina observaciones estadísticas y biomecánicas, permitiendo valorar simultáneamente la fidelidad con la distribución original y la coherencia cinemática tras reconstruir el movimiento en el espacio cartesiano.

Para esta tarea se ha planteado un proceso de evaluación dividido en dos fases complementarias. La primera fase, denominada análisis de distribución, evalúa si las secuencias generadas por la red siguen la misma distribución estadística que las del conjunto real. La segunda fase, el análisis biomecánico, evalúa las secuencias según su coherencia biomecánica y la consistencia cinemática entre las condiciones de entrada (L, H) y la secuencia generada.

Adicionalmente, para evaluar correctamente el rendimiento del modelo se emplearon dos conjuntos de datos diferenciados, destinados a primero validar el funcionamiento de la GAN y posteriormente a probar su capacidad para operar con datos nuevos. Ambos conjuntos se evaluarán con los análisis descritos antes y se comparará su resultado para poder determinar la capacidad del modelo para cumplir con el objetivo establecido.

- **Conjunto de entrenamiento**: El primer conjunto de datos será aquel formado por los ciclos utilizados durante la fase adversarial. Además de servir para el aprendizaje del modelo, este conjunto permite realizar una primera evaluación diagnóstica cuyo objetivo es comprobar que el generador resultante tras el entrenamiento adversario ha aprendido correctamente la distribución

original de las trayectorias articulares y la variabilidad presente en los datos reales.

- **Conjunto de validación**: Este conjunto de datos está compuesto por ciclos de marcha no utilizados durante el entrenamiento ni incluidos en el 10 % reservado para la validación interna del GAN. Este conjunto contiene ensayos diferentes a los vistos por la red recogidos por el proyecto NIMBLE y reservados para su uso en la evaluación funcional del GAN. Este conjunto de datos permite evaluar si el generador es capaz de generalizar correctamente su funcionamiento cuando se enfrenta a condiciones no presentes durante el aprendizaje.

4.1. Análisis de distribución

El análisis de distribución tiene como objetivo comprobar si las secuencias sintéticas generadas por el modelo comparten estadística similar a las trayectorias reales del conjunto de entrenamiento.

Para ello, se emplea un módulo de comparación que evalúa la capacidad del generador para reproducir la forma global, la variabilidad y las relaciones internas del movimiento. Siendo $Y^{\text{real}} \in \mathbb{R}^{N_r \times T \times J}$ el conjunto de trayectorias reales y $Y^{\text{syn}} \in \mathbb{R}^{N_s \times T \times J}$ el conjunto de trayectorias sintéticas generadas por el modelo con las mismas condiciones de entrada que Y^{real}, donde N es el número de ciclos, T el número de instantes temporales por ciclo y J el número de articulaciones por secuencia, el módulo procesa estos conjuntos y obtiene tres perspectivas distintas para asistir en el proceso de comparación. Las tres perspectivas nos van a permitir valorar la forma individual de las secuencias de cada articulación, su relación con otras y la variabilidad global del movimiento generado. De esta manera podemos determinar si las secuencias generadas pueden considerarse estadísticamente realistas, permitiéndonos comparar diferentes configuraciones del generador a la hora de seleccionar los pesos de entrenamiento más adecuados.

4.1.1. Análisis de las curvas promedio

En primer lugar, se analiza la capacidad del modelo para reproducir la forma media de las trayectorias articulares. Para cada articulación j y para cada instante del ciclo t, se calcula la media y la desviación estándar a partir de todas las repeticiones disponibles. Estas curvas permiten visualizar la evolución temporal media de cada articulación por separado, así como la dispersión típica en torno a dicha media. Esta representación ofrece una primera impresión cualitativa sobre el grado en que las señales sintéticas siguen la misma distribución que las reales. Para cuantificar de forma objetiva la similitud entre ambas se emplean el error cuadrático medio

(RMSE) entre las curvas promedio y la correlación de Pearson.

La Figura 4.1 muestra las curvas promedio para el conjunto de entrenamiento y la Figura 4.2 recoge los resultados análogos en el conjunto de validación.

Se puede observar que en el conjunto de entrenamiento (Figura 4.1) las curvas sintéticas siguen muy de cerca la trayectoria media de las señales reales para las cuatro articulaciones, con bandas de dispersión de anchura similar en todas excepto cadera, pero con correlaciones prácticamente perfectas en cadera, rodilla y pelvis. El tobillo presenta ya un comportamiento algo más delicado, con el RMSE absoluto más bajo pero el mayor error relativo debido a su rango angular reducido.

En el conjunto de validación (Figura 4.2) se mantiene en términos generales la forma global de las trayectorias, pero aparecen varias discrepancias individuales en cada articulación:

- **Cadera (Hip_flex):** La evolución temporal de la flexoextensión sigue siendo muy similar entre datos reales y sintéticos, y la correlación se mantiene alta ($r \approx 0{,}996$). Sin embargo, el RMSE aumenta de 2,573° en entrenamiento a 3,831° en validación. Visualmente, la curva sintética tiende a infraestimar ligeramente la flexión durante buena parte del ciclo, especialmente en la zona de máxima extensión alrededor del 60 % del ciclo. Esto se debe principalmente a la forma media del generador con los datos de entrenamiento, donde se mantiene en valores de flexión menores a la media de su distribución, tendiendo a generar trayectorias más atenuadas. No obstante, el grado de diferencia es reducido y con una forma temporal muy similar al conjunto real.
- **Rodilla (Knee_flex):** La rodilla sigue siendo la articulación mejor reproducida. Las curvas sintéticas capturan con precisión los puntos de inflexión y la amplitud de la flexión máxima, con correlaciones muy altas tanto en entrenamiento ($r \approx 0{,}997$) como en validación ($r \approx 0{,}996$). El RMSE incluso disminuye ligeramente en validación (de 2,525° a 2,110°), lo que sugiere que, pese a pequeñas diferencias locales, la dinámica media de la rodilla se generaliza de forma robusta. No obstante, también se ha de recalcar particularidades que aparecen en tanto los datos sintéticos como los datos reales ya presentes en los datos reales como son la ausencia de la pequeña flexión inicial responsable de gran parte de la absorción de carga y la presencia de picos de flexión en oscilación algo superiores a los valores típicos de una marcha más lenta. Ambas de las particularidades pueden verse explicadas por la presencia de ciclos de marcha de mayor velocidad que la norma, causando la ausencia de la flexión de rodilla inicial y picos de flexión principal mayores.
- **Tobillo (Ankle_flex):** En los datos sintéticos, el tobillo es la articulación donde la degradación en el conjunto de validación resulta más evidente. Mientras que en entrenamiento la media sintética se ajusta razonablemente a la real (RMSE 0,927°, $r \approx 0{,}985$), en validación el RMSE casi se duplica (1,708°) y la

correlación desciende de forma clara ($r \approx 0{,}909$). La curva sintética muestra un desplazamiento sistemático respecto a la real, con mayor flexión plantar al inicio del ciclo y diferencias apreciables en la región del pico de flexión plantar y en el valle posterior. Además, las bandas de dispersión no se solapan tan bien como en entrenamiento. El modelo tiende a producir una variabilidad más concentrada que no cubre completamente el rango observado en los datos reales. Todo ello indica que el tobillo es la articulación donde el modelo generaliza peor la forma media y la variabilidad de la señal.

- **Inclinación pélvica (Pelvis_List):** La pelvis mantiene un ajuste razonablemente bueno, pero con una degradación perceptible respecto al entrenamiento. El RMSE pasa de 0,281° a 0,568° y la correlación se reduce de $r \approx 0{,}996$ a $r \approx 0{,}976$. Las curvas sintéticas y reales conservan la misma estructura global con una elevación contralateral durante el apoyo intermedio y un descenso asociado a la transferencia de carga, pero la señal sintética tiende a infraestimar ligeramente la amplitud del movimiento y presenta una dispersión más estrecha. De nuevo, el modelo reproduce el patrón medio, pero subestima parte de la variabilidad presente en los sujetos reales.

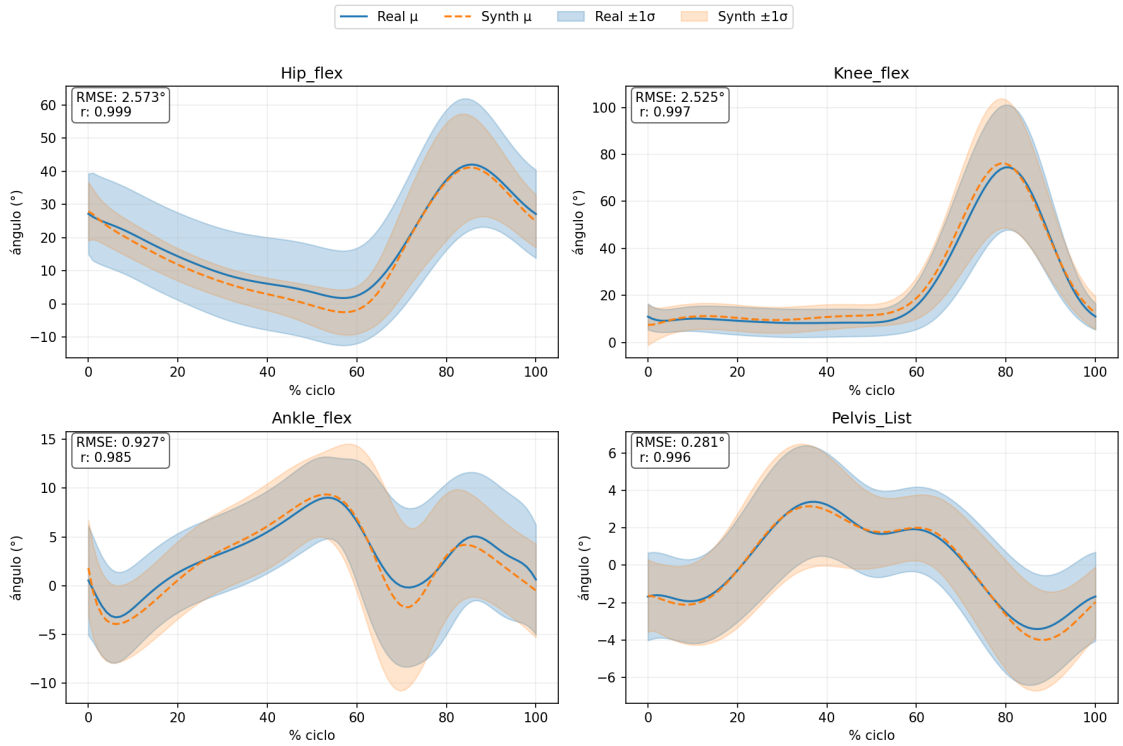


Figura 4.1: Comparación entre las curvas promedio reales y sintéticas para las cuatro articulaciones analizadas (cadera, rodilla, tobillo e inclinación pélvica) en el conjunto de entrenamiento. La línea continua representa la media de las señales reales y la línea discontinua la media de las señales generadas por el modelo, mientras que las bandas sombreadas muestran la dispersión típica ($\pm 1\sigma$) en cada conjunto.

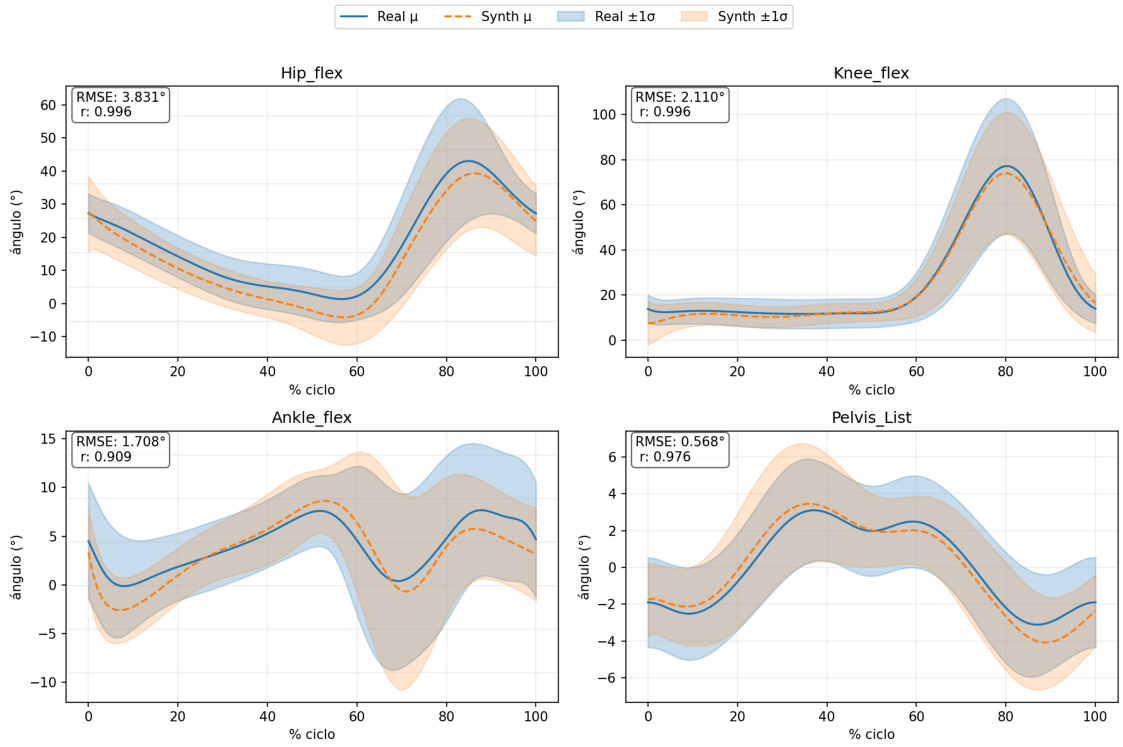


Figura 4.2: Comparación entre las curvas promedio reales y sintéticas para las cuatro articulaciones analizadas (cadera, rodilla, tobillo e inclinación pélvica) en el conjunto de validación. La línea continua representa la media de las señales reales y la línea discontinua la media de las señales generadas por el modelo, mientras que las bandas sombreadas muestran la dispersión típica ($\pm 1\sigma$) en cada conjunto.

Desde el punto de vista cuantitativo, las Tablas 4.1 y 4.2 resumen el comportamiento del modelo en el conjunto de entrenamiento y en el conjunto de validación. En entrenamiento, las tres articulaciones proximales presentan errores absolutos moderados y correlaciones muy elevadas. La cadera y la pelvis muestran porcentajes de RMSE en torno al 6.39 % y 4.12 %, mientras que la rodilla alcanza el valor relativo más bajo, 3.81 %, a pesar de ser la articulación con mayor rango de movimiento. El tobillo, en cambio, concentra el mayor RMSE relativo, 7.55 %, a partir de un RMSE absoluto muy pequeño, lo que se explica por su rango angular reducido, de solo 12.274 grados.

Al pasar al conjunto de validación se mantiene esta jerarquía, aunque con una degradación clara en términos de error relativo. La rodilla sigue siendo la articulación mejor reproducida, con un RMSE absoluto similar, un porcentaje de error que permanece bajo, 3.21 %, y una correlación prácticamente perfecta. La cadera y la pelvis conservan correlaciones altas, pero el RMSE relativo se incrementa hasta valores cercanos al 9–10 %, reflejando la ligera infraestimación de amplitud observada en las curvas promedio. El tobillo vuelve a ser la articulación más problemática, con un RMSE absoluto que casi se duplica y un porcentaje de error que se dispara hasta el 19.52 %, junto con la correlación más baja de todas. En conjunto, las

tablas muestran que el modelo generaliza bien la dinámica de las articulaciones proximales, mientras que la representación del tobillo resulta mucho más sensible a la variabilidad intersujeto y a las diferencias de fase.

Ángulo	**Rango (°)**	**RMSE (°)**	**%RMSE**	r
Hip_flex	40.237	2.573	6.39 %	0.999
Knee_flex	66.202	2.525	3.81 %	0.997
Ankle_flex	12.274	0.927	7.55 %	0.985
Pelvis_List	6.818	0.281	4.12 %	0.996

Tabla 4.1: Curvas promedio reales y sintéticas en el conjunto de entrenamiento. Se muestra el rango angular de la curva media real (A_j), el error cuadrático medio entre curvas promedio (RMSE_j), su versión relativa normalizada respecto al rango ($\mathrm{RMSE}_j^{\mathrm{rel}}$) y la correlación de Pearson (r_j).

Ángulo	**Rango (°)**	**RMSE (°)**	**%RMSE**	r
Hip_flex	40.255	3.831	9.52 %	0.996
Knee_flex	65.650	2.110	3.21 %	0.996
Ankle_flex	8.750	1.708	19.52 %	0.909
Pelvis_List	6.219	0.568	9.13 %	0.976

Tabla 4.2: Curvas promedio reales y sintéticas en el conjunto de validación. Se indica el rango angular de la curva media real, el RMSE absoluto entre las curvas promedio, el RMSE relativo normalizado por el rango y la correlación de Pearson para cada articulación.

En conjunto, el análisis de las curvas promedio muestra que el modelo ha aprendido de forma sólida la organización global de la marcha. En el conjunto de entrenamiento las trayectorias sintéticas reproducen con gran fidelidad tanto la forma media como la variabilidad de las articulaciones proximales, y esta estructura se mantiene en el conjunto de validación con una degradación moderada de las métricas. La rodilla es la articulación mejor capturada, con errores relativos bajos y correlaciones casi perfectas, lo que sugiere que el modelo representa de manera robusta la dinámica principal del ciclo. La cadera y la pelvis conservan también un ajuste razonablemente bueno, aunque con una ligera infraestimación de amplitud y un incremento del RMSE relativo. El tobillo se confirma como el punto más frágil del generador, con una caída clara de la correlación y un aumento muy marcado del RMSE relativo, consecuencia de su rango reducido y de la alta sensibilidad a pequeñas desalineaciones temporales. Estos resultados indican que, desde una perspectiva estadística, las trayectorias sintéticas son coherentes con la marcha registrada, pero también ponen de relieve que las conclusiones extraídas a partir de las articulaciones distales deben interpretarse con mayor cautela en los análisis biomecánicos posteriores.

4.1.2. Acoplamiento interarticular

Además de evaluar cada articulación de forma individual, es necesario analizar si el modelo reproduce la coordinación natural entre las articulaciones del miembro inferior. En la marcha, la dinámica no depende solo de la evolución temporal de cada ángulo por separado, sino de la interacción continua entre ellos, de modo que una generación realista debe preservar también estas relaciones. Para estudiar este aspecto se calcula, tanto en los datos reales como en los sintéticos, una matriz de acoplamiento interarticular que recoge la correlación media entre pares de articulaciones en cada conjunto. Para dos articulaciones j_a y j_b, el acoplamiento medio se define como

$$C^{\text{real}}_{j_a,j_b} = \frac{1}{N_r}\sum_{n=1}^{N_r} \operatorname{corr}\big(Y^{\text{real}}_{n,:,j_a},\, Y^{\text{real}}_{n,:,j_b}\big), \qquad C^{\text{syn}}_{j_a,j_b} = \frac{1}{N_s}\sum_{n=1}^{N_s} \operatorname{corr}\big(Y^{\text{syn}}_{n,:,j_a},\, Y^{\text{syn}}_{n,:,j_b}\big),$$

donde $Y_{n,:,j}$ representa la señal temporal de la articulación j en la secuencia n. A partir de estas matrices se obtiene una matriz de diferencias

$$\Delta C = C^{\text{syn}} - C^{\text{real}},$$

que indica cuánto se desvía el acoplamiento sintético respecto al real en cada par articular. Valores cercanos a cero reflejan que el modelo conserva correctamente la coordinación natural de la marcha, mientras que desviaciones mayores señalan correlaciones artificiales amplificadas o atenuadas.

Las Figuras 4.3 y 4.4 muestran las matrices de correlación obtenidas a partir de los datos reales de entrenamiento y validación. En ambos conjuntos aparece un patrón muy consistente. La cadera y la rodilla presentan una correlación positiva moderada, con valores de r próximos a 0,59, lo que refleja que ambas articulaciones tienden a cambiar de sentido en momentos similares del ciclo, con extensión progresiva durante el apoyo y nueva flexión en el prebalanceo y el balanceo inicial. La cadera se relaciona de forma opuesta con la pelvis, con una correlación claramente negativa cercana a $-0{,}79$, de modo que las posiciones más extendidas de cadera coinciden con una elevación contralateral de la pelvis y la vuelta hacia la flexión se acompaña de una pérdida de esa elevación. La rodilla mantiene también una correlación negativa moderada con la pelvis, alrededor de $-0{,}30$. En las articulaciones que incluyen al tobillo se aprecia la diferencia más clara entre el conjunto de entrenamiento y el de validación. En los datos reales de entrenamiento, los pares cadera–tobillo y pelvis–tobillo presentan correlaciones de magnitud moderada (en torno a $-0{,}23$ y 0,23, respectivamente), mientras que en el conjunto de validación estas relaciones se atenúan hasta valores muy próximos a cero ($r \approx 0{,}06$ para cadera–tobillo y $r \approx 0{,}01$ para pelvis–tobillo, con rodilla–tobillo también cercano a cero). Este cambio sugiere que el acoplamiento distal del tobillo no es un rasgo robusto del patrón de marcha, sino que depende de forma marcada de las características del subconjunto analizado. En el conjunto de validación la estrategia del tobillo parece ser más heterogénea entre sujetos, lo que se traduce en un patrón de correlaciones más débil y menos consistente con las articulaciones proximales. Este comportamiento es coherente con

la literatura actual, donde el tobillo se identificó como la articulación más sensible a la variabilidad intersujeto y a pequeñas desalineaciones temporales [69].

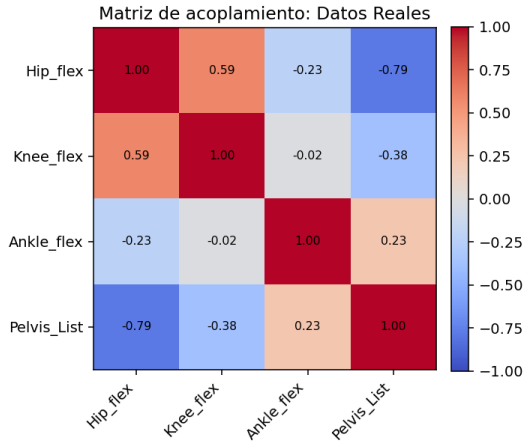


Figura 4.3: Matriz de acoplamiento interarticular obtenida a partir de los datos reales del conjunto de entrenamiento. Cada elemento refleja la correlación media entre dos articulaciones durante el ciclo de marcha.

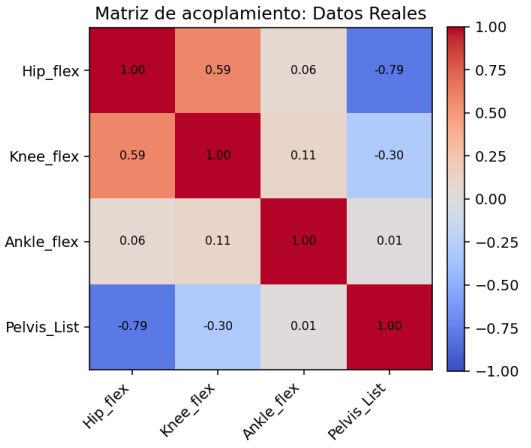


Figura 4.4: Matriz de acoplamiento interarticular obtenida a partir de los datos reales del conjunto de validación. Cada elemento refleja la correlación media entre dos articulaciones durante el ciclo de marcha.

Las Figuras 4.5 y 4.6 recogen las matrices de correlación obtenidas a partir de las trayectorias sintéticas. En el conjunto de entrenamiento, el generador reproduce de forma correcta la organización interarticular real. La cadera y la rodilla mantienen una correlación positiva moderada, con r cercano a 0,54, la cadera y el tobillo conservan una relación negativa en torno a $-0{,}27$ y el acoplamiento entre cadera y pelvis sigue siendo claramente inverso, con valores próximos a $-0{,}74$. El resto de pares articulares presentan correlaciones de menor intensidad, con una relación negativa débil entre rodilla y pelvis, alrededor de $-0{,}30$, un acoplamiento positivo suave entre tobillo y pelvis, en torno a 0,29, y una correlación prácticamente nula entre rodilla y tobillo, próxima a $-0{,}05$. Este patrón indica que, cuando trabaja sobre datos vistos, el modelo preserva de manera fiable la arquitectura proximal de la marcha y no introduce acoplamientos artificiales de gran magnitud.

El comportamiento en el conjunto de validación resulta especialmente relevante. En la Figura 4.6 se observa que el modelo mantiene de forma razonable las relaciones dominantes. La cadera y la rodilla siguen mostrando una correlación positiva moderada, con r cercano a 0,53, y la relación entre cadera y pelvis conserva prácticamente la misma magnitud negativa, alrededor de $-0{,}78$. La rodilla y la pelvis continúan vinculadas por un acoplamiento negativo, con un valor aproximado de $-0{,}35$. Es decir, las dependencias proximales más estables se preservan incluso cuando el generador se enfrenta a combinaciones de condiciones no vistas durante el entrenamiento.

En las articulaciones distales el patrón es similar al de los datos reales. Las correlaciones que incluyen al tobillo siguen siendo bajas y se sitúan en torno a $-0{,}07$ para el par cadera y tobillo y a 0,09 para pelvis y tobillo. Estas variaciones reflejan ligeros desplazamientos respecto a los datos reales, pero no cambian el hecho de que el tobillo presenta un acoplamiento intrínsecamente débil con las articulaciones proximales.

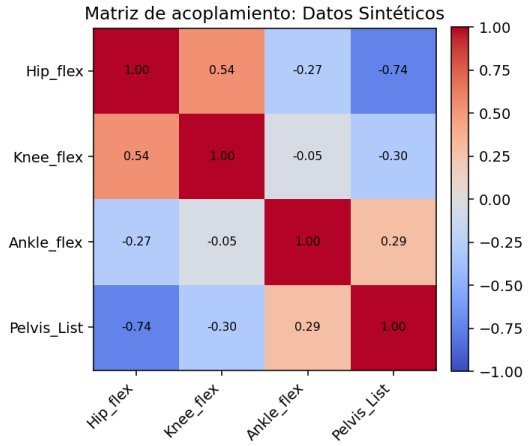


Figura 4.5: Matriz de acoplamiento interarticular obtenida a partir de las señales sintéticas generadas por el modelo en el conjunto de entrenamiento.

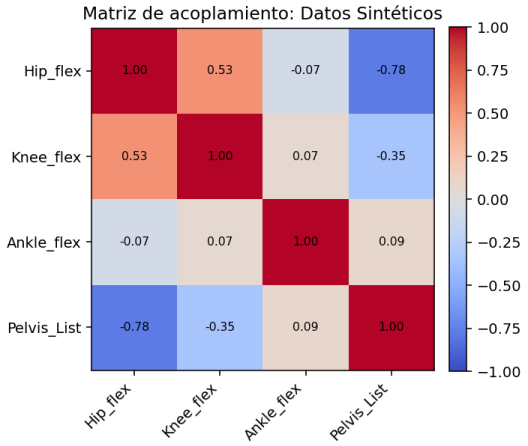


Figura 4.6: Matriz de acoplamiento interarticular obtenida a partir de las señales sintéticas generadas por el modelo en el conjunto de validación.

Las Figuras 4.7 y 4.8 representan las matrices de diferencias ΔC en entrenamiento y validación y permiten cuantificar de forma más directa estas discrepancias. En el conjunto de entrenamiento, la mayoría de los elementos de ΔC se mantienen muy próximos a cero y el valor medio absoluto de las diferencias es de 0,0395. En validación este valor medio absoluto es de 0,0438, también muy reducido. En ambos casos, las discrepancias más visibles se concentran en los pares que incluyen a la pelvis y al tobillo. En entrenamiento las mayores diferencias aparecen en rodilla y pelvis, con un incremento de correlación de aproximadamente $+0{,}07$, y en tobillo y pelvis, con una diferencia cercana a $+0{,}06$. En validación se observa una discrepancia de alrededor de $+0{,}08$ en pelvis y tobillo y un valor cercano a $-0{,}13$ en cadera y tobillo, asociado al cambio de signo de la correlación respecto al conjunto real. También se registran diferencias moderadas en cadera y rodilla, en torno a $-0{,}06$, y en rodilla y pelvis, cercanas a $-0{,}04$. En todos los casos las magnitudes permanecen por debajo de 0,1, lo que indica que, a escala global, el modelo introduce ajustes relativamente pequeños sobre el patrón de acoplamiento original.

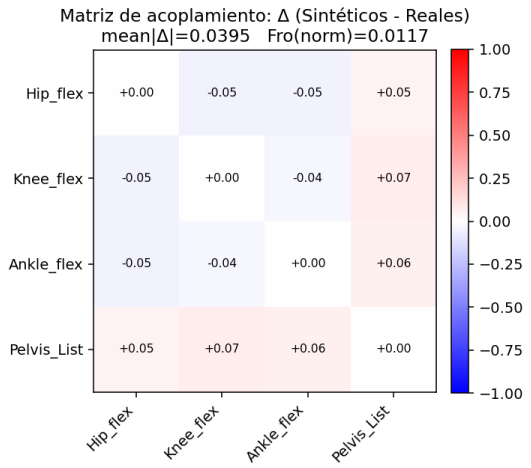


Figura 4.7: Matriz de diferencias del acoplamiento interarticular en el conjunto de entrenamiento.

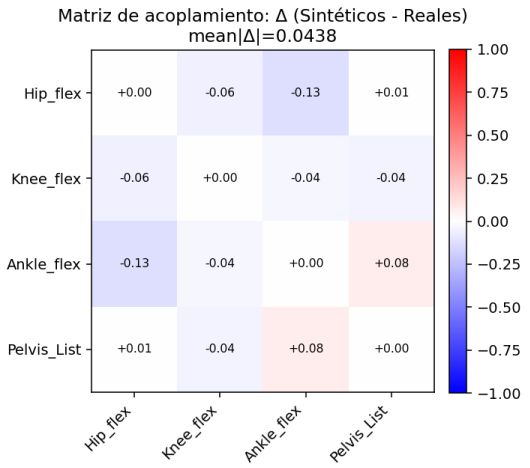


Figura 4.8: Matriz de diferencias del acoplamiento interarticular en el conjunto de validación.

Desde una perspectiva clínica, estas diferencias no modifican la estructura dominante del ciclo. Los pares funcionalmente más relevantes, como cadera y rodilla y cadera y pelvis, mantienen valores muy próximos entre datos reales y sintéticos tanto en entrenamiento como en validación. Las mayores variaciones se concentran en los pares que incluyen al tobillo, donde el acoplamiento ya es débil en los datos reales y pequeñas fluctuaciones son esperables. En conjunto, el análisis del acoplamiento interarticular muestra que el modelo no solo es capaz de generar trayectorias articulares plausibles de forma individual, sino que también preserva la estructura principal de coordinación entre articulaciones en ambos conjuntos. Estos resultados son coherentes con lo descrito en la literatura sobre coordinación interarticular en la marcha, donde se ha observado una relación más robusta entre cadera y rodilla y una mayor variabilidad en los pares que incluyen al tobillo tanto en población sana como en contextos patológicos [69]. Esto refuerza la idea de que el generador captura de manera consistente la organización global de la marcha y que las diferencias observadas se concentran en los componentes más sensibles a la variabilidad intersujeto y a las desalineaciones temporales.

4.1.3. Análisis mediante componentes principales (PCA)

El análisis mediante componentes principales permite comprobar si las trayectorias sintéticas se distribuyen de forma similar a las reales cuando se consideran todas sus dimensiones a la vez. Cada señal de marcha es una señal de alta dimensión formada por cien instantes temporales y cuatro articulaciones. Con el PCA se identifican los aspectos del movimiento que más varían en el *dataset* y se reduce esa información a un espacio de menor dimensión donde cada ciclo se representa

como un único punto. Esta representación facilita ver si los ciclos sintéticos ocupan la misma región que los reales, si muestran una variabilidad comparable o si el modelo genera patrones que no aparecen en los datos originales. Dado que las muestras sintéticas se generan a partir de las mismas condiciones de entrada, cabría esperar que sus trayectorias ocupen una región similar a la de los ciclos reales en este espacio reducido.

Para aplicar PCA, cada trayectoria de marcha se vectoriza concatenando las señales de cada articulación una detrás de otra, de modo que cada ciclo queda representado como un vector en $\mathbb{R}^{T \cdot J}$:

$$\mathbf{x}_n^{\text{real}} = \text{vec}(Y_{n,:,:}^{\text{real}}), \qquad \mathbf{x}_m^{\text{syn}} = \text{vec}(Y_{m,:,:}^{\text{syn}}).$$

A partir de estos vectores se construye una matriz de datos en la que cada fila corresponde a un ciclo de marcha y cada columna corresponde a un instante temporal t de una articulación j concreta:

$$X = \begin{bmatrix} x_{1,t=1,j=1} & x_{1,t=2,j=1} & \cdots & x_{1,t=T,j=1} & x_{1,t=1,j=2} & \cdots & x_{1,t=T,j=J} \\ x_{2,t=1,j=1} & x_{2,t=2,j=1} & \cdots & x_{2,t=T,j=1} & x_{2,t=1,j=2} & \cdots & x_{2,t=T,j=J} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ x_{N,t=1,j=1} & x_{N,t=2,j=1} & \cdots & x_{N,t=T,j=1} & x_{N,t=1,j=2} & \cdots & x_{N,t=T,j=J} \end{bmatrix}.$$

A continuación, se centra la matriz restando la media de cada columna y, sobre esta matriz centrada, se calcula su descomposición en valores singulares:

$$\tilde{X} = USV^\top$$

Las columnas de V representan las direcciones principales de variación del *dataset*, los valores singulares de S indican la cantidad de varianza capturada en cada dirección y la matriz U contiene los coeficientes con los que cada ciclo se proyecta sobre esas direcciones. Al multiplicar U por S se obtiene la matriz US, que contiene la proyección de todas las muestras en el espacio de componentes principales. Esta matriz tiene dimensión $N \times D$, donde cada fila representa un ciclo de marcha y cada columna una componente principal. En este trabajo se utilizan las dos primeras columnas de US, denominadas PC1 y PC2, que recogen las coordenadas de cada ciclo en las componentes que más varianza explican.

El porcentaje de varianza visualizada en el plano formado por PC1 y PC2 se calcula como

$$\text{Var}(PC1 + PC2) = \frac{s_1^2 + s_2^2}{\sum_k s_k^2},$$

lo que permite cuantificar cuánta información del conjunto original se observa en el espacio reducido. Una varianza explicada elevada indica que las dos primeras

componentes capturan las variaciones más importantes del movimiento y permiten comparar de forma fiable la distribución global de muestras reales y sintéticas.

En este espacio bidimensional se representan conjuntamente los ciclos reales y sintéticos. Para comparar sus distribuciones se calcula el centroide y la elipse de dispersión de cada conjunto. El centroide resume la posición global de la distribución y corresponde al punto medio de las muestras proyectadas en el plano PC1 y PC2. La elipse de dispersión indica la región donde se concentra la mayor parte de las muestras; su forma y orientación informan sobre la dirección principal de variación y la amplitud de la variabilidad dentro del conjunto. Si ambas nubes se solapan, presentan centroides próximos y elipses con forma y orientación similares, puede considerarse que el generador reproduce adecuadamente la estructura global de variabilidad de la marcha humana que aparece en el *dataset* real.

La Figura 4.9 muestra la proyección conjunta de los ciclos reales y sintéticos de entrenamiento, mientras que la Figura 4.10 recoge los resultados análogos para el conjunto de validación.

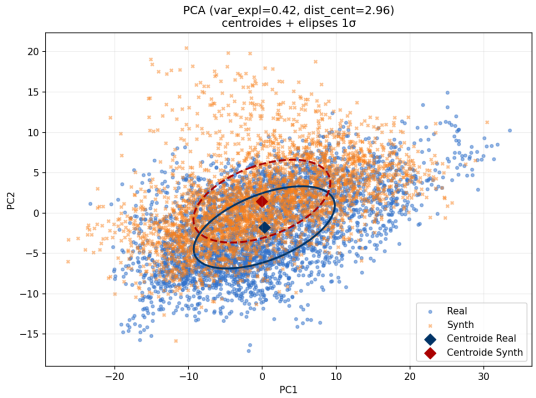


Figura 4.9: Proyección conjunta de los ciclos reales y sintéticos del conjunto de entrenamiento en el plano PCA.. Se muestran los centroides y las elipses de dispersión de una desviación estándar de cada conjunto.

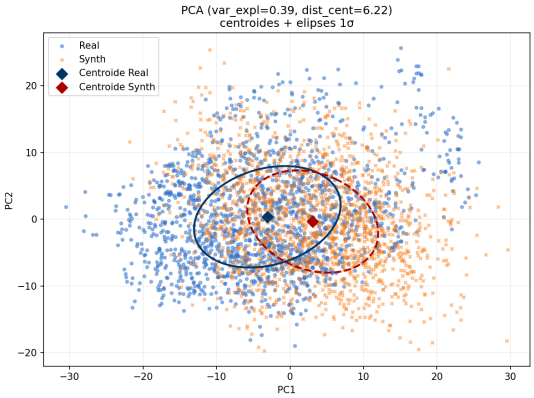


Figura 4.10: Proyección conjunta de los ciclos reales y sintéticos del conjunto de validación en el plano PCA. Se muestran los centroides y las elipses de dispersión de una desviación estándar de cada conjunto.

En el conjunto de entrenamiento (Figura 4.9) las dos primeras componentes principales capturan el 42.2 % de la varianza total. Las nubes de datos reales y sintéticos presentan un solapamiento amplio y una forma alargada similar, lo que indica que la mayor parte de la variabilidad se organiza a lo largo de un mismo eje dominante. Las elipses de dispersión tienen una longitud comparable y una orientación muy parecida, de modo que la magnitud y la dirección principal de la variabilidad coinciden en ambos conjuntos. La elipse sintética aparece ligeramente más ancha, lo que sugiere que el modelo introduce una variabilidad algo mayor que la observada en el *dataset*

original, aunque esta sobredispersión es moderada y no modifica la estructura general del espacio reducido. Los centroides real y sintético se encuentran separados por 2.956 unidades en el plano PC1 y PC2, con el centroide sintético desplazado hacia valores algo más altos de ambas componentes. Esta distancia es pequeña en relación con la extensión de las nubes y no rompe el solapamiento global entre ambas distribuciones.

En el conjunto de validación (Figura 4.10) las dos primeras componentes capturan el 39 % de la varianza total. Sigue existiendo un solapamiento apreciable entre las muestras reales y sintéticas, pero la organización relativa de los dos conjuntos muestra diferencias más claras que en el entrenamiento. Los ciclos reales tienden a organizarse a lo largo de una diagonal que avanza desde valores negativos de PC1 y PC2 hacia valores positivos en ambas direcciones. Las muestras sintéticas, en cambio, se concentran preferentemente hacia valores más altos de PC1 y muestran una distribución similar en PC2 pero en dirección perpendicular al conjunto de datos de validación. Las elipses de dispersión mantienen tamaños similares, lo que indica que la magnitud global de la variabilidad es comparable, pero sus ejes principales no comparten exactamente la misma orientación. Esto sugiere que el modelo preserva un nivel de dispersión cercano al real, aunque desplaza parte de la variabilidad hacia direcciones ligeramente distintas en el espacio PCA. La diferencia más clara aparece en la posición de los centroides. El centroide sintético de validación se encuentra desplazado de forma notable respecto al real, con una distancia total de 6.22 unidades en el plano PC1 y PC2. Este desplazamiento indica que las trayectorias sintéticas tienden a concentrarse en una región diferente del espacio latente respecto a los ciclos reales, aunque siguen situándose dentro del entorno general ocupado por estos. La combinación de esta separación entre centroides y la orientación distinta de las elipses muestra que, aunque las muestras generadas capturan en buena medida la tendencia global de la distribución real, la estructura estadística en el plano reducido no se preserva con la misma precisión que en el conjunto de entrenamiento.

En conjunto, el análisis PCA muestra que el modelo es capaz de aproximar de forma razonable la distribución global de variabilidad de las trayectorias reales, sobre todo cuando se evalúa sobre el conjunto de entrenamiento. En validación las secuencias sintéticas siguen ocupando una región plausible del espacio definido por los ciclos reales, pero la separación entre centroides y la rotación de las elipses indican que la distribución generada se desplaza y se deforma respecto a la original. Estas diferencias encajan con las conclusiones del análisis de curvas promedio y del acoplamiento interarticular, donde la fidelidad estadística del modelo es alta en las articulaciones proximales, pero se deteriora al exigir una generalización completa de la distribución de marcha en condiciones no vistas.

4.2. Análisis biomecánico

Una vez comprobado que el modelo es capaz de reproducir la distribución estadística de las trayectorias articulares, el siguiente paso consiste en evaluar si las secuencias generadas son también biomecánicamente coherentes. El objetivo de este análisis no es valorar únicamente la similitud numérica entre señales, sino verificar que, al ser interpretadas mediante el modelo cinemático de NIMBLE, producen un patrón de marcha compatible con el movimiento humano.

Para interpretar correctamente las trayectorias generadas es necesario reconstruir la marcha completa de ambas piernas. El modelo cinemático de NIMBLE requiere disponer de las trayectorias articulares de ambos miembros inferiores, pero el generador sólo modela explícitamente la pierna ipsilateral. Por ello, la pierna contralateral se reconstruye aplicando un desfase temporal del 50 % del ciclo sobre la pierna generada, lo que se apoya en la biomecánica clásica de la marcha, donde ambas piernas evolucionan de manera aproximadamente simétrica con un desfase cercano a medio ciclo [2]. Esta aproximación sólo es válida si el ciclo generado es prácticamente periódico, es decir, si el estado articular al final del ciclo coincide con el del inicio.

Para garantizar esta condición se calcula, para cada secuencia, una medida de similitud entre el vector articular inicial y final

$$s_n = \left(1 - \frac{\left\|\mathbf{y}_{\text{fin}}^{(n)} - \mathbf{y}_{\text{ini}}^{(n)}\right\|}{\left\|\mathbf{y}_{\text{ini}}^{(n)}\right\|}\right) \cdot 100,$$

y sólo se conservan para el análisis aquellas secuencias que cumplen $s_n \geq 95\,\%$. Este filtrado elimina ciclos cuyo cierre no es suave y que, al reconstruir la pierna contralateral mediante el desfase temporal, producirían saltos no fisiológicos en las trayectorias cartesianas del pie.

La aplicación de este criterio de calidad tiene un impacto muy relevante en el conjunto de secuencias disponibles. En el conjunto de entrenamiento se descarta un 51.2 % de las secuencias totales generadas, mientras que en el conjunto de validación se elimina aproximadamente un 38 % de las muestras. Estos porcentajes indican que una fracción considerable de las trayectorias generadas no cumple la condición de periodicidad exigida para obtener una marcha biomecánicamente coherente. Por un lado, el filtrado permite concentrar el análisis en los ciclos más plausibles y evitar conclusiones condicionadas por secuencias claramente defectuosas. Por otro lado, el hecho de que sea necesario descartar un número tan elevado de muestras revela una limitación clara del modelo, que tiende a producir soluciones plausibles desde un punto de vista estadístico pero no siempre suficientemente regulares para sostener una reconstrucción cinemática estable. El análisis biomecánico que se presenta a continuación debe interpretarse, por tanto, como una evaluación sobre el subconjunto de trayectorias que superan este filtro de calidad.

4.2.1. Consistencia de las condiciones clínicas

Un primer aspecto para valorar la coherencia biomecánica de las secuencias generadas es comprobar hasta qué punto las trayectorias articulares sintéticas respetan las condiciones clínicas con las que fueron condicionadas. Para ello se compara, tanto en el conjunto de entrenamiento como en el de validación, la longitud de paso (L) y la altura de paso (H) especificadas en la entrada (X_{cond}) con los valores reconstruidos tras aplicar el modelo cinemático de NIMBLE (X_{real}).

Las Figuras 4.11 y 4.12 muestran el plano L–H para entrenamiento y validación, respectivamente. En ambos casos las nubes de puntos correspondientes a X_{cond} y X_{real} se concentran en regiones similares del plano, con longitudes de paso comprendidas aproximadamente entre 0.25 m y 0.8 m y alturas entre 0.05 m y 0.4 m, en consonancia con las restricciones impuestas al construir los *datasets*. Sin embargo, en los dos conjuntos aparecen valores reconstruidos atípicos que se alejan de estos rangos, con longitudes que superan los 2 m y alturas por encima de 60 cm. También aparecen otras desviaciones más atenuadas en el conjunto de validación, donde la nube de X_{real} se extiende algo más allá del dominio de entrenamiento y se observan más puntos fuera del cuadro de condiciones clínicas originales. En conjunto, la comparación visual sugiere que el generador respeta razonablemente el rango global de las condiciones, pero que la reconstrucción cinemática amplifica ciertas combinaciones angulares dando lugar a un pequeño número de ciclos con longitudes y alturas claramente no fisiológicas.

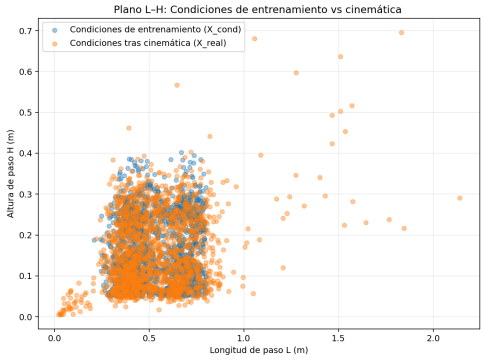


Figura 4.11: Plano L–H comparando las condiciones de entrada (X_{cond}) y las obtenidas tras el modelo cinemático (X_{real}) en el conjunto de entrenamiento.

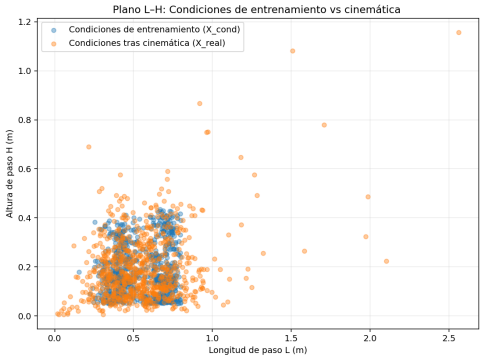


Figura 4.12: Plano L–H comparando las condiciones de entrada (X_{cond}) y las obtenidas tras el modelo cinemático (X_{real}) en el conjunto de validación.

Las Figuras 4.13 y 4.14 permiten analizar con más detalle la relación entre condiciones y reconstrucciones al representar L_{real} frente a L_{cond} y H_{real} frente a H_{cond}, junto con la recta identidad. En el conjunto de entrenamiento, la mayoría de las muestras se agrupa estrechamente alrededor de dicha recta, lo que indica que el generador tiende a aproximarse de forma razonable a las longitudes y alturas de paso deseadas. Aun así, aparecen valores atípicos que se desvían de forma notable

y de manera irregular a lo largo del rango de condiciones, sin un patrón sistemático claro. En el conjunto de validación se mantiene la misma tendencia global, pero el alineamiento con la recta identidad es claramente menor. Incluso ignorando los valores extremos, la nube de puntos es más ancha y se observa un número mayor de muestras alejadas de la identidad tanto en longitud como en altura. No obstante, la estructura general de la distribución se conserva y en la longitud de paso se distinguen todavía dos conglomerados principales alrededor de 0.4 m y 0.7 m, heredados de la distribución de condiciones originales.

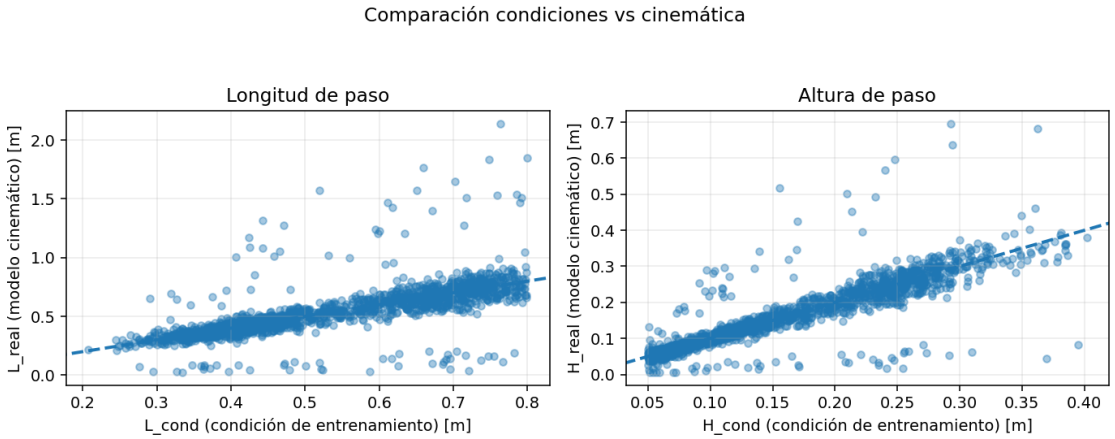


Figura 4.13: Diagramas de dispersión para la comparación entre X_{real} y X_{cond} en el conjunto de entrenamiento.

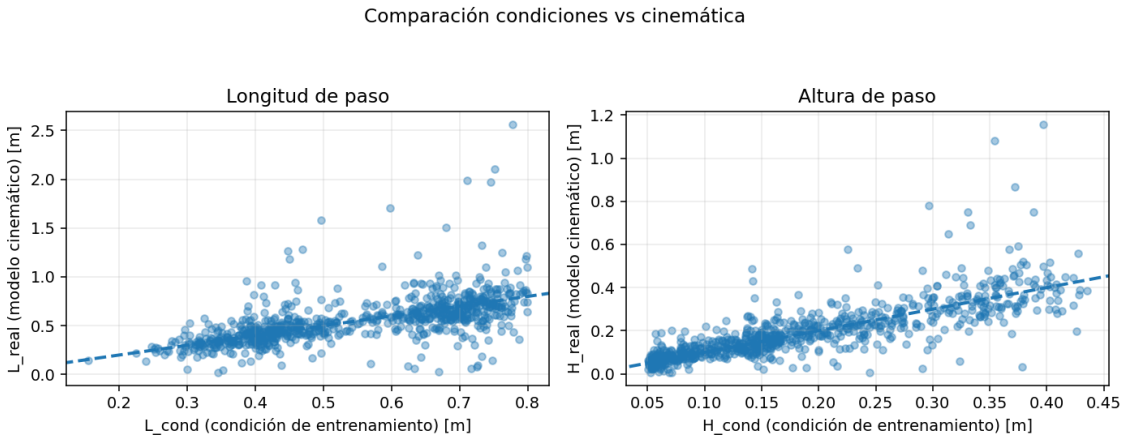


Figura 4.14: Comparación entre las condiciones clínicas y los valores reconstruidos en el conjunto de validación. Izquierda longitud de paso. Derecha altura de paso. La recta discontinua representa la recta identidad $y = x$.

Para más detalle de cómo varía el error en función de la propia condición clínica, se calculó la diferencia entre condición y reconstrucción en centímetros ($L_{\text{real}} - L_{\text{cond}}$ y $H_{\text{real}} - H_{\text{cond}}$) y se agruparon las muestras en tramos de L_{cond} y H_{cond}. Las

Figuras 4.15 y 4.16 muestran la distribución de estos errores mediante diagramas de caja para el conjunto de entrenamiento y el de validación, respectivamente.

En el conjunto de entrenamiento (Figura 4.15), las medianas del error en longitud de paso se mantienen muy próximas a cero en los tres intervalos de L_{cond} y las distribuciones son razonablemente simétricas. Esto indica que, dentro del dominio visto durante el entrenamiento, el modelo no introduce un sesgo sistemático claro hacia pasos más largos o más cortos, aunque la dispersión aumenta de forma progresiva a medida que crece la longitud condicionada. En los tramos de L_{cond} más altos se aprecia ya una ligera tendencia a que L_{real} quede por debajo de L_{cond}. En la altura de paso el comportamiento es algo más contenido. Los boxplots de $H_{\text{real}} - H_{\text{cond}}$ presentan medianas prácticamente nulas, excepto en el mayor tramo de alturas, y rangos intercuartílicos reducidos en los tres tramos de H_{cond}. La mayoría de las muestras se concentra dentro de un margen de error estrecho, aunque se identifican valores considerados atípicos con errores por encima de 15 cm en los casos más extremos. Estos valores atípicos claramente coinciden con errores en la creación de las trayectorias y no reflejan pasos reales. En conjunto, el modelo reproduce de forma bastante estable la altura de paso en entrenamiento, con un número de *outliers* apreciable de forma aislada pero que solo representan un 5 % de los resultados totales. En el conjunto de validación (Figura 4.16) la estructura general se conserva, pero las tendencias que ya se insinuaban en entrenamiento se vuelven más claras. En la longitud de paso, las distribuciones siguen centradas en torno a cero, pero se observa una deriva progresiva hacia mayores errores a medida que aumenta L_{cond}. Además, en el tramo de pasos más largos los diagramas muestran una asimetría visible hacia valores negativos, lo que indica que el modelo tiende a generar longitudes ligeramente menores que las deseadas. Esta degradación no se manifiesta solo en el desplazamiento de la mediana, sino también en el ensanchamiento del rango intercuartílico. En la altura de paso, la dependencia de la condición es más suave. En los tres tramos de H_{cond} las medianas del error permanecen muy próximas a cero y el rango intercuartílico se mantiene relativamente contenido, especialmente en el intervalo intermedio, donde la mayoría de las muestras concentra errores pequeños. Solo en las alturas más altas se aprecia un ligero desplazamiento hacia valores negativos y un aumento moderado de la dispersión. Aun así, es evidente la presencia de un número mayor de valores atípicos en comparación con los datos de entrenamiento, que en conjunto representan aproximadamente un 14 % de las muestras y pueden alcanzar errores de varias decenas de centímetros en un subconjunto reducido de ciclos.

En conjunto, la comparación visual entre entrenamiento y validación sugiere que el modelo conserva mejor la coherencia en altura que en longitud y que las discrepancias más relevantes se concentran en los pasos largos y en las regiones periféricas del espacio de condiciones.

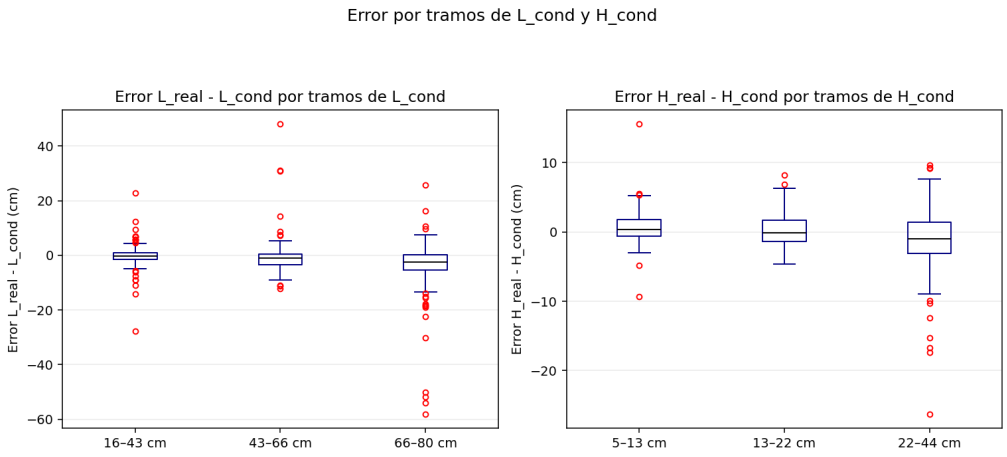


Figura 4.15: Distribución del error firmado entre condiciones y valores reconstruidos en el conjunto de entrenamiento, agrupado por tramos de condición.

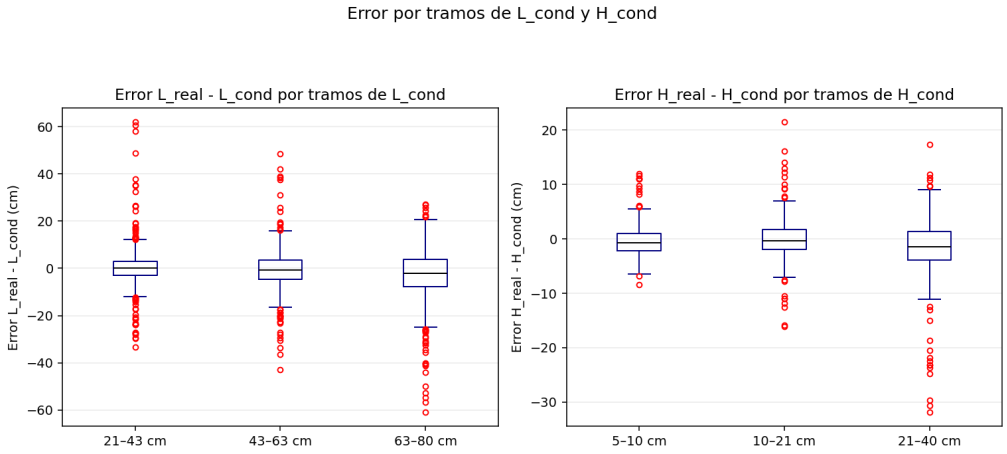


Figura 4.16: Distribución del error firmado entre condiciones y valores reconstruidos en el conjunto de validación, agrupado por tramos de condición.

Las Tablas 4.3 y 4.4 completan el análisis mediante los percentiles del error absoluto. En la longitud de paso, el error mediano pasa de 3.5 cm en entrenamiento a 6.3 cm en validación, el percentil 75 crece de aproximadamente 6.4 cm a 12.7 cm y el percentil 95 se incrementa de 14.4 cm hasta casi 29.5 cm. Esta evolución confirma que los errores típicos y extremos en L se amplifican de forma significativa cuando el modelo se enfrenta a combinaciones de condiciones no vistas durante el entrenamiento. En la altura de paso, el deterioro es más moderado. La mediana del error aumenta de 1 cm a 2.8 cm y el percentil 95 pasa de unos 4.9 cm a 12.2 cm, manteniéndose en rangos aún relativamente contenidos. En conjunto, los percentiles reflejan que la mayor parte de las muestras mantiene errores pequeños o moderados, especialmente en H, pero que existe una cola de secuencias con errores importantes, sobre todo en la longitud de paso en el conjunto de validación.

Magnitud	**p50** $\lvert d \rvert$ **(m)**	**p75** $\lvert d \rvert$ **(m)**	**p95** $\lvert d \rvert$ **(m)**
L	0.0353	0.0641	0.1441
H	0.0102	0.0206	0.0489

Tabla 4.3: Percentiles del error absoluto entre las condiciones deseadas y las reconstruidas en el conjunto de entrenamiento.

Magnitud	**p50** $\lvert d \rvert$ **(m)**	**p75** $\lvert d \rvert$ **(m)**	**p95** $\lvert d \rvert$ **(m)**
L	0.0627	0.1274	0.2951
H	0.0275	0.0518	0.1215

Tabla 4.4: Percentiles del error absoluto entre las condiciones deseadas y las reconstruidas en el conjunto de validación ($N = 771$).

En resumen, el análisis conjunto de entrenamiento y validación muestra que el modelo aprende de forma razonable la relación entre las condiciones clínicas de longitud y altura de paso y las trayectorias articulares que las generan, con un ajuste especialmente sólido en la altura. La longitud de paso se reproduce con precisión aceptable en entrenamiento, pero resulta claramente más sensible en validación, donde aumentan tanto el RMSE como los errores extremos. Esto sugiere que, aunque el generador es capaz de mantener la coherencia clínica en la mayoría de los ciclos, su capacidad de generalización es limitada cuando se combinan condiciones no vistas previamente, sobre todo al trabajar sobre grandes longitudes de paso.

4.2.2. Análisis de las trayectorias cartesianas del pie

Además de la comparación entre las condiciones clínicas, resulta fundamental evaluar la geometría del movimiento del pie generado por el modelo. Las trayectorias cartesianas obtenidas a partir del modelo cinemático permiten comprobar si las secuencias articulares producidas por el generador se traducen en una marcha con un comportamiento espacial coherente. Para ello se analizan ocho señales correspondientes al tobillo, talón y punta de ambos pies en las componentes sagital (X) y vertical (Z), lo que proporciona una descripción completa del avance y la elevación del pie durante el ciclo.

En primer lugar, se representa el conjunto de trayectorias individuales de cada una de estas señales, obteniendo a partir de ellas su curva media y su desviación estándar. Estas curvas permiten evaluar varios aspectos biomecánicos concretos. En la componente sagital (X), las trayectorias del tobillo deberían mostrar una progresión continua hacia adelante, sin retrocesos bruscos ni cambios de pendiente incompatibles con una locomoción estable. En la componente vertical (Z), tanto el

talón como la punta deberían reflejar un comportamiento coherente con las fases de apoyo y oscilación. El talón debe descender de forma progresiva antes del contacto con el suelo, mientras que la punta debe elevarse durante la fase de oscilación sin presentar picos o hundimientos no fisiológicos. La elevación máxima del pie debería producirse aproximadamente en la mitad de la fase de oscilación, formando un arco suave y continuo.

Además, el análisis conjunto de las señales de ambos pies permite comprobar si se mantiene la alternancia típica de la marcha. Durante el apoyo de un pie, el contralateral debería encontrarse en la fase de oscilación con una elevación vertical clara, de modo que las curvas Z del talón y la punta de un pie se sitúen próximas al suelo cuando las del otro pie describen el máximo de su trayectoria. Este patrón de alternancia debe apreciarse tanto en el conjunto de entrenamiento como en el de validación.

Las Figuras 4.17 y 4.19 recogen las trayectorias cartesianas reconstruidas a partir de las secuencias sintéticas del conjunto de entrenamiento, mientras que las Figuras 4.18 y 4.21 muestran los resultados análogos para el conjunto de validación. En todos los casos se representan las muestras individuales junto con la curva media y la banda de una desviación estándar.

En la componente anteroposterior (X), ilustrada en las Figuras 4.17 y 4.18, las trayectorias del tobillo describen un patrón globalmente coherente con el avance esperado durante el ciclo de la marcha. En el conjunto de entrenamiento, la forma media es suave y estable y las bandas de dispersión muestran una variabilidad moderada a lo largo de todo el ciclo. La progresión temporal refleja un patrón funcional reconocible, con un periodo inicial de doble apoyo durante aproximadamente el primer 10 % del ciclo, seguido del avance claro de la pierna derecha al entrar en fase de balanceo y del patrón inverso hacia el 60 % del ciclo, cuando la pierna izquierda inicia su oscilación mientras la derecha estabiliza de nuevo el contacto.

En el conjunto de validación (Figura 4.18) se mantiene esta organización global. La curva media reproduce prácticamente la misma forma que en entrenamiento y la alternancia entre ambos pies sigue siendo evidente. No obstante, la desviación estándar es algo mayor, especialmente tras el avance del pie derecho y en la parte final del ciclo, lo que indica que la variabilidad intersujeto y la combinación de condiciones no vistas se traducen en una dispersión ligeramente superior de las trayectorias cartesianas. A pesar de ello, no se observan retrocesos bruscos ni cambios de pendiente incompatibles con una marcha estable, por lo que el comportamiento en X puede considerarse biomecánicamente plausible en ambos conjuntos.

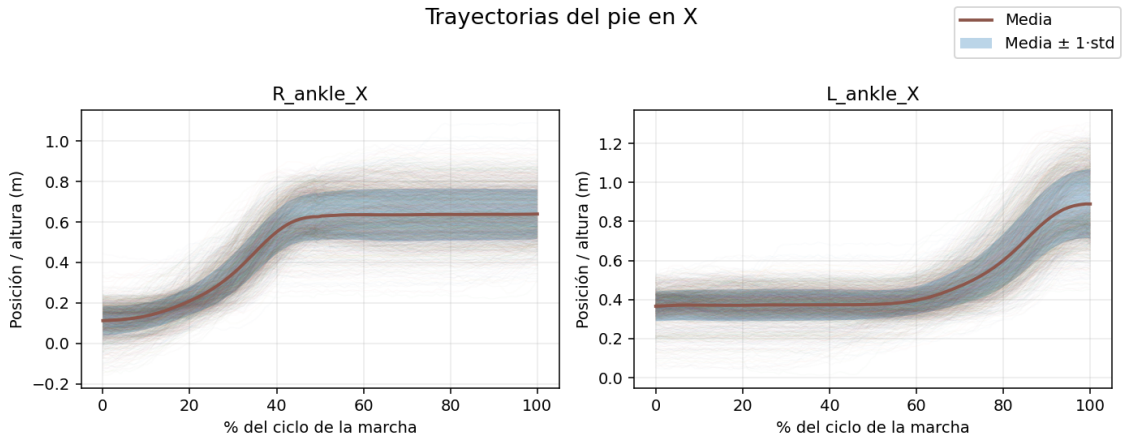


Figura 4.17: Trayectorias cartesianas sagitales (X) del tobillo reconstruidas mediante el modelo cinemático en el conjunto de entrenamiento. Las líneas finas representan todas las muestras, la línea gruesa indica la media y la banda sombreada corresponde a ± 1 desviación estándar.

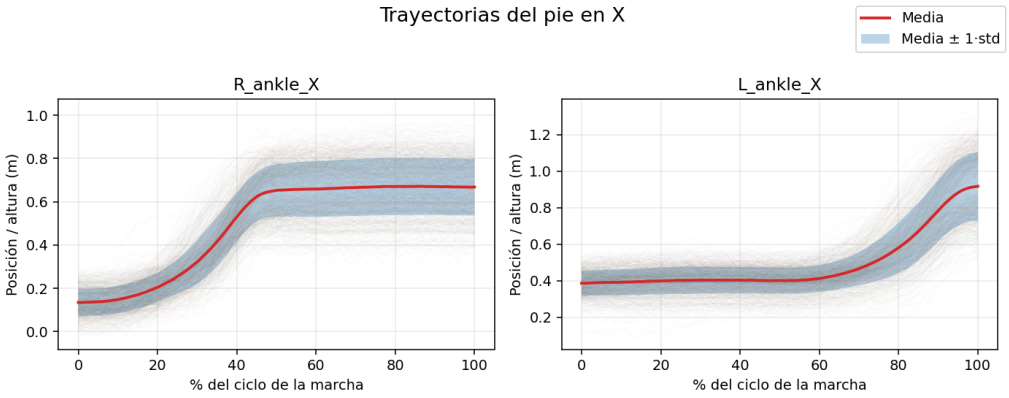


Figura 4.18: Trayectorias anteroposteriores (X) del tobillo reconstruidas a partir de las señales sintéticas del conjunto de validación.

La componente vertical (Z) permite analizar con más detalle la fase de oscilación y el contacto con el suelo. La Figura 4.19 muestra las señales verticales del tobillo, talón y punta de ambos pies en el conjunto de entrenamiento. La morfología media reproduce el patrón típico de elevación durante el balanceo y descenso previo al contacto inicial, con máximos bien definidos aproximadamente en la mitad de la fase de oscilación de cada pierna y una alternancia clara entre pie derecho e izquierdo. La variabilidad es mayor que en la componente X, como es esperable en una magnitud muy sensible a pequeñas diferencias angulares, pero la estructura global se mantiene reconocible y compatible con una marcha habitual. Sin embargo, el análisis detallado de estas trayectorias revela un patrón recurrente que señala un problema específico del conjunto reconstruido. En prácticamente todos los canales aparece una franja muy densa en torno a $Z \approx 0$, lo que indica que un número importante de trayectorias desciende hasta el plano del suelo e incluso lo atraviesa ligeramente.

Estas penetraciones negativas no se corresponden con un movimiento real y reflejan que, en algunas muestras, pequeñas incoherencias en las secuencias articulares se amplifican en la coordenada vertical tras aplicar el modelo cinemático. Este efecto se aprecia con especial claridad en la señal `R_toe_Z`, representada de forma aislada en la Figura 4.20, donde además se observa una caída artificial muy pequeña alrededor del 50 % del ciclo. Este descenso leve no se extiende al resto de canales y parece estar relacionado con las discontinuidades residuales entre los valores finales e iniciales de algunos ciclos generados, que persisten a pesar del filtrado de consistencia aplicado al inicio del análisis biomecánico.

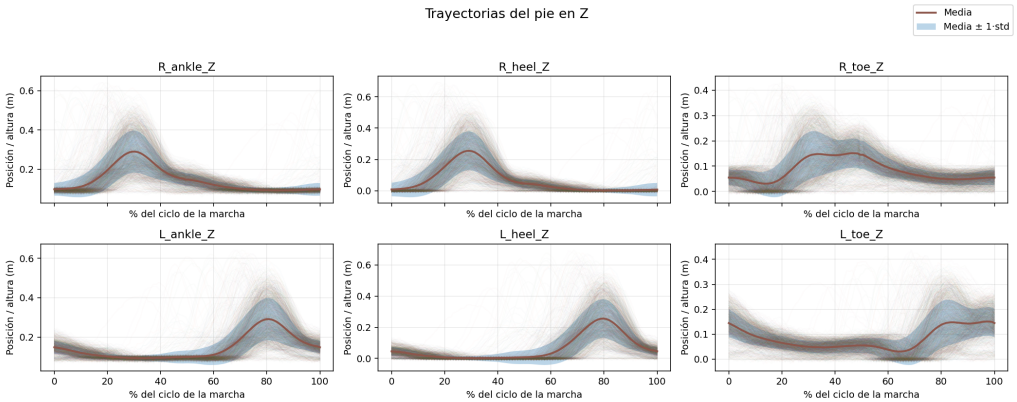


Figura 4.19: Trayectorias cartesianas verticales (Z) del tobillo, talón y punta reconstruidas mediante el modelo cinemático en el conjunto de entrenamiento.

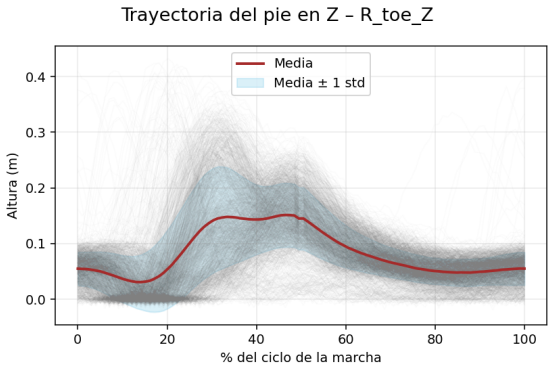


Figura 4.20: Trayectoria vertical del pie derecho en la coordenada Z para la señal `R_toe_Z` en el conjunto de entrenamiento.

En el conjunto de validación, la Figura 4.21 recoge las señales verticales del tobillo, talón y punta de ambos pies. La morfología media vuelve a reflejar de forma correcta el patrón típico de elevación durante el balanceo y descenso antes del contacto inicial, con máximos en torno al 35–40 % del ciclo para el pie derecho y alrededor del 80 % para el pie izquierdo, lo que confirma de nuevo la alternancia entre ambos miembros. La dispersión se mantiene moderada y la estructura general de las bandas es fisiológicamente reconocible. Al igual que en entrenamiento, persiste una franja de trayectorias que descienden hasta valores próximos a $Z = 0$ e

incluso ligeramente por debajo, señal de que el problema de penetración en el suelo no desaparece por completo al pasar al conjunto de validación. No obstante, a diferencia de lo que ocurre en entrenamiento, no se observan discontinuidades evidentes ni cambios abruptos en la pendiente de las curvas, lo que sugiere que, bajo las combinaciones de condiciones de validación, la reconstrucción cinemática es algo más regular a pesar de las penetraciones puntuales.

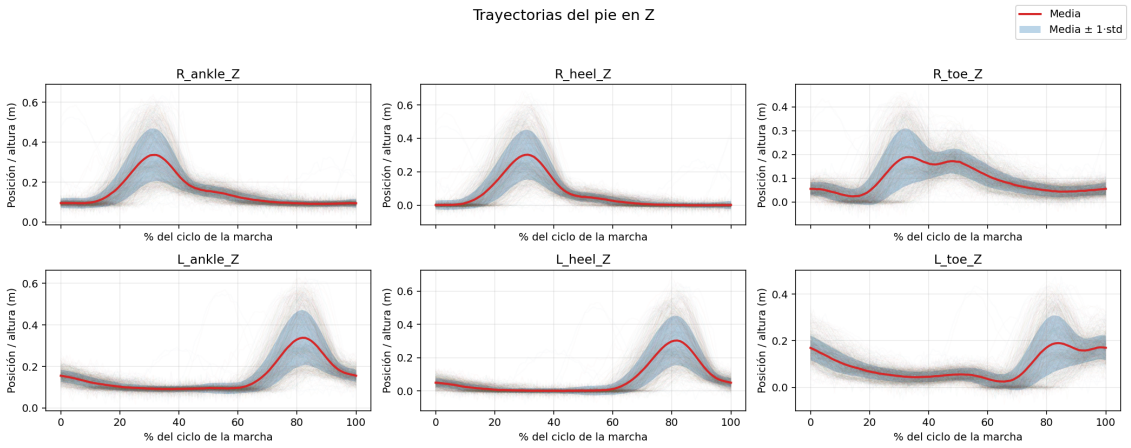


Figura 4.21: Trayectorias verticales (Z) del tobillo, talón y punta reconstruidas a partir de las señales sintéticas del conjunto de validación.

En conjunto, el análisis de las trayectorias cartesianas del pie indica que el modelo es capaz de generar un patrón de marcha espacialmente coherente tanto en entrenamiento como en validación. La organización temporal del avance en X y la alternancia entre ambos pies en Z se reproducen de forma consistente y reconocible. Sin embargo, la presencia de penetraciones del plano del suelo y de pequeñas discontinuidades residuales en algunas señales, especialmente en el conjunto de entrenamiento, revela que la proyección cinemática amplifica ciertas irregularidades angulares y genera un subconjunto de trayectorias con apoyo excesivamente agresivo o cierre de ciclo imperfecto. Estos efectos son localizados y no alteran la estructura media de la marcha, pero deben tenerse en cuenta a la hora de interpretar las métricas clínicas y las posibles aplicaciones del modelo en contextos de simulación o asistencia al movimiento.

4.2.3. Análisis temporal de las trayectorias del pie

El análisis temporal permite evaluar si la secuencia reconstruida de apoyo y oscilación es compatible con la organización funcional del ciclo de marcha. A partir de las señales verticales del talón y la punta de cada pie, y utilizando un mismo umbral de contacto en ambos conjuntos, se estiman las duraciones de las fases de apoyo, oscilación y doble apoyo para cada ciclo válido. Las Tablas 4.5 y 4.6 resumen

los resultados obtenidos en entrenamiento y validación, respectivamente.

En el conjunto de entrenamiento (Tabla 4.5), la fase de apoyo ocupa en torno al 60 % del ciclo tanto para el pie derecho (media 60.5 %) como para el izquierdo (60.1 %), con desviaciones estándar moderadas (7.4 % y 6.9 %) y percentiles que se sitúan entre el 52–76 % y el 52–73 %. La fase de oscilación presenta la distribución complementaria esperada, con duraciones cercanas al 40 % y una dispersión similar. En validación (Tabla 4.6) se observa un patrón muy parecido. Las medias de apoyo descienden ligeramente hasta 58.4 % y 57.8 %, mientras que la oscilación aumenta de forma complementaria hasta aproximadamente el 42 %. Las desviaciones estándar y los percentiles se mantienen en rangos similares a los del conjunto de entrenamiento. En conjunto, estos resultados muestran que el modelo conserva de forma consistente la estructura temporal básica del ciclo de marcha (aproximadamente 60 % de apoyo y 40 % de oscilación) tanto en las secuencias vistas durante el entrenamiento como en las condiciones de validación. Las mayores diferencias entre conjuntos aparecen en la duración del doble apoyo. En entrenamiento, la media se sitúa en 20.6 % con una desviación estándar de 11.9 % y un rango que va desde el 5 % (p5) hasta el 44 % (p95). En validación, el doble apoyo presenta una media ligeramente menor (18.4 %), pero mantiene una dispersión elevada (std = 12.4 %) y percentiles prácticamente idénticos (4–44 %). Esta variabilidad refleja la sensibilidad del cálculo del contacto simultáneo de ambos pies a pequeñas incoherencias verticales ya descritas en el análisis espacial. No obstante, la mayor parte de las muestras se agrupa en torno a valores compatibles con la marcha funcional y la organización temporal global del ciclo se mantiene dentro de márgenes biomecánicamente plausibles tanto en entrenamiento como en validación.

Magnitud	**Media (%)**	**Std (%)**	**p5 (%)**	**p50 (%)**	**p95 (%)**
Apoyo pie derecho	60.5	7.4	52.0	59.0	76.0
Apoyo pie izquierdo	60.1	6.9	52.0	59.0	73.0
Oscilación pie derecho	39.5	7.4	24.0	41.0	48.0
Oscilación pie izquierdo	39.9	6.9	27.0	41.0	48.0
Doble apoyo	20.6	11.9	5.0	18.0	44.0

Tabla 4.5: Duraciones temporales de las fases del ciclo de marcha estimadas mediante el modelo cinemático en el conjunto de entrenamiento.

Magnitud	**Media (%)**	**Std (%)**	**p5 (%)**	**p50 (%)**	**p95 (%)**
Apoyo pie derecho	58.4	7.8	48.0	57.0	74.0
Apoyo pie izquierdo	57.8	6.9	49.0	56.0	71.9
Oscilación pie derecho	41.6	7.8	26.0	43.0	52.0
Oscilación pie izquierdo	42.2	6.9	28.1	44.0	51.0
Doble apoyo	18.4	12.4	4.0	15.0	44.0

Tabla 4.6: Duraciones temporales de las fases del ciclo de marcha estimadas mediante el modelo cinemático en el conjunto de validación.

Capítulo 5

Discusión

Los resultados obtenidos sitúan al modelo generativo como una aproximación razonablemente fiel a la marcha humana, pero también ponen de manifiesto limitaciones claras cuando se exige generalización y coherencia biomecánica estricta. En términos generales, la red es capaz de reproducir la organización estadística de la marcha incluyendo la forma media de las trayectorias, sus rangos dinámicos y parte de su variabilidad. Además, también es capaz de generar ciclos que, tras la reconstrucción cinemática, dan lugar a patrones espaciales plausibles en una fracción importante de las muestras. Sin embargo, esta fidelidad se degrada de forma apreciable cuando se exploran combinaciones de longitud y altura de paso de mayor magnitud que las del dominio de entrenamiento.

La comparación con el algoritmo de trayectorias según objetivos clínicos desarrollado en el proyecto NIMBLE permite contextualizar estos resultados frente a soluciones basadas en modelos cinemáticos optimizados. En dicho proyecto, la combinación de un algoritmo metaheurístico IWO-IK con un modelo directo en espacio cartesiano obtiene errores medios en la longitud de paso por debajo del centímetro y en la altura por debajo de 3 cm, con coeficientes de determinación muy elevados. Cuando este planificador se sustituye por una red neuronal entrenada sobre esas soluciones, la precisión se reduce en longitud con errores típicos del orden de unos 5 centímetros, pero sin alteración en la dimensión vertical [36]. En comparación, el generador propuesto en este trabajo se sitúa en un rango similar de error absoluto en altura de paso, con medianas en torno a los 3 cm pero con valores atípicos en percentil les elevados con errores de hasta 12 cm. En la longitud de paso, en cambio, los errores crecen de forma más acusada con una mediana de error de 6.3 cm, pero valores extremos próximos a 29.5 cm en el percentil 95 en el conjunto. Esto evidencia una mayor sensibilidad en esta dimensión cuando se combinan condiciones alejadas del núcleo de datos originales. En términos prácticos, el modelo mantiene un control razonablemente fino sobre H, pero menos robusto sobre L, lo que lo sitúa por detrás de NIMBLE cuando el objetivo principal es garantizar con precisión una longitud de paso prescrita en todo el espacio clínico.

Desde una perspectiva biomecánica, la reconstrucción cartesiana de la marcha a partir de las trayectorias articulares sintetizadas confirma que una fracción importante de las secuencias generadas se traduce en patrones espaciales plausibles. En la componente anteroposterior, las trayectorias del pie describen un avance continuo y sin retrocesos bruscos, con longitudes de paso que, salvo en los casos de extrapolación comentados, resultan compatibles con las condiciones de entrada. En la componente vertical, la elevación del pie durante la oscilación y el descenso previo al contacto con el suelo reproducen una morfología similar a la observada en sujetos sanos y proporcionan un despeje suficiente para evitar el arrastre de la punta en la mayoría de los ciclos válidos. La organización temporal de las fases de apoyo y oscilación se mantiene próxima al esquema clásico de aproximadamente 60 % de apoyo y 40 % de oscilación tanto en entrenamiento como en validación, mientras que el doble apoyo presenta mayor dispersión, coherente con la sensibilidad de esta magnitud a pequeñas irregularidades verticales. En conjunto, el modelo es capaz de generar trayectorias articulares con buena capacidad biomecánica pero baja puntería en el acierto de las condiciones clínicas para su creación.

La principal limitación metodológica identificada respecto a la creación de las trayectoras atraviesa de forma transversal todos estos resultados y está directamente relacionada con la periodicidad de las secuencias generadas y con el procedimiento empleado para reconstruir la pierna contralateral. El modelo cinemático asume un desfase temporal del 50 % entre ambas piernas, de modo que cualquier discrepancia entre el estado articular inicial y final del ciclo se traduce en un empalme imperfecto al concatenar ambas mitades. En el conjunto de entrenamiento se observó una pequeña irregularidad alrededor del 50 % del ciclo en las trayectorias verticales del pie cuando se analizan todas las muestras sintéticas sin filtrar, un artefacto que prácticamente desaparece en el conjunto de validación. Esta anomalía está directamente relacionada con el término de cierre de ciclo incluido en la función de pérdida, diseñado para penalizar discrepancias entre el primer y el último instante del ciclo articular y forzar periodicidad. Aunque este término reduce de manera notable las inconsistencias, no logra corregirlas por completo en todas las muestras. Cuando una trayectoria no cumple correctamente esta condición, el desfase temporal del 50 % utilizado para reconstruir la pierna contralateral produce un salto artificial en las coordenadas cartesianas que se manifiesta como un pico alrededor de la mitad del ciclo en la coordenada vertical y como un cambio abrupto de pendiente en la componente anteroposterior. Las Figuras 5.2 y 5.1, obtenidas a partir del conjunto sintético completo sin filtrado, ilustran de forma clara este efecto y muestran cómo un empalme sin continuidad genera picos y discontinuidades en el punto de unión, en contraste con las trayectorias más suaves obtenidas tras aplicar el filtrado de calidad.

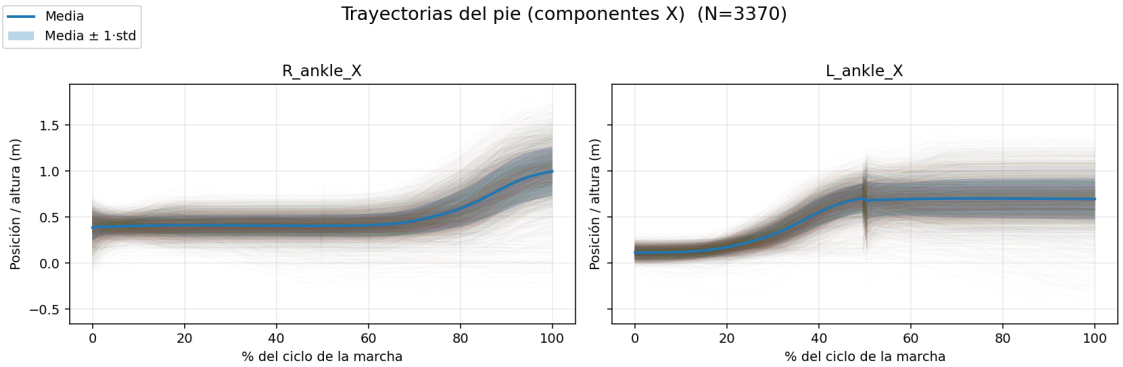


Figura 5.1: Trayectorias del pie en X recreadas con el total de los datos sintéticos de entrenamiento tras aplicar un desfase del 50 %.

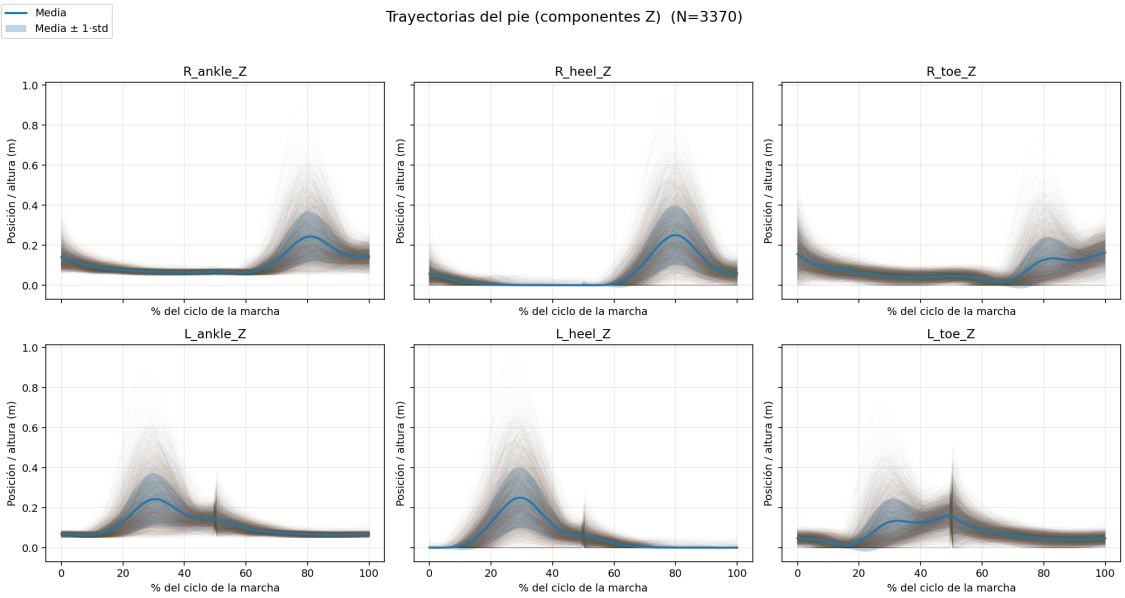


Figura 5.2: Trayectorias del pie en Z recreadas con el total de los datos sintéticos de entrenamiento tras aplicar un desfase del 50 %.

Para evitar que estos artefactos condicionaran el análisis biomecánico se aplicó precisamente ese filtrado de calidad, basado en la similitud entre los vectores articulares inicial y final de cada secuencia, conservando únicamente los ciclos que alcanzaban al menos un 95 % de similitud. Este criterio garantiza un cierre suficientemente suave como para que el desfase de medio ciclo no produzca saltos visibles en las trayectorias cartesianas, pero tiene un impacto considerable sobre el tamaño efectivo del conjunto analizado. Aproximadamente la mitad de las secuencias generadas en el conjunto de entrenamiento y algo más de un tercio de las de validación tuvieron que ser descartadas por no cumplir este umbral. El hecho de que sea necesario eliminar una proporción tan elevada de muestras revela una limitación estructural del modelo actual. En la práctica, el modelo debe entenderse por tanto

como un generador que produce un conjunto amplio de candidatos entre los que es preciso seleccionar, mediante criterios adicionales de calidad, aquellos ciclos que resultan adecuados para un análisis biomecánico detallado o para un uso posterior en simulación.

Capítulo 6

Conclusiones y líneas futuras

Primero de todo, resulta necesario recalcar las competencias adquiridas durante el grado de Ingeniería Biomédica que han sido necesarias para la realización de este trabajo. La implementación del modelo generativo y de todo el proceso de evaluación se ha sustentado en las bases de programación trabajadas en asignaturas como Fundamentos de Programación y Programación en Entornos de Red, que facilitaron en los primeros años de la carrera el aprendizaje de Python. Del mismo modo, los principios fundamentales de la inteligencia artificial, especialmente los relacionados con arquitecturas generativas y evaluación de modelo, se apoyaron en los conocimientos adquiridos en la asignatura de Inteligencia Artificial. Por otra parte, la redacción técnica y la estructuración formal de la memoria han sido posibles gracias al manejo de LaTeX aprendido en Análisis de Sistemas Dinámicos Biológicos. Finalmente, la interpretación biomecánica de las trayectorias articulares y el análisis de las fases de la marcha se han apoyado en los contenidos impartidos en la asignatura de Biomecánica.

Con esta base formativa se ha podido desarrollar y evaluar una red generativa antagónica condicionada para la síntesis de trayectorias articulares de la marcha humana a partir de condiciones clínicas específicas y medidas antropométricas individuales. El trabajo ha permitido integrar la biomecánica clásica con técnicas modernas de aprendizaje profundo y entrenar un modelo capaz de aprender la estructura estadística del movimiento humano recogida en la base de datos del proyecto NIMBLE. El generador resultante es capaz de producir nuevos ciclos articulares que, en términos globales, reproducen la forma media del movimiento, su variabilidad dentro del ciclo y las dependencias internas entre articulaciones.

En conjunto, los resultados sitúan al modelo generativo como una base prometedora para la generación de patrones de marcha condicionados por parámetros clínicos, con una representación estadística y biomecánica coherente pero con claros fallos que deben resolverse. Para ello se ponen de relieve dos líneas de trabajo prioritarias. Por un lado, el refuerzo explícito de la periodicidad y del cierre de ciclo,

durante el desarrollo del proyecto, el aumento del peso relacionado con la pérdida de cierre de ciclo no vio resultados esperanzadores, causando la pérdida bimecánica total del modelo en valores altos. Es por ello que para la mejora del modelo se requiere la creación de un mejor sistema que asegure la continuidad entre ciclos, ya sea mediante pérdidas adicionales más específicas, mediante la integración del modelo cinemático en el propio proceso de entrenamiento o mediante arquitecturas que impongan continuidad entre ciclos sucesivos. Por otro lado, es evidente la necesidad de mejora del control de las características de paso al explorar regiones del espacio clínico alejadas de los datos originales. En específico, un mayor refuerzo en la longitud de paso que presenta mayores errores que se alejan de los valores medios de error del modelo generativo creado por NIMBLE, con la posible integración de un sistema que sustituya al modelo predictor integrado por otro más eficiente. Abordar estas cuestiones permitirá convertir el modelo en una herramienta más robusta y transferible para aplicaciones de planificación, simulación y asistencia a la marcha en entornos clínicos.

Si estas direcciones se desarrollan adecuadamente, modelos como el presentado podrían convertirse en herramientas útiles para la creación de datasets ampliados, la simulación de situaciones difíciles de registrar experimentalmente y el prototipado rápido de sistemas de rehabilitación asistida. Este tipo de recursos ayudaría a reducir la dependencia de campañas experimentales extensas y a acelerar el desarrollo de tecnologías centradas en la marcha. En proyectos como NIMBLE, donde el análisis detallado del tobillo es esencial, disponer de datos sintéticos fiables permitiría evaluar algoritmos en contextos controlados y estudiar comportamientos que no siempre están disponibles en bases de datos reales.

En relación con los objetivos planteados al inicio del trabajo, se puede concluir que se han cumplido de forma coherente con lo esperado, ya que se ha diseñado un modelo generativo basado en una arquitectura cGAN entrenado con las trayectorias articulares recogidas por el proyecto NIMBLE junto con las condiciones clínicas de su modelo cinemático, produciendo ciclos articulares de la marcha condicionados por metas clínicas y antropométricas, evaluándose su coherencia estadística y biomecánica de las trayectorias sintéticas frente a datos reales. En conjunto, este trabajo demuestra que el uso de modelos generativos para la síntesis de trayectorias articulares es una vía prometedora y técnicamente viable, aunque todavía requiere refinamientos clave para garantizar su solidez biomecánica completa. El modelo reproduce con fidelidad la estructura global del ciclo de marcha y mantiene una correspondencia razonable con las condiciones clínicas impuestas, pero su uso en contextos clínicos exige avanzar en la mejora del cierre del ciclo articular y en la consistencia distal de las articulaciones. Aun así, este proyecto establece una base clara y bien delimitada sobre la que seguir desarrollando sistemas generativos aplicados al análisis y la rehabilitación de la marcha.

Bibliografía

[1] J. P. Haas, "Figure 2: Classification of a normal gait cycle (modified to Perry 1992)", *Scientific Figure on ResearchGate*, 2015. https://www.researchgate.net/figure/Classification-of-a-normal-gait-cycle-modified-to-Perry-1992-p-2-4-20_fig2_278045816

[2] J. Perry y J. M. Burnfield, "Gait Analysis: Normal and Pathological Function", *SLACK Incorporated*, 2010. https://archive.org/details/gaitanalysisnorm0000perr

[3] M. Guerrero, "Apuntes personales de la asignatura Biomecánica de G, Baviano", *Universidad Rey Juan Carlos*, Curso 2024–2025.

[4] H. Stolze, S. Klebe, C. Baecker, C. Zechlin, L. Friege, S. Pohle, y G. Deuschl, "Prevalence of gait disorders in hospitalized neurological patients", *Movement Disorders*, 2005. https://pubmed.ncbi.nlm.nih.gov/15390043/

[5] S. Tiwari, A. Joshi, N. Rai, y P. Satpathy, "Impact of Stroke on Quality of Life of Stroke Survivors and Their Caregivers: A Qualitative Study from India", *Journal of Neurosciences in Rural Practice*, 2021. https://pubmed.ncbi.nlm.nih.gov/34737502/

[6] World Health Organization, "Over 1 in 3 people affected by neurological conditions, the leading cause of illness and disability worldwide", Nota de prensa, 14 March 2024. https://www.who.int/news/item/14-03-2024-over-1-in-3-people-affected-by-neurological-conditions--the-leading-cause-of-illness-and-disability-worldwide

[7] Y. Béjot, H. Bailly, J. Durier, y M. Giroud, "Epidemiology of stroke in Europe and trends for the 21st century", *La Presse Médicale*, 2016. https://pubmed.ncbi.nlm.nih.gov/27816343/

[8] S. Li, G. E. Francisco, y P. Zhou, "Post-stroke Hemiplegic Gait: New Perspective and Insights", *Frontiers in Physiology*, 2018. https://www.frontiersin.org/articles/10.3389/fphys.2018.01021/full

[9] B. H. Dobkin, "Rehabilitation after Stroke", *The New England Journal of Medicine*, 2005. https://www.researchgate.net/publication/7893247_Rehabilitation_after_Stroke

[10] A. M. Dollar y H. Herr, "Lower extremity exoskeletons and active orthoses: Challenges and state-of-the-art", *IEEE Transactions on Robotics*, 2008. https://ieeexplore.ieee.org/document/4479627

[11] S. Jezernik, G. Colombo, T. Keller, M. Frueh, y M. Morari, "Robotic orthosis Lokomat: A rehabilitation and research tool", *Neuromodulation*, 2003. https://pubmed.ncbi.nlm.nih.gov/22150969/

[12] Y.-H. Park, D.-H. Lee, y J.-H. Lee, "A comprehensive review: Robot-assisted treatments for gait rehabilitation in stroke patients", *Medicina*, 2024. https://www.mdpi.com/1648-9144/60/4/620

[13] K. Y. Nam, H. J. Kim, B. S. Kwon, J.-W. Park, H. J. Lee, y A. Yoo, "Robot-assisted gait training (Lokomat) improves walking function and activity in people with spinal cord injury: A systematic review", *Journal of NeuroEngineering and Rehabilitation*, 2017. https://jneuroengrehab.biomedcentral.com/articles/10.1186/s12984-017-0232-3

[14] J. Mehrholz, S. Thomas, J. Kugler, M. Pohl, y B. Elsner, "Electromechanical-assisted training for walking after stroke", *Cochrane Database of Systematic Reviews*, 2020. https://www.cochranelibrary.com/cdsr/doi/10.1002/14651858.CD006185.pub5/full

[15] I. Aprile, C. Conte, A. Cruciani, C. Pecchioli, L. Castelli, S. E. Insalaco, M. Germanotta, C. Iacovelli, et al., "Efficacy of robot-assisted gait training combined with robotic balance training in subacute stroke patients: a randomized clinical trial", *Journal of Clinical Medicine*, 2022. https://www.mdpi.com/2077-0383/11/17/5162

[16] K. van Kammen, A. M. Boonstra, L. H. V. van der Woude, C. Visscher, H. A. Reinders-Messelink, y R. den Otter, "Lokomat guided gait in hemiparetic stroke patients: The effects of training parameters on muscle activity and temporal symmetry", *Disability and Rehabilitation*, 2020. https://pubmed.ncbi.nlm.nih.gov/30973764/

[17] M. Potašová, P. Mačej, E. Moraučíková, P. S. Baňárová, y P. Kutiš, "Lokomat vs. Conventional Therapy—Impact on Gait Symmetry in Hemiparetic Patients: Preliminary Clinical Study", *Healthcare*, 2025. https://www.mdpi.com/2227-9032/13/8/929

[18] İ. Saral, E. Tekeci, Y. T. Yayla, y E. Çakar, "Clinical practice data of robot-assisted gait therapy after stroke: a retrospective study", *Bagcilar Medical Bulletin*, vol. 7, no. 4, 2022. https://www.behmedicalbulletin.org/pdf/1e8a7eae-47cf-4a4e-a540-9cee47620b04/articles/BMB.galenos.2022.2022-06-055/Bagc%C4%B1larMedicalBulletin-7-319-En.pdf

[19] L. Marchal-Crespo y D. J. Reinkensmeyer, "Review of control strategies for robotic movement training after neurologic injury", *Journal of NeuroEngineering and Rehabilitation*, 2009. https://jneuroengrehab.biomedcentral.com/articles/10.1186/1743-0003-6-20

[20] J. F. Veneman, R. Kruidhof, E. E. G. Hekman, R. Ekkelenkamp, E. H. F. Van Asseldonk, y H. van der Kooij, "Design and evaluation of the LOPES exoskeleton robot for interactive gait rehabilitation", *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2007. https://pubmed.ncbi.nlm.nih.gov/17894270/

[21] S. M. Campbell, C. P. Diduch, y J. W. Sensinger, "Autonomous Assistance-as-Needed Control of a Lower Limb Exoskeleton With Guaranteed Stability", *IEEE Access*, 2020. https://ieeexplore.ieee.org/document/8995557

[22] H. Kawamoto, K. Sankai, et al., "Pilot study: locomotion improvement using HAL in chronic stroke", *BMC Neurology*, 2013. https://bmcneurol.biomedcentral.com/articles/10.1186/1471-2377-13-141

[23] A. Nilsson, et al., "Gait training early after stroke with HAL: safety & feasibility", *BMC Neurology*, 2014. https://pmc.ncbi.nlm.nih.gov/articles/PMC4065313/

[24] A. Rodríguez-Fernández, et al., "Systematic review on wearable lower-limb exoskeletons for gait training in neuromuscular impairments", *Journal of NeuroEngineering and Rehabilitation*, 2021. https://jneuroengrehab.biomedcentral.com/articles/10.1186/s12984-021-00815-5

[25] C. Park, J. Hwang, y J. H. You, "Comparative Effectiveness of Robot-interactive Gait Training With and Without Ankle Robotic Control in Patients with Brain Damage", *Archives of Physical Medicine and Rehabilitation*, 2022. https://www.researchgate.net/publication/358968128_Comparative_Effectiveness_of_Robot-interactive_Gait_Training_With_and_Without_Ankle_Robotic_Control_in_Patients_with_Brain_Damage

[26] L. M. Mooney y H. M. Herr, "Biomechanical walking mechanisms underlying the metabolic reduction caused by an autonomous exoskeleton", *Journal of NeuroEngineering and Rehabilitation*, 2016. https://jneuroengrehab.biomedcentral.com/articles/10.1186/s12984-016-0111-3

[27] ReWalk Robotics Ltd., "FDA Issues Clearance for the ReStore™ Exo-Suit, the First Soft Robotic System for Stroke Therapy", Comunicado de prensa, 4 June 2019. https://www.prnewswire.com/news-releases/fda-issues-clearance-for-the-restore-exo-suit-the-first-soft-robotic-system-for-stroke-therapy-300861824.html

[28] L. N. Awad, A. Esquenazi, G. E. Francisco, K. J. Nolan, y A. Jayaraman, "The ReWalk ReStore™ soft robotic exosuit: a multi-site clinical trial of the safety, reliability, and feasibility of exosuit-augmented post-stroke gait rehabilitation", *Journal of NeuroEngineering and Rehabilitation*, 2020. https://jneuroengrehab.biomedcentral.com/articles/10.1186/s12984-020-00702-5

[29] K. Ernstmeyer y E. Christman (eds.), "Table 13.2b. Common Types of Assistance Required", In: *Nursing Fundamentals [Internet]*, Eau Claire (WI): Chippewa Valley Technical College; 2021. https://www.ncbi.nlm.nih.gov/books/NBK591828/table/ch13mobility.T.common_types_of_assistanc/

[30] Hocoma AG, "Figure: The Lokomat gait rehabilitation robot", *Scientific Figure on ResearchGate*, 2001. Available from: https://www.researchgate.net/figure/The-Lokomat-gait-rehabilitation-robot-Photo-courtesy-of-Hocoma-AG_fig1_225084999 [accessed 28 Nov 2025].

[31] L. van Dijk et al., "Figure: A subject walking with the LOPES-II exoskeleton", *Scientific Figure on ResearchGate*, 2019. Available from: https://www.researchgate.net/figure/A-subject-walking-with-LOPES-II-exoskeleton_fig1_335140849 [accessed 28 Nov 2025].

[32] Cyberdyne Inc., "Figure: Hybrid Assistive Limb (HAL) exoskeleton", *EurekAlert! Multimedia*, 2020. Available from: https://www.eurekalert.org/multimedia/822235 [accessed 28 Nov 2025].

[33] ReWalk Robotics, "Figure: ReStore soft exosuit for post-stroke gait rehabilitation", *MedicalExpo*, 2019. Available from: https://www.medicalexpo.es/prod/rewalk-robotics/product-80949-913531.html [accessed 28 Nov 2025].

[34] J. Ramos-Rojas, J. A. Castaño, P. R. Fernández, J. Carballeira, E. Pérez-Martín, J. S. Lora-Millán, S. Borromeo, y A. J. del-Ama, "Design and validation of an ambulatory user support gait rehabilitation robot: NIMBLE", *Actuators*, 2024. https://doi.org/10.3390/act13090348

[35] J. S. Lora-Millán, J. Ramos-Rojas, J. Carballeira, J. A. Castaño, y A. J. del-Ama, "A Direct Gait Kinematic Model to Estimate Forward Progression and Spatial Stepping Features in Cartesian Space", *IEEE Access*, 2025. https://doi.org/10.1109/ACCESS.2025.3587807

[36] J. S. Lora-Millán, J. Ramos-Rojas, J. Carballeira-Lopez y A. J. del-Ama, "A Metaheuristic Approach for Adaptative Joint-Space Trajectory Generation for Lower-Limb Exoskeletons Based on Step Length and Foot Clearance Requirements", In: Pons, J.L., Tornero, J., y Akay, M. (eds), Converging Clinical and Engineering Research on Neurorehabilitation V. ICNR 2024. Biosystems & Biorobotics, vol. 31. Springer, Cham, 2025. https://doi.org/10.1007/978-3-031-77588-8_3

[37] C. Di Natali, F. Polichetti, L. Garzo, M. Bravi, F. Cempini, N. Vitiello, y C. A. Avizzano, "Systematic framework for performance evaluation of exoskeletons: A case study on lower-limb devices", *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2020. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC11265387/

[38] S. Fong, S. Deb, y X.-S. Yang, "Metaheuristic algorithms for optimization in robotics: A survey", *Computers & Electrical Engineering*, 2015. https://www.sciencedirect.com/science/article/abs/pii/S0045790615000154

[39] A. Slowik y H. Kwasnicka, "Evolutionary algorithms and their applications to engineering problems", *Neural Computing and Applications*, 2020. https://link.springer.com/article/10.1007/s00521-020-04832-8

[40] B. Ren, J. Liu, y J. Chen, "Simulating human–machine coupled model for gait trajectory optimization of the lower limb exoskeleton system based on genetic algorithm", *International Journal of Advanced Robotic Systems*, 2020. https://doi.org/10.1177/1729881419893493

[41] J. Wang, B. Tang, M. Pang, K. Xiang, y Z. Ju, "Self-adaptive particle swarm optimization with human-in-the-loop for ankle exoskeleton control", *Sensors and Materials*, 2021. https://doi.org/10.18494/SAM.2021.3227

[42] O. Coser, C. Tamantini, P. Soda, y L. Zollo, "AI-based methodologies for exoskeleton-assisted rehabilitation of the lower limb: a review", *Frontiers in Robotics and AI*, 2024. https://doi.org/10.3389/frobt.2024.1341580

[43] "What is a Multilayer Perceptron (MLP) or a Feedforward Neural Network (FNN)?", AIML.com, 2025. https://aiml.com/what-is-a-multilayer-perceptron-mlp/

[44] S. Luo, G. Androwis, S. Adamovich, H. Su, y X. Zhou, "Reinforcement Learning and Control of a Lower Extremity Exoskeleton for Squat Assistance", *Frontiers in Robotics and AI*, 2021. https://www.frontiersin.org/articles/10.3389/frobt.2021.702845/full

[45] S. Luo, G. Androwis, S. Adamovich, E. Nunez, H. Su, y X. Zhou, "Robust walking control of a lower limb rehabilitation exoskeleton coupled with a musculoskeletal model via deep reinforcement learning", *Journal of NeuroEngineering and Rehabilitation*, 2023. https://jneuroengrehab.biomedcentral.com/articles/10.1186/s12984-023-01147-2

[46] O. Coser, C. Tamantini, M. Tortora, L. Furia, R. Sicilia, L. Zollo, y P. Soda, "Deep Learning for Human Locomotion Analysis in Lower-Limb Exoskeletons: A Comparative Study", *Frontiers in Computer Science*, 2025. https://www.frontiersin.org/articles/10.3389/fcomp.2025.1597143/full

[47] M. Z. Uddin, T. T. Ngo, Y. Makihara, N. Takemura, X. Li, D. Muramatsu, y Y. Yagi, "The OU-ISIR Large Population Gait Database with Real-Life Carried Object and its Performance Evaluation", *IPSJ Transactions on Computer Vision and Applications*, 2018. https://doi.org/10.1186/s41074-018-0041-z

[48] B. Van Hooren, J. T. Fuller, J. D. Buckley, J. R. Miller, K. Sewell, G. Rao, C. Barton, C. Bishop, y R. W. Willy, "Is Motorized Treadmill Running Biomechanically Comparable to Overground Running? A Systematic Review and Meta-Analysis of Cross-Over Studies", *Sports Medicine*, 2020. https://pubmed.ncbi.nlm.nih.gov/31802395/

[49] S. Sarkar, P. J. Phillips, Z. Liu, I. R. Vega, P. Grother, y K. W. Bowyer, "The humanID gait challenge problem: data sets, performance, and analysis", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2005. https://pubmed.ncbi.nlm.nih.gov/15688555/

[50] E. Ruff, R. Russell, M. Stoeckle, P. Miotto, y J. P. How, "Surrogate Neural Networks for Efficient Simulation-based Trajectory Planning Optimization", arXiv preprint arXiv:2303.17468, 2023. https://arxiv.org/abs/2303.17468

[51] C. Dindorf, J. Dully, J. Konradi, C. Wolf, S. Becker, S. Simon, J. Huthwelker, F. Werthmann, J. Kniepert, P. Drees, U. Betz, M. Fröhlich, "Enhancing biomechanical machine learning with limited data: generating realistic synthetic posture data using generative artificial intelligence", *Frontiers in Bioengineering and Biotechnology*, vol. 12, 2024. https://www.frontiersin.org/journals/bioengineering-and-biotechnology/articles/10.3389/fbioe.2024.1350135/full

[52] E. Barsoum, J. Kender, y Z. Liu, "HP-GAN: Probabilistic 3D human motion prediction via GAN", *Proceedings of the CVPR 2018 Workshops*, 2018. https://openaccess.thecvf.com/content_cvpr_2018_workshops/w29/html/Barsoum_HP-GAN_Probabilistic_3D_CVPR_2018_paper.html

[53] Y. Wang, Z. Li, X. Wang, H. Yu, W. Liao, y D. Arifoglu, "Human Gait Data Augmentation and Trajectory Prediction for Lower-Limb Rehabilitation Robot Control Using GANs and Attention Mechanism", *Machines*, vol. 9, no. 12, article 367, 2021. https://doi.org/10.3390/machines9120367

[54] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, y Y. Bengio, "Generative Adversarial Networks", arXiv preprint arXiv:1406.2661, 2014. https://arxiv.org/abs/1406.2661

[55] J. F. Nash, "Equilibrium Points in N-Person Games", *Proceedings of the National Academy of Sciences*, 1950. https://www.pnas.org/doi/10.1073/pnas.36.1.48

[56] J. Lin, "Divergence Measures Based on the Shannon Entropy", *IEEE Transactions on Information Theory*, 1991. https://ieeexplore.ieee.org/document/61115

[57] M. Arjovsky y L. Bottou, "Towards Principled Methods for Training Generative Adversarial Networks", arXiv preprint arXiv:1701.04862, 2017. https://arxiv.org/abs/1701.04862

[58] M. Arjovsky, S. Chintala, y L. Bottou, "Wasserstein GAN", *arXiv*, 2017. https://arxiv.org/abs/1701.07875

[59] I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, y A. Courville, "Improved Training of Wasserstein GANs", *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. https://arxiv.org/abs/1704.00028

[60] X. Li, Y. Wang, y C. Zhang, "TTS-CGAN: A Transformer Time-Series Conditional GAN for Biosignal Data Augmentation", arXiv preprint arXiv:2206.13676, 2022. https://arxiv.org/abs/2206.13676

[61] M. Mirza y S. Osindero, "Conditional Generative Adversarial Nets", arXiv preprint arXiv:1411.1784, 2014. https://arxiv.org/abs/1411.1784

[62] "Introduction to Conditional GANs (CGAN)", Scaler Topics, 2023. https://www.scaler.com/topics/cgan/

[63] T. Golany y K. Radinsky, "PGANs: Personalized Generative Adversarial Networks for ECG Synthesis to Improve Patient-Specific Cardiovascular Diagnosis", *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, no. 01, pp. 133–140, 2020. https://ojs.aaai.org/index.php/AAAI/article/view/3830

[64] F. Kugler, M. Garcia, C. O'Reilly, y E. Nemati, "A Conditional GAN for Generating Time Series Data for Stress Detection in Wearable Physiological Sensor Data", *Sensors*, vol. 22, no. 16, 5969, 2022. https://www.mdpi.com/1424-8220/22/16/5969

[65] M. Kim y L. J. Hargrove, "Generating synthetic gait patterns based on benchmark datasets for controlling prosthetic legs," *Journal of NeuroEngineering and Rehabilitation*, 2023. https://jneuroengrehab.biomedcentral.com/articles/10.1186/s12984-023-01232-6

[66] V. Avkhimenia, *CWGAN-GP-time-series: Conditional Wasserstein GAN-GP for Synthetic Time Series*, Repositorio en GitHub. Disponible en: https://github.com/avkhimen/CWGAN-GP-time-series

[67] P. D'Oro, *pytorch-GAN-timeseries: Generative Adversarial Networks for Time Series*, Repositorio en GitHub. Disponible en: https://github.com/proceduralia/pytorch-GAN-timeseries

[68] J. Park, *eeg-wgan: Wasserstein GAN with Gradient Penalty for EEG Signal Generation*, Repositorio en GitHub. Disponible en: https://github.com/JoshParkSJ/eeg-wgan

[69] A. Nasri, A. Abbasi, Z. Hadavi, S. Abbasi y Z. Svoboda, "Lower-extremity interjoint coordination variability in active individuals with transtibial amputation and healthy males during gait", *Scientific Reports*, vol. 14, art. 11668, 2024. https://pmc.ncbi.nlm.nih.gov/articles/PMC11111844/